

碩士論文口試

學生 黃丞暘

指導教授 曹振海

國立東華大學應用數學系統計碩士班

2026 年 4 月 XX 日

目錄

背景與動機

問題與目的

資料與前處理

方法與流程

結果與討論

背景與動機

研究背景



半導體製程：累積大量資料，同時具有高維度、高缺失率與類別不平衡，建模與解釋皆具難度

模型預測：黑箱模型有很好的預測／分類能力，且在品質預測可作為良率改善與製程監控的基礎

研究動機



- 黑箱模型：箱子內的計算是什麼？如何預測是好還是壞？
依據是？

文獻回顧

- ▶ 黑箱模型可作為高維資料的強基準，但解釋性不足。
- ▶ SHAP 可量化特徵貢獻 [2]
- ▶ LIME 可做局部解釋，但在高維異質資料下可能不穩定。
[3]

問題與目的

研究目的

- ▶ 若整體資料存在多個子群，單一模型的局部解釋可能混合不同規則。
- ▶ 分群後建立黑箱模型，以降低資料異質性對模型學習的干擾。
- ▶ 若以隨機擾動生成鄰近點，可能偏離真實資料分布，產生外插風險。
- ▶ 設計格子點生成方法，以控制局部擾動範圍，提升局部擬合的穩定性，並降低外插可能造成的偏誤
- ▶ 建立可檢視的局部刻劃模型，以作為黑箱模型在分類行為上的可解釋依據。

資料與前處理

研究資料

▶ 半導體製程資料 SEmi COnductor Manufacturing

idx	Time	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1


▶ 共 1567 筆樣本

▶ 590 個量測變數


▶ 1 個二元品質類別，其中 Pass(-1) 有 1463 筆 (93.36%)，Fail(1) 有 104 筆 (6.64%)

資料來源：UCI SECOM Dataset

資料 EDA - 目標變數




資料 EDA - 單一特徵的缺失值




► 動作：移除缺失值數量超過 1000 筆的單一特徵

資料 EDA - 單一特徵的相異值



► 動作：移除相異值種類低於 10 種的單一特徵



資料 EDA - 補齊缺失值



- ▶ KNN 補值法在缺失值估計上具有良好的穩健性 [4]
- ▶ 動作：採用 KNN imputer 進行補值，設定 $k = 10$

資料 EDA - 極端點

- ▶ 離群樣本對 PCA 主成分方向與投影結果造成影響 [1]
- ▶ 動作：依門檻 $PC1 \leq 10$ 及 $PC2 \leq 10$ 移除極端點



資料前處理

- (1) 目標變數重新編碼：Pass ($-1 \rightarrow 0$)，移除時間欄位
- (2) 移除缺失值數量超過 1000 筆的單一特徵
- (3) 移除相異值種類低於 10 種的單一特徵
- (4) 採用 KNN imputer 進行補值，設定 $k = 10$
- (5) 依門檻 $PC1 \leq 10$ 及 $PC2 \leq 10$ 移除極端點


最終分析資料

► 最終分析資料為 1525 筆樣本、459 個特徵

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0

方法與流程


流程大綱




分群設計：SMOTE $\rightarrow$ PCA $\rightarrow$ KMeans

- ▶ 以 SMOTE 補強少數類別於降維空間中的資訊。
- ▶ 於 PCA 空間以 k-means 進行分群。
- ▶ 以 elbow method 選定群數 $k = 2$ 。

前



後



- ▶ 完成分群後移除合成樣本，只保留真實資料供後續建模

黑箱模型

- ▶ Skicit-learn: XGBClassifier
- ▶ 評估方式：五折交叉驗證
- ▶ 僅在訓練集執行 SMOTE，每一折當測試集輸出機率值
- ▶ 用 Accuracy(ACC)、False Alarm Rate(FAR)、ROC-AUC 評估群間是否有差異

局部刻劃方法

- ▶ 在群 c 內，取滿足 $|\hat{p} - 0.5| \leq 0.05$ 的樣本集合，記為 S_n^c
- ▶ 對 S_n^c 內的樣本特徵向量取平均，定義群內中心點為

$$x_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^{(c)}, \dots, x_p^{(c)})$$


- ▶ 以中心點為基準生成格子點：

$$x^{(m)} = x_{\text{center}}^c + \delta \mathbf{m}$$

其中


- δ 為各維度相同的位移步長
- $\mathbf{m} = (m_1, \dots, m_p)$ 為位移向量，且
 $m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$
- ▶ 共有 $(2k+1)^p$ 個格子點

局部格子點舉例



- ▶ 以黑箱模型對格子點輸出的預測機率作為應變數
- ▶ 本研究： $p = 459$ 、 $k = 2$

建立局部刻劃模型




結果與討論

分群黑箱模型

group	n	Pass / Fail	ACC	FAR	ROC-AUC
全體	1525	1430 / 95	0.9272 [0.9141, 0.9397]	0.0189 [0.0120, 0.0264]	0.6623 [0.6054, 0.7178]
群 0	676	619 / 57	0.8846 [0.8595, 0.9083]	0.0468 [0.0308, 0.0639]	0.6983 [0.6308, 0.7631]
群 1	849	811 / 38	0.9482 [0.9329, 0.9623]	0.0099 [0.0037, 0.0172]	0.6224 [0.5228, 0.7171]

決策邊界樣本與中心點建立



► 篩選結果：群 0 取 12 個、群 1 取 7 個。

局部刻劃模型結果

Cluster	使用特徵數	點估計	95% 信賴區間
0	96	0.584160	[0.583563, 0.584737]
1	56	0.592644	[0.590905, 0.594560]

群 0 : 特徵係數

特徵	係數	特徵	係數	特徵	係數
intercept	1.005144	x153	0.013929	x554	0.008468
x291	0.034033	x426	0.013283	x324	-0.008034
x7	-0.029912	x588	0.011796	x361	0.007764
x141	-0.028171	x585	0.010932	x247	-0.007745
x87	0.022993	x253	0.009463	x274	-0.007529
x217	0.022274	x144	-0.009319	x282	-0.007520
x461	0.019723	x470	0.009020	x525	0.007486
x20	0.017796	x103	-0.008795	x578	-0.006877
x58	-0.015820	x518	-0.008775	x240	0.006598
x1	-0.014731	x358	0.008565	x164	0.006592
x378	0.014099				

群 1 : 特徵係數

特徵	係數	特徵	係數	特徵	係數
(intercept)	0.996643	x8	0.004151	x196	0.002293
x386	0.016675	x92	0.003006	x337	0.002250
x117	-0.012556	x112	-0.002733	x81	0.002090
x420	-0.011799	x288	0.002681	x276	0.001966
x456	0.010252	x252	0.00264	x51	0.001769
x28	-0.009172	x17	0.002646	x355	-0.001724
x36	-0.008981	x347	0.002574	x145	-0.001689
x287	-0.007539	x82	0.002374	x431	0.001613
x103	-0.006848	x551	-0.002365	x571	-0.001550
x583	0.005797	x497	0.002339	x247	0.001472
x184	0.005055				

結果總結

- ▶ 分群後，各群黑箱模型呈現不同的錯誤型態與可分類程度。
- ▶ 以決策邊界附近樣本建立中心點，可聚焦於模型判斷最不明確的局部區域。
- ▶ 結構化格子點可在可控制的鄰域內近似黑箱輸出，避免隨機擾動造成的外插偏誤。
- ▶ 群內局部刻劃模型可將黑箱決策轉為具體的局部重要特徵與方向性資訊。

結論

- ▶ 本研究提出一套適用於高維、缺失嚴重且類別不平衡製程資料的分析流程。
- ▶ 透過先分群再於群內建模，可降低異質性對黑箱學習與局部解釋的干擾。
- ▶ 透過中心點與格子點設計，可在較低外插風險下建立局部線性刻劃模型。
- ▶ 研究結果顯示，不同子群對應不同的黑箱局部決策結構，分群式局部刻劃具分析價值。

未來工作

附錄

References I

-  Mia Hubert, Peter J. Rousseeuw, and Karlien Vanden Branden.
ROBPCA: A New Approach to Robust Principal Component Analysis.
Technometrics, 47(1):64–79, 2005.
<https://doi.org/10.1198/004017004000000563>.
-  Scott Lundberg and Su-In Lee.
A Unified Approach to Interpreting Model Predictions.
(arXiv:1705.07874), 2017.
arXiv. <https://doi.org/10.48550/arXiv.1705.07874>.

References II



Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin.

「Why Should I Trust You?」: Explaining the Predictions of Any Classifier.

Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pages 1135–1144, 2016.

<https://doi.org/10.1145/2939672.2939778>.



Olga Troyanskaya, Michael Cantor, Gavin Sherlock, Pat Brown, Trevor Hastie, Robert Tibshirani, David Botstein, and Russ B. Altman.

Missing value estimation methods for DNA microarrays.

Bioinformatics, 17(6):520–525, 2001.

<https://api.semanticscholar.org/CorpusID:1105917>.

References III

謝謝聆聽

問題