

# 碩士論文口試

學生 黃丞暘

指導教授 曹振海

國立東華大學應用數學系統計碩士班

2026 年 X 月 XX 日

# 目錄

介紹

問題與方法

結果與討論

# 介紹



力晶電子



台積電



台灣美日先進光罩



旺宏電子



南亞科技



茂德科技



華亞科技




量宏科技



瑞晶電子

圖片來源：鋒霈環境科技股份有限公司

# 半導體




## 六大製程



圖片來源：SEMI 國際半導體產業協會

## 晶片良率



圖片來源：WIKIPIEDA

## 資料


### ▶ 半導體製程資料 SEmi COnductor Manufacturing

| idx | Time                | x1        | x2        | x3        | ... | x588   | x589   | x590     | Pass/Fail |
|-----|---------------------|-----------|-----------|-----------|-----|--------|--------|----------|-----------|
| 1   | 2008-07-19 11:55:00 | 3030.9300 | 2564.0000 | 2187.7333 | ... | NaN    | NaN    | NaN      | -1        |
| 2   | 2008-07-19 12:32:00 | 3095.7800 | 2465.1400 | 2230.4222 | ... | 0.0201 | 0.0060 | 208.2045 | -1        |
| 3   | 2008-07-19 13:17:00 | 2932.6100 | 2559.9400 | 2186.4111 | ... | 0.0484 | 0.0148 | 82.8602  | 1         |
| 4   | 2008-07-19 14:43:00 | 2988.7200 | 2479.9000 | 2199.0333 | ... | 0.0149 | 0.0044 | 73.8432  | -1        |
| 5   | 2008-07-19 15:22:00 | 3032.2400 | 2502.8700 | 2233.3667 | ... | 0.0149 | 0.0044 | 73.8432  | -1        |



- ▶ 共 1567 筆樣本
- ▶ 590 個量測變數
- ▶ -1 代表 Pass，1 代表 Fail

資料來源：UCI SECOM Dataset

## 資料 - 類別不平衡



## 資料 - 高維度、高缺失率



## 文獻回顧

▶ 賴立夫 (2022) [2]



## 目的

- ▶ 建立較佳的預測模型
- ▶ 在該模型上提供對單一預測結果具參考價值的解釋
- ▶ 比較：全體資料之預測結果

| 研究         | 前處理方法     | 預測模型               | ACC    | FAR    |
|------------|-----------|--------------------|--------|--------|
| 賴利夫 (2022) | KNN、SMOTE | 決策樹 (ID3)          | 85.99% | 11.26% |
| 賴利夫 (2022) | KNN、SMOTE | 決策樹 (CART)         | 86.94% | 9.22%  |
| 本研究        | 資料前處理     | XGBoost Classifier | 92.72% | 1.89%  |


# 問題與方法

# 問題

- ▶ 如何建立好的預測模型
  - 量測變數龐大，能蒐集到的樣本數不足
  - 多個子群結構
- ▶ 如何讓局部刻劃更可靠
  - 隨機擾動生成

【舉例】咖啡廳


## 流程



## 資料前處理

- (1) 目標變數重新編碼：Pass ( $-1 \rightarrow 0$ )，移除時間欄位
- (2) 移除缺失值數量超過 1000 筆的單一特徵
- (3) 移除相異值種類低於 10 種的單一特徵
- (4) 採用 KNN imputer 進行補值，設定  $k = 10$
- (5) 移除離群樣本

## 資料 - 離群樣本



► 離群樣本對 PCA 主成分方向與投影結果造成影響 [1]

# 最終資料

| idx | x1        | x2        | x3        | ... | x588      | x589      | x590      | Pass/Fail |
|-----|-----------|-----------|-----------|-----|-----------|-----------|-----------|-----------|
| 1   | 0.216411  | 0.856549  | -0.434551 | ... | -0.140893 | -0.050083 | 0.201450  | 0         |
| 2   | 1.094037  | -0.374751 | 1.020782  | ... | 0.421933  | 0.258167  | 1.167895  | 0         |
| 3   | -1.114171 | 0.805982  | -0.479627 | ... | 3.631596  | 3.316370  | -0.171694 | 1         |
| 4   | -0.354825 | -0.190915 | -0.049316 | ... | -0.167828 | -0.297870 | -0.268061 | 0         |
| 5   | 0.234139  | 0.095176  | 1.121165  | ... | -0.167828 | -0.297870 | -0.268061 | 0         |

► 最終分析資料為 1525 筆樣本、459 個特徵

## 分群

- ▶ 存在類別不平衡？

以 SMOTE 補強少數類別於降維空間中的資訊

- ▶ SMOTE → PCA → KMeans 分成兩群

- ▶ 完成分群後移除合成資料，只保留真實資料供後續建模

# 預測模型

- ▶ XGBoost Classifier
- ▶ 採用五折交叉驗證，得到每筆樣本輸出機率  $\hat{p}$

| 群 0  |           |                   | 群 1  |           |                   |
|------|-----------|-------------------|------|-----------|-------------------|
| 樣本編號 | $\hat{p}$ | $ \hat{p} - 0.5 $ | 樣本編號 | $\hat{p}$ | $ \hat{p} - 0.5 $ |
| 82   | 0.498364  | 0.001636          | 1158 | 0.493004  | 0.006996          |
| 225  | 0.516134  | 0.016134          | 990  | 0.513882  | 0.013882          |
| 44   | 0.481022  | 0.018978          | 1361 | 0.521811  | 0.021811          |
| 144  | 0.527558  | 0.027558          | 1189 | 0.473835  | 0.026165          |
| 345  | 0.470658  | 0.029342          | 1187 | 0.528723  | 0.028723          |

## 局部刻劃方法

- ▶ 在群  $c$  內，取滿足  $|\hat{p} - 0.5| \leq 0.05$  的樣本集合，記為  $S_n^c$
- ▶ 對  $S_n^c$  內的樣本特徵向量取平均，定義群內中心點為

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$


- ▶ 以中心點為基準生成格子點：

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m}$$

其中


- $\delta$  為各維度相同的位移步長
- $\mathbf{m} = (m_1, \dots, m_p)$  為位移向量，且  
 $m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$
- ▶ 共有  $(2k+1)^p$  個格子點

## 局部格子點舉例



- ▶ 以預測模型對格子點輸出的機率作為應變數
- ▶ 本研究：  $p = 459$ 、 $k = 2$

## 建立局部刻劃模型



# 結果與討論

## 比較分群後的預測模型

### ► 預測模型：XGBoost Classifier

| 群名  | 樣本數  | Pass / Fail | ACC                        | FAR                        | ROC-AUC                    |
|-----|------|-------------|----------------------------|----------------------------|----------------------------|
| 全體  | 1525 | 1430 / 95   | 0.9272<br>[0.9141, 0.9397] | 0.0189<br>[0.0120, 0.0264] | 0.6623<br>[0.6054, 0.7178] |
| 群 0 | 676  | 619 / 57    | 0.8846<br>[0.8595, 0.9083] | 0.0468<br>[0.0308, 0.0639] | 0.6983<br>[0.6308, 0.7631] |
| 群 1 | 849  | 811 / 38    | 0.9482<br>[0.9329, 0.9623] | 0.0099<br>[0.0037, 0.0172] | 0.6224<br>[0.5228, 0.7171] |

## 決策邊界樣本

| 群 0  |           |                   | 群 1  |           |                   |
|------|-----------|-------------------|------|-----------|-------------------|
| 樣本編號 | $\hat{p}$ | $ \hat{p} - 0.5 $ | 樣本編號 | $\hat{p}$ | $ \hat{p} - 0.5 $ |
| 82   | 0.498364  | 0.001636          | 1158 | 0.493004  | 0.006996          |
| 225  | 0.516134  | 0.016134          | 990  | 0.513882  | 0.013882          |
| 44   | 0.481022  | 0.018978          | 1361 | 0.521811  | 0.021811          |
| 144  | 0.527558  | 0.027558          | 1189 | 0.473835  | 0.026165          |
| 345  | 0.470658  | 0.029342          | 1187 | 0.528723  | 0.028723          |
| 298  | 0.468458  | 0.031542          | 458  | 0.464450  | 0.035550          |
| 484  | 0.533517  | 0.033517          | 1054 | 0.540420  | 0.040420          |
| 105  | 0.458454  | 0.041546          |      |           |                   |
| 111  | 0.457258  | 0.042742          |      |           |                   |
| 247  | 0.544061  | 0.044061          |      |           |                   |
| 653  | 0.548375  | 0.048375          |      |           |                   |
| 109  | 0.548989  | 0.048989          |      |           |                   |

## 局部刻劃模型結果





| 最終使用特徵數 |    | 特徵                              |
|---------|----|---------------------------------|
| 群 0     | 96 | x291, x87, x217, x461, x20, ... |
| 群 1     | 56 | x386, x456, x583, x184, x8, ... |

| 群 0                                        |           | 群 1                                        |           |
|--------------------------------------------|-----------|--------------------------------------------|-----------|
| $R^2 = 0.5842$                             |           | $R^2 = 0.5926$                             |           |
| 95% <i>C.I.</i> $\in [0.583563, 0.584737]$ |           | 95% <i>C.I.</i> $\in [0.590905, 0.594560]$ |           |
| 特徵                                         | 估計係數      | 特徵                                         | 估計係數      |
| intercept                                  | 1.005144  | intercept                                  | 0.996643  |
| x291                                       | 0.034033  | x386                                       | 0.016675  |
| x7                                         | -0.029912 | x117                                       | -0.012556 |
| x141                                       | -0.028171 | x420                                       | -0.011799 |
| x87                                        | 0.022993  | x456                                       | 0.010252  |
| x217                                       | 0.022274  | x28                                        | -0.009172 |
| x461                                       | 0.019723  | x36                                        | -0.008981 |
| x20                                        | 0.017796  | x287                                       | -0.007539 |
| x58                                        | -0.015820 | x103                                       | -0.006848 |
| x1                                         | -0.014731 | x583                                       | 0.005797  |
| x378                                       | 0.014099  | x184                                       | 0.005055  |

## 局部刻劃模型跨群比較

| 比較設定                                            | $R^2$     | $\rho$   |
|-------------------------------------------------|-----------|----------|
| $f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$ | 0.584211  | 0.764337 |
| $f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$ | 0.642828  | 0.801765 |
| $f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$ | -4.153173 | 0.217520 |
| $f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$ | -2.024091 | 0.051963 |

# 局部刻劃模型跨群比較



## 結果總結

- ▶ 各群預測模型
- ▶ 建立可控制的局部範圍
- ▶ 局部刻劃模型

## 結論

- ▶ 分析流程
- ▶ 先分群再建模
- ▶ 設計局部格子點擬合模型
- ▶ 各群的決策行為

# 未來工作

# 附錄

## References I

-  Mia Hubert, Peter J. Rousseeuw, and Karlien Vanden Branden.  
ROBPCA: A New Approach to Robust Principal Component  
Analysis.

*Technometrics*, 47(1):64–79, 2005.

<https://doi.org/10.1198/004017004000000563>.

-  賴立夫.  
使用 KNN 和決策樹方法對填補缺失值的製造數據進行失效  
預測和原因追蹤分析.

2022.

<https://hdl.handle.net/11296/ub6st3>.

# 謝謝聆聽

問題

## 資料介紹 - 離群樣本處理完

