

碩士論文口試

學生 黃丞暘

指導教授 曹振海

國立東華大學應用數學系統計碩士班

2026 年 X 月 XX 日

目錄

緒論

研究資料

方法與流程

結果與討論

背景與動機

背景與動機



力晶電子



台積電



台灣美日先進光罩



旺宏電子



南亞科技



茂德科技



華亞科技




量宏科技



瑞晶電子


圖片來源：鋒霈環境科技股份有限公司

背景與動機



圖片來源：SEMI 國際半導體產業協會

背景與動機



圖片來源：WIKIPIEDA

文獻回顧

文獻回顧

- ▶ 賴立夫 (2022) 提出決策樹 [4]
- ▶ Lundberg & Lee(2017) 提出 SHAP [2]
- ▶ Ribeiro et.al(2016) 提出 LIME [3]

問題與目的

問題與目的

- ▶ 量測變數龐大，能蒐集到的樣本數不足
- ▶ 多個子群結構
- ▶ 隨機擾動生成

【舉例】咖啡廳

資料介紹

資料介紹


▶ 半導體製程資料 SEmi COnductor Manufacturing

idx	Time	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1

- ▶ 共 1567 筆樣本
- ▶ 590 個量測變數
- ▶ -1 代表 Pass，1 代表 Fail


資料來源：UCI SECOM Dataset

資料介紹 - 目標變數



► Pass(-1) 有 1463 筆 (93.36%)，Fail(1) 有 104 筆 (6.64%)

資料介紹 - 離群樣本



► 離群樣本對 PCA 主成分方向與投影結果造成影響 [1]

資料前處理

- (1) 目標變數重新編碼：Pass ($-1 \rightarrow 0$)，移除時間欄位
- (2) 移除缺失值數量超過 1000 筆的單一特徵
- (3) 移除相異值種類低於 10 種的單一特徵
- (4) 採用 KNN imputer 進行補值，設定 $k = 10$
- (5) 移除離群樣本


最終資料

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0

► 最終分析資料為 1525 筆樣本、459 個特徵

方法與流程

流程大綱



分群

- ▶ 存在類別不平衡？

以 SMOTE 補強少數類別於降維空間中的資訊

- ▶ SMOTE → PCA → KMeans 分成兩群

- ▶ 完成分群後移除合成資料，只保留真實資料供後續建模

預測模型

► XGBoost Classifier

► 採用五折交叉驗證，得到每筆樣本輸出機率 $\hat{p}$

群 0			群 1		
樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $	樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $
82	0.498364	0.001636	1158	0.493004	0.006996
225	0.516134	0.016134	990	0.513882	0.013882
44	0.481022	0.018978	1361	0.521811	0.021811
144	0.527558	0.027558	1189	0.473835	0.026165
345	0.470658	0.029342	1187	0.528723	0.028723

局部刻劃方法

- ▶ 在群 c 內，取滿足 $|\hat{p} - 0.5| \leq 0.05$ 的樣本集合，記為 S_n^c
- ▶ 對 S_n^c 內的樣本特徵向量取平均，定義群內中心點為

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$


- ▶ 以中心點為基準生成格子點：

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m}$$

其中


- δ 為各維度相同的位移步長
- $\mathbf{m} = (m_1, \dots, m_p)$ 為位移向量，且
 $m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$
- ▶ 共有 $(2k+1)^p$ 個格子點

局部格子點舉例



- ▶ 以預測模型對格子點輸出的機率作為應變數
- ▶ 本研究： $p = 459$ 、 $k = 2$

建立局部刻劃模型



結果與討論

比較分群後的預測模型

► 預測模型：XGBoost Classifier

群名	樣本數	Pass / Fail	ACC	FAR	ROC-AUC
全體	1525	1430 / 95	0.9272 [0.9141, 0.9397]	0.0189 [0.0120, 0.0264]	0.6623 [0.6054, 0.7178]
群 0	676	619 / 57	0.8846 [0.8595, 0.9083]	0.0468 [0.0308, 0.0639]	0.6983 [0.6308, 0.7631]
群 1	849	811 / 38	0.9482 [0.9329, 0.9623]	0.0099 [0.0037, 0.0172]	0.6224 [0.5228, 0.7171]

► 比較：全體資料之預測結果

研究	前處理方法	預測模型	ACC	FAR
賴利夫 (2022)	KNN、SMOTE	決策樹 (ID3)	85.99%	11.26%
賴利夫 (2022)	KNN、SMOTE	決策樹 (CART)	86.94%	9.22%
本研究	資料前處理	XGBoost Classifier	92.72%	1.89%

決策邊界樣本

群 0			群 1		
樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $	樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $
82	0.498364	0.001636	1158	0.493004	0.006996
225	0.516134	0.016134	990	0.513882	0.013882
44	0.481022	0.018978	1361	0.521811	0.021811
144	0.527558	0.027558	1189	0.473835	0.026165
345	0.470658	0.029342	1187	0.528723	0.028723
298	0.468458	0.031542	458	0.464450	0.035550
484	0.533517	0.033517	1054	0.540420	0.040420
105	0.458454	0.041546			
111	0.457258	0.042742			
247	0.544061	0.044061			
653	0.548375	0.048375			
109	0.548989	0.048989			

局部刻劃模型結果





最終使用特徵數		特徵
群 0	96	x291, x87, x217, x461, x20, ...
群 1	56	x386, x456, x583, x184, x8, ...

群 0		群 1	
$R^2 = 0.5842$		$R^2 = 0.5926$	
95% <i>C.I.</i> $\in [0.583563, 0.584737]$		95% <i>C.I.</i> $\in [0.590905, 0.594560]$	
特徵	估計係數	特徵	估計係數
intercept	1.005144	intercept	0.996643
x291	0.034033	x386	0.016675
x7	-0.029912	x117	-0.012556
x141	-0.028171	x420	-0.011799
x87	0.022993	x456	0.010252
x217	0.022274	x28	-0.009172
x461	0.019723	x36	-0.008981
x20	0.017796	x287	-0.007539
x58	-0.015820	x103	-0.006848
x1	-0.014731	x583	0.005797
x378	0.014099	x184	0.005055

局部刻劃模型跨群比較

比較設定	R^2	ρ
$f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$	0.584211	0.764337
$f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$	0.642828	0.801765
$f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$	-4.153173	0.217520
$f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$	-2.024091	0.051963

局部刻劃模型跨群比較



結果總結

- ▶ 各群預測模型
- ▶ 建立可控制的局部範圍
- ▶ 局部刻劃模型

結論

- ▶ 分析流程
- ▶ 先分群再建模
- ▶ 設計局部格子點擬合模型
- ▶ 各群的決策行為

未來工作

附錄

References I



Mia Hubert, Peter J. Rousseeuw, and Karlien Vanden Branden.
ROBPCA: A New Approach to Robust Principal Component
Analysis.

Technometrics, 47(1):64–79, 2005.

<https://doi.org/10.1198/004017004000000563>.



Scott Lundberg and Su-In Lee.

A Unified Approach to Interpreting Model Predictions.

(arXiv:1705.07874), 2017.

arXiv. <https://doi.org/10.48550/arXiv.1705.07874>.

References II



Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin.

「Why Should I Trust You?」: Explaining the Predictions of Any Classifier.

Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pages 1135–1144, 2016.

<https://doi.org/10.1145/2939672.2939778>.



賴立夫.

使用 KNN 和決策樹方法對填補缺失值的製造數據進行失效預測和原因追蹤分析.

2022.

<https://hdl.handle.net/11296/ub6st3>.

謝謝聆聽

問題

資料介紹 - 離群樣本處理完

