

碩士論文口試

學生 黃丞暘

指導教授 曹振海

國立東華大學應用數學系統計碩士班

2026 年 X 月 XX 日

目錄


介紹

問題

方法與流程

討論


介紹



資料來源：MIC，2021年9月

圖片來源：李淑蓮 北美智權報

半導體




六大製程



圖片來源：SEMI 國際半導體產業協會

晶片良率



圖片來源：WIKIPIEDA

資料


▶ 半導體製程資料 (SEmi COnductor Manufacturing, SECOM)

idx	Time	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1



- ▶ 共 1567 筆樣本
- ▶ 590 個量測變數
- ▶ -1 代表 Pass，1 代表 Fail

資料來源：UCI

資料 - 類別不平衡



資料 - 高缺失率



文獻回顧

- ▶ Salem et al. (2018) — 前處理 + 預測模型、ANOVA
- ▶ 賴立夫 (2022) — KNN 補值、SMOTE、決策樹
- ▶ Park et al. (2024) — 前處理流程
- ▶ Presciuttini et al. (2024) — LIME、可解釋預測模型

目的

- ▶ 建立較佳的預測模型
- ▶ 在該模型上提供對單一預測結果具參考價值的解釋

預測模型結果

► 比較：全體資料之預測結果

研究	ACC	FAR	ROC-AUC
賴立夫 (2022)	85.99%	11.26%	
賴立夫 (2022)	86.94%	9.22%	
Salem et al. (2018)		24.95%	70.22%
Park et al. (2024)	85.14%		
Presciuttini et al. (2024)			
本研究 (分群前)	92.72%	1.89%	66.23%

比較分群後的預測模型

群名	樣本數	Pass / Fail	ACC	FAR	ROC-AUC
全體（分群前）	1525	1430 / 95	0.9272 [0.9141, 0.9397]	0.0189 [0.0120, 0.0264]	0.6623 [0.6054, 0.7178]
群 0	676	619 / 57	0.8846 [0.8595, 0.9083]	0.0468 [0.0308, 0.0639]	0.6983 [0.6308, 0.7631]
群 1	849	811 / 38	0.9482 [0.9329, 0.9623]	0.0099 [0.0037, 0.0172]	0.6224 [0.5228, 0.7171]

局部刻劃模型結果

最終使用特徵數		特徵
群 0	96	x291, x87, x217, x461, x20, ...
群 1	56	x386, x456, x583, x184, x8, ...

群 0		群 1	
$R^2 = 0.5842$		$R^2 = 0.5926$	
95% C.I. $\in [0.583563, 0.584737]$		95% C.I. $\in [0.590905, 0.594560]$	
特徵	估計係數	特徵	估計係數
intercept	1.005144	intercept	0.996643
x291	0.034033	x386	0.016675
x7	-0.029912	x117	-0.012556
x141	-0.028171	x420	-0.011799
x87	0.022993	x456	0.010252
x217	0.022274	x28	-0.009172
x461	0.019723	x36	-0.008981
x20	0.017796	x287	-0.007539
x58	-0.015820	x103	-0.006848
x1	-0.014731	x583	0.005797
x378	0.014099	x184	0.005055


問題

問題

- ▶ 如何建立好的預測模型
 - 量測變數龐大，能蒐集到的樣本數不足
 - 多個子群結構
- ▶ 如何讓局部刻劃更可靠
 - 隨機擾動生成

【舉例】咖啡廳


方法與流程



資料前處理

- (1) 目標變數重新編碼：Pass ($-1 \rightarrow 0$)，移除時間欄位
- (2) 移除缺失值數量超過 1000 筆的單一特徵
- (3) 移除相異值種類低於 10 種的單一特徵
- (4) 採用 KNN imputer 進行補值，設定 $k = 10$
- (5) 移除離群樣本

資料 - 離群樣本



► 離群樣本對 PCA 主成分方向與投影結果造成影響 [1]

最終資料

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0

► 最終分析資料為 1525 筆樣本、459 個特徵

分群

- ▶ 存在類別不平衡？

以 SMOTE 補強少數類別於降維空間中的資訊

- ▶ SMOTE → PCA → KMeans 分成兩群

- ▶ 完成分群後移除合成資料，只保留真實資料供後續建模

預測模型

► XGBoost Classifier

► 採用五折交叉驗證，得到每筆樣本輸出機率 $\hat{p}$

群 0				群 1			
樣本編號	$\hat{p}$	真實類別	預測類別	樣本編號	$\hat{p}$	真實類別	預測類別
82	0.498364	Pass	Pass	1158	0.493004	Pass	Pass
225	0.516134	Pass	Fail	990	0.513882	Pass	Fail
44	0.481022	Pass	Pass	1361	0.521811	Fail	Fail
144	0.527558	Pass	Fail	1189	0.473835	Fail	Pass
345	0.470658	Pass	Pass	1187	0.528723	Pass	Fail

局部刻劃方法

- ▶ 在群 c 內，取滿足 $|\hat{p} - 0.5| \leq 0.05$ 的樣本集合，記為 S_n^c
- ▶ 對 S_n^c 內的樣本特徵向量取平均，定義群內中心點為

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$


- ▶ 以中心點為基準生成格子點：

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m}$$

其中


- δ 為各維度相同的位移步長
- $\mathbf{m} = (m_1, \dots, m_p)$ 為位移向量，且
 $m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$
- ▶ 共有 $(2k+1)^p$ 個格子點

局部格子點舉例



- ▶ 以預測模型對格子點輸出的機率作為應變數
- ▶ 本研究： $p = 459$ 、 $k = 2$

建立局部刻劃模型



討論





決策邊界樣本

群 0			群 1		
樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $	樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $
82	0.498364	0.001636	1158	0.493004	0.006996
225	0.516134	0.016134	990	0.513882	0.013882
44	0.481022	0.018978	1361	0.521811	0.021811
144	0.527558	0.027558	1189	0.473835	0.026165
345	0.470658	0.029342	1187	0.528723	0.028723
298	0.468458	0.031542	458	0.464450	0.035550
484	0.533517	0.033517	1054	0.540420	0.040420
105	0.458454	0.041546			
111	0.457258	0.042742			
247	0.544061	0.044061			
653	0.548375	0.048375			
109	0.548989	0.048989			

局部刻劃模型跨群比較

比較設定	R^2	ρ
$f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$	0.584211	0.764337
$f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$	0.642828	0.801765
$f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$	-4.153173	0.217520
$f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$	-2.024091	0.051963

局部刻劃模型跨群比較



結果總結

- ▶ 各群預測模型
- ▶ 建立可控制的局部範圍
- ▶ 局部刻劃模型

結論

- ▶ 分析流程
- ▶ 先分群再建模
- ▶ 設計局部格子點擬合模型
- ▶ 各群的決策行為

未來工作

附錄

References I



Mia Hubert, Peter J. Rousseeuw, and Karlien Vanden Branden.
ROBPCA: A New Approach to Robust Principal Component
Analysis.

Technometrics, 47(1):64–79, 2005.

<https://doi.org/10.1198/004017004000000563>.

謝謝聆聽

問題

資料介紹 - 離群樣本處理完

