

碩士論文口試

學生 黃丞暘

指導教授 曹振海

國立東華大學應用數學系統計碩士班

2026 年 X 月 XX 日

目錄


介紹

目的


方法流程與結果討論

結論


介紹



半導體




六大製程



圖片來源：SEMI 國際半導體產業協會

晶片良率



圖片來源：Wikipedia

資料

▶ 半導體製程資料 (SEmi COnductor Manufacturing, SECOM)

idx	Time	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1

▶ 樣本數：1567



▶ 製程量測變數：590

▶ 目標變數

- -1 代表 Pass：1463
- 1 代表 Fail：104

資料來源：UCI

資料 - 高缺失率



文獻回顧

研究	補值	特徵篩選	預測模型	解釋方法
Salem et al. (2018)	In-Painting KNN	Univariate	LR	ANOVA
賴立夫 (2022)	KNN	RF	CART	決策樹
Park et al. (2024)	Mean	PCA	SVM	—
Presciuttini et al. (2024)	Median	Boruta	XGBoost	LIME
Naudé et al. (2024)	KNN	ANOVA	SVM	SHAP

目的

目的

1. 提升預測模型的表現
2. 提供具解釋性的局部刻劃模型

結果 I - 比較文獻預測模型

研究／預測模型	ACC	FAR	AUC
Salem et al. (2018)	74.41%	24.95%	70.22%
賴立夫 (2022)	86.94%	9.22%	—
Park et al. (2024)	85.14%	6.59%	—
Presciuttini et al. (2024)	89.49%	4.14%	75%
Naudé et al. (2024)	—	—	62.33%
本研究 (分群前)	92.72%	1.89%	66.36%
本研究 (分群後) 群 0	88.47%	4.68%	69.74%
本研究 (分群後) 群 1	94.82%	0.99%	62.66%


- ▶ ACC: Accuracy(準確度)
- ▶ FAR: False Alarm Rate(誤報率)
- ▶ AUC: Area under ROC curve(鑑別度)

結果 II - 局部刻劃模型

群 0		群 1	
$R^2 = 0.58$		$R^2 = 0.59$	
特徵	估計係數	特徵	估計係數
intercept	1.0051	intercept	0.9966
x291	0.0340	x386	0.0167
x7	-0.0299	x117	-0.0126
x141	-0.0282	x420	-0.0118
x87	0.0230	x456	0.0106
x217	0.0223	x28	-0.0092
x461	0.0197	x36	-0.0090
x20	0.0178	x287	-0.0075
x58	-0.0158	x103	-0.0068
x1	-0.0147	x583	0.0058
x378	0.0141	x184	0.0051

方法流程與結果討論


方法流程與結果討論



資料前處理

- (1) 目標變數重新編碼：Pass ($-1 \rightarrow 0$)，移除時間欄位
- (2) 移除缺失值數量超過 1000 筆的單一特徵
- (3) 移除相異值種類低於 10 種的單一特徵
- (4) 採用 KNN 補缺失值
- (5) 採用 PCA 移除離群樣本

資料 - 離群樣本



最終資料

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0

► 最終分析資料為 1525 筆樣本、459 個特徵

分群

- ▶ SECOM 資料具有類別不平衡與高維度特性
 - 1. SMOTE 補強少數類別資訊
 - 2. PCA 將五百多個變數濃縮為主成分，
 - 3. KMeans 分成兩群
- ▶ 分群完成後移除合成資料，只保留真實資料供後續建模

訓練預測模型結果

- ▶ XGBoost Classifier
- ▶ 五折交叉驗證：80% 訓練集、20% 測試集
(每次訓練集會用 SMOTE)

	Pass	Fail	ACC	FAR	ROC-AUC
全體	1463	104	92.72%	1.89%	66.36%
群 0	619	57	88.47%	4.68%	69.74%
群 1	811	38	94.82%	0.99%	62.66%

預測模型輸出機率

- 每一折測試集可得到每筆樣本輸出機率 $\hat{p}$

表 1: 以群 0 為例

idx	x1	...	x590	真實類別	$\hat{p}$	預測類別
1	0.216411	...	0.201450	Pass	0.005049	Pass
2	1.094037	...	1.167895	Pass	0.080591	Pass
3	-1.114171	...	-0.171694	Fail	0.765585	Fail
4	-0.354825	...	-0.268061	Pass	0.193338	Pass
5	0.234139	...	-0.268061	Pass	0.011200	Pass

決策邊界樣本

群 0			群 1		
樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $	樣本編號	$\hat{p}$	$ \hat{p} - 0.5 $
82	0.4984	0.0016	1158	0.4930	0.0070
225	0.5161	0.0161	990	0.5139	0.0139
44	0.4810	0.0190	1361	0.5218	0.0218
144	0.5276	0.0276	1189	0.4738	0.0262
345	0.4707	0.0293	1187	0.5287	0.0287
298	0.4685	0.0315	458	0.4645	0.0355
484	0.5335	0.0335	1054	0.5404	0.0404
105	0.4585	0.0415			
111	0.4573	0.0427			
247	0.5441	0.0441			
653	0.5484	0.0484			
109	0.5490	0.0490			

局部刻劃方法

- ▶ 在群 c 內，取滿足 $|\hat{p} - 0.5| \leq 0.05$ 的樣本集合，記為 S_n^c
- ▶ 對 S_n^c 內的樣本特徵向量取平均，定義群內中心點為

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$


- ▶ 以中心點為基準生成格子點：

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m}$$

其中


- δ 為各維度相同的位移步長
- $\mathbf{m} = (m_1, \dots, m_p)$ 為位移向量，且
 $m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$
- ▶ 共有 $(2k+1)^p$ 個格子點

局部格子點舉例



- ▶ 以預測模型對格子點輸出的機率作為應變數
- ▶ 本研究： $p = 459$ 、 $k = 2$

擬和局部刻劃模型流程







局部刻劃模型

群 0		群 1	
$R^2 = 0.58$		$R^2 = 0.59$	
特徵 (97 個)	估計係數	特徵 (56 個)	估計係數
intercept	1.0051	intercept	0.9966
x291	0.0340	x386	0.01668
x7	-0.0299	x117	-0.0126
x141	-0.0282	x420	-0.0118
x87	0.0230	x456	0.0106
x217	0.0223	x28	-0.0092
x461	0.0197	x36	-0.0090
x20	0.0178	x287	-0.0075
x58	-0.0158	x103	-0.0068
x1	-0.0147	x583	0.0058
x378	0.0141	x184	0.0051

局部刻劃模型跨群比較

比較設定	R^2	ρ
$f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$	0.58	0.76
$f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$	0.64	0.80
$f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$	-4.15	0.22
$f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$	-2.02	0.05

局部刻劃模型跨群比較



結論

結論

- ▶ 分析流程
- ▶ 先分群再建模
- ▶ 設計局部格子點擬合模型
- ▶ 局部的決策行為

未來工作


謝謝聆聽

問題

附錄

References I

資料介紹 - 離群樣本處理完



XGBoost 參數設定

項目	設定內容
程式版本	Python 3.12.7
預測模型	XGBClassifier
隨機種子	42
n_estimators	300
max_depth	3
learning_rate	0.1
subsample	0.8
colsample_bytree	0.8
min_child_weight	10
gamma	1.0
reg_lambda	2.0
reg_alpha	0.5
objective	binary:logistic
eval_metric	logloss