

碩士論文口試

學生 黃丞暘

指導教授 曹振海

國立東華大學應用數學系統計碩士班

2026 年 X 月 XX 日

目錄

緒論

研究資料

方法與流程

結果與討論

背景與動機

背景與動機



力晶電子



台積電



台灣美日先進光罩



旺宏電子



南亞科技



茂德科技



華亞科技




量宏科技



瑞晶電子

圖片來源：鋒霈環境科技股份有限公司

背景與動機



圖片來源：SEMI 國際半導體產業協會

文獻回顧

文獻回顧

- ▶ 賴立夫 (2022) 提出決策樹。[4]
- ▶ Lundberg & Lee(2017) 提出 SHAP 。[2]
- ▶ Ribeiro et.al(2016) 提出 LIME 。[3]

問題與目的

問題與目的

- ▶ 若整體資料存在多個子群，單一模型的局部解釋可能混合不同規則。
 - 先分群，再建立黑箱模型
- ▶ 若以隨機擾動生成鄰近點，可能偏離真實資料分布，產生外插風險。
 - 設計局部格子點的生成方法
- ▶ 建立可檢視的局部刻劃模型，以作為黑箱模型在分類行為上的可解釋依據。

資料介紹

資料介紹


▶ 半導體製程資料 SEmi COnductor Manufacturing

idx	Time	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1


- ▶ 共 1567 筆樣本
- ▶ 590 個量測變數
- ▶ 1 個二元品質類別，其中 Pass(-1) 有 1463 筆 (93.36%)，Fail(1) 有 104 筆 (6.64%)

資料來源：UCI SECOM Dataset


資料 EDA - 目標變數



資料 EDA - 單一特徵的缺失值




資料 EDA - 單一特徵的相異值




資料 EDA - 極端點

- 離群樣本對 PCA 主成分方向與投影結果造成影響 [1]



資料前處理

- (1) 目標變數重新編碼：Pass ($-1 \rightarrow 0$)，移除時間欄位
- (2) 移除缺失值數量超過 1000 筆的單一特徵
- (3) 移除相異值種類低於 10 種的單一特徵
- (4) 採用 KNN imputer 進行補值，設定 $k = 10$
- (5) 移除極端點




最終分析資料

► 最終分析資料為 1525 筆樣本、459 個特徵

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0

方法與流程


流程大綱




分群設計：SMOTE $\rightarrow$ PCA $\rightarrow$ KMeans

- ▶ 以 SMOTE 補強少數類別於降維空間中的資訊。
- ▶ 於 PCA 空間以 k-means 進行分群。
- ▶ 以 elbow method 選定群數 $k = 2$ 。

前



後



- ▶ 完成分群後移除合成樣本，只保留真實資料供後續建模

黑箱模型

- ▶ Skicit-learn: XGBClassifier
- ▶ 評估方式：五折交叉驗證
- ▶ 僅在訓練集執行 SMOTE，每一折當測試集輸出機率值
- ▶ 用 Accuracy(ACC)、False Alarm Rate(FAR)、 $ROC - AUC$ 評估群間是否有差異

局部刻劃方法

- ▶ 在群 c 內，取滿足 $|\hat{p} - 0.5| \leq 0.05$ 的樣本集合，記為 S_n^c
- ▶ 對 S_n^c 內的樣本特徵向量取平均，定義群內中心點為

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$


- ▶ 以中心點為基準生成格子點：

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m}$$

其中


- δ 為各維度相同的位移步長
 - $\mathbf{m} = (m_1, \dots, m_p)$ 為位移向量，且
 $m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$
- ▶ 共有 $(2k+1)^p$ 個格子點

局部格子點舉例



- ▶ 以黑箱模型對格子點的輸出機率作為應變數
- ▶ 本研究： $p = 459$ 、 $k = 2$

建立局部刻劃模型




結果與討論

分群黑箱模型

群名	樣本數	Pass / Fail	<i>ACC</i>	<i>FAR</i>	<i>ROC - AUC</i>
全體	1525	1430 / 95	0.9272 [0.9141, 0.9397]	0.0189 [0.0120, 0.0264]	0.6623 [0.6054, 0.7178]
群 0	676	619 / 57	0.8846 [0.8595, 0.9083]	0.0468 [0.0308, 0.0639]	0.6983 [0.6308, 0.7631]
群 1	849	811 / 38	0.9482 [0.9329, 0.9623]	0.0099 [0.0037, 0.0172]	0.6224 [0.5228, 0.7171]

決策邊界樣本與中心點建立



► 形成中心點的樣本：群 0 取 12 個、群 1 取 7 個。

局部刻劃模型結果





最終使用特徵數		特徵
群 0	96	x291, x87, x217, x461, x20, ...
群 1	56	x386, x456, x583, x184, x8, ...

群 0		群 1	
$R^2 = 0.5842$		$R^2 = 0.5926$	
95% <i>C.I.</i> $\in [0.583563, 0.584737]$		95% <i>C.I.</i> $\in [0.590905, 0.594560]$	
特徵	估計係數	特徵	估計係數
intercept	1.005144	intercept	0.996643
x291	0.034033	x386	0.016675
x7	-0.029912	x117	-0.012556
x141	-0.028171	x420	-0.011799
x87	0.022993	x456	0.010252
x217	0.022274	x28	-0.009172
x461	0.019723	x36	-0.008981
x20	0.017796	x287	-0.007539
x58	-0.015820	x103	-0.006848
x1	-0.014731	x583	0.005797
x378	0.014099	x184	0.005055

局部線性模型跨群比較

比較設定	R^2	ρ
$f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$	0.584211	0.764337
$f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$	0.642828	0.801765
$f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$	-4.153173	0.217520
$f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$	-2.024091	0.051963

局部線性模型跨群比較



結果總結

- ▶ 分群後，各群黑箱模型呈現不同的錯誤型態與可分類程度。
- ▶ 以決策邊界附近樣本建立中心點，可聚焦於模型判斷最不明確的局部區域。
- ▶ 結構化格子點可在可控制的鄰域內近似黑箱輸出，避免隨機擾動造成的外插偏誤。
- ▶ 群內局部刻劃模型可將黑箱決策轉為具體的局部重要特徵與方向性資訊。

結論

- ▶ 本研究提出一套適用於高維、缺失嚴重且類別不平衡製程資料的分析流程。
- ▶ 透過先分群再於群內建模，可降低異質性對黑箱學習與局部解釋的干擾。
- ▶ 透過中心點與格子點設計，可在較低外插風險下建立局部線性刻劃模型。
- ▶ 研究結果顯示，不同子群對應不同的黑箱局部決策結構，分群式局部刻劃具分析價值。

未來工作

附錄

References I



Mia Hubert, Peter J. Rousseeuw, and Karlien Vanden Branden.
ROBPCA: A New Approach to Robust Principal Component
Analysis.

Technometrics, 47(1):64–79, 2005.

<https://doi.org/10.1198/004017004000000563>.



Scott Lundberg and Su-In Lee.

A Unified Approach to Interpreting Model Predictions.

(arXiv:1705.07874), 2017.

arXiv. <https://doi.org/10.48550/arXiv.1705.07874>.

References II



Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin.

「Why Should I Trust You?」: Explaining the Predictions of Any Classifier.

Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pages 1135–1144, 2016.

<https://doi.org/10.1145/2939672.2939778>.



賴立夫.

使用 KNN 和決策樹方法對填補缺失值的製造數據進行失效預測和原因追蹤分析.

2022.

<https://hdl.handle.net/11296/ub6st3>.

謝謝聆聽

問題