

# 碩士論文口試

學生 黃丞暘

指導教授 曹振海

國立東華大學應用數學系統計碩士班

2026 年 X 月 XX 日

# 目錄

緒論

研究資料

方法與流程

結果與討論

# 背景與動機

## 背景與動機



力晶電子



台積電



台灣美日先進光罩



旺宏電子



南亞科技



茂德科技



華亞科技




量宏科技



瑞晶電子




圖片來源：鋒霈環境科技股份有限公司

## 背景與動機



圖片來源：SEMI 國際半導體產業協會

## 背景與動機



圖片來源：WIKIPIEDA

# 文獻回顧

## 文獻回顧

- ▶ 賴立夫 (2022) 提出決策樹。[4]
- ▶ Lundberg & Lee(2017) 提出 SHAP 。[2]
- ▶ Ribeiro et.al(2016) 提出 LIME 。[3]

# 問題與目的

## 問題與目的

- ▶ 量測變數龐大，樣本數不足
- ▶ 多個子群結構      【舉例】咖啡廳
- ▶ 隨機擾動生成

# 資料介紹

## 資料介紹


### ▶ 半導體製程資料 SEmi COnductor Manufacturing

| idx | Time                | x1        | x2        | x3        | ... | x588   | x589   | x590     | Pass/Fail |
|-----|---------------------|-----------|-----------|-----------|-----|--------|--------|----------|-----------|
| 1   | 2008-07-19 11:55:00 | 3030.9300 | 2564.0000 | 2187.7333 | ... | NaN    | NaN    | NaN      | -1        |
| 2   | 2008-07-19 12:32:00 | 3095.7800 | 2465.1400 | 2230.4222 | ... | 0.0201 | 0.0060 | 208.2045 | -1        |
| 3   | 2008-07-19 13:17:00 | 2932.6100 | 2559.9400 | 2186.4111 | ... | 0.0484 | 0.0148 | 82.8602  | 1         |
| 4   | 2008-07-19 14:43:00 | 2988.7200 | 2479.9000 | 2199.0333 | ... | 0.0149 | 0.0044 | 73.8432  | -1        |
| 5   | 2008-07-19 15:22:00 | 3032.2400 | 2502.8700 | 2233.3667 | ... | 0.0149 | 0.0044 | 73.8432  | -1        |

- ▶ 共 1567 筆樣本
- ▶ 590 個量測變數
- ▶ 1 個二元品質類別，其中 Pass(-1) 有 1463 筆 (93.36%)，Fail(1) 有 104 筆 (6.64%)


資料來源：UCI SECOM Dataset

## 資料介紹 - 目標變數



## 資料介紹 - 極端點

- 離群樣本對 PCA 主成分方向與投影結果造成影響 [1]




## 資料介紹

- (1) 目標變數重新編碼：Pass ( $-1 \rightarrow 0$ )，移除時間欄位
  - (2) 移除缺失值數量超過 1000 筆的單一特徵
  - (3) 移除相異值種類低於 10 種的單一特徵
  - (4) 採用 KNN imputer 進行補值，設定  $k = 10$
  - (5) 移除極端點
- 最終分析資料為 1525 筆樣本、459 個特徵

| idx | x1        | x2        | x3        | ... | x588      | x589      | x590      | Pass/Fail |
|-----|-----------|-----------|-----------|-----|-----------|-----------|-----------|-----------|
| 1   | 0.216411  | 0.856549  | -0.434551 | ... | -0.140893 | -0.050083 | 0.201450  | 0         |
| 2   | 1.094037  | -0.374751 | 1.020782  | ... | 0.421933  | 0.258167  | 1.167895  | 0         |
| 3   | -1.114171 | 0.805982  | -0.479627 | ... | 3.631596  | 3.316370  | -0.171694 | 1         |
| 4   | -0.354825 | -0.190915 | -0.049316 | ... | -0.167828 | -0.297870 | -0.268061 | 0         |
| 5   | 0.234139  | 0.095176  | 1.121165  | ... | -0.167828 | -0.297870 | -0.268061 | 0         |

# 方法與流程

## 流程大綱



## 分群設計：SMOTE $\rightarrow$ PCA $\rightarrow$ KMeans

- ▶ 存在類別不平衡？

以 SMOTE 補強少數類別於降維空間中的資訊

- ▶ 完成分群後移除合成樣本，只保留真實資料供後續建模

## 局部刻劃方法

- ▶ 在群  $c$  內，取滿足  $|\hat{p} - 0.5| \leq 0.05$  的樣本集合，記為  $S_n^c$
- ▶ 對  $S_n^c$  內的樣本特徵向量取平均，定義群內中心點為

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$


- ▶ 以中心點為基準生成格子點：

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m}$$

其中


- $\delta$  為各維度相同的位移步長
- $\mathbf{m} = (m_1, \dots, m_p)$  為位移向量，且  
 $m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$
- ▶ 共有  $(2k+1)^p$  個格子點

## 局部格子點舉例



- ▶ 以分類模型對格子點的輸出機率作為應變數
- ▶ 本研究：  $p = 459$ 、 $k = 2$

## 建立局部刻劃模型




# 結果與討論

## 比較分群後的分類模型

- ▶ 分類模型：XGBoost Classifier
- ▶ 評估方式：重抽，計算點估計、建立 95% 信賴區間

| 群名  | 樣本數  | Pass / Fail | <i>ACC</i>                 | <i>FAR</i>                 | <i>ROC - AUC</i>           |
|-----|------|-------------|----------------------------|----------------------------|----------------------------|
| 全體  | 1525 | 1430 / 95   | 0.9272<br>[0.9141, 0.9397] | 0.0189<br>[0.0120, 0.0264] | 0.6623<br>[0.6054, 0.7178] |
| 群 0 | 676  | 619 / 57    | 0.8846<br>[0.8595, 0.9083] | 0.0468<br>[0.0308, 0.0639] | 0.6983<br>[0.6308, 0.7631] |
| 群 1 | 849  | 811 / 38    | 0.9482<br>[0.9329, 0.9623] | 0.0099<br>[0.0037, 0.0172] | 0.6224<br>[0.5228, 0.7171] |

## 決策邊界樣本與中心點建立



► 形成中心點的樣本：群 0 取 12 個、群 1 取 7 個。

## 局部刻劃模型結果





| 最終使用特徵數 |    | 特徵                              |
|---------|----|---------------------------------|
| 群 0     | 96 | x291, x87, x217, x461, x20, ... |
| 群 1     | 56 | x386, x456, x583, x184, x8, ... |

| 群 0                                        |           | 群 1                                        |           |
|--------------------------------------------|-----------|--------------------------------------------|-----------|
| $R^2 = 0.5842$                             |           | $R^2 = 0.5926$                             |           |
| 95% <i>C.I.</i> $\in [0.583563, 0.584737]$ |           | 95% <i>C.I.</i> $\in [0.590905, 0.594560]$ |           |
| 特徵                                         | 估計係數      | 特徵                                         | 估計係數      |
| intercept                                  | 1.005144  | intercept                                  | 0.996643  |
| x291                                       | 0.034033  | x386                                       | 0.016675  |
| x7                                         | -0.029912 | x117                                       | -0.012556 |
| x141                                       | -0.028171 | x420                                       | -0.011799 |
| x87                                        | 0.022993  | x456                                       | 0.010252  |
| x217                                       | 0.022274  | x28                                        | -0.009172 |
| x461                                       | 0.019723  | x36                                        | -0.008981 |
| x20                                        | 0.017796  | x287                                       | -0.007539 |
| x58                                        | -0.015820 | x103                                       | -0.006848 |
| x1                                         | -0.014731 | x583                                       | 0.005797  |
| x378                                       | 0.014099  | x184                                       | 0.005055  |

## 局部線性模型跨群比較

| 比較設定                                            | $R^2$     | $\rho$   |
|-------------------------------------------------|-----------|----------|
| $f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$ | 0.584211  | 0.764337 |
| $f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$ | 0.642828  | 0.801765 |
| $f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$ | -4.153173 | 0.217520 |
| $f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$ | -2.024091 | 0.051963 |

# 局部線性模型跨群比較



## 結果總結

- ▶ 分群後，各群分類模型呈現不同的錯誤型態與可分類程度。
- ▶ 以決策邊界附近樣本建立中心點，可聚焦於模型判斷最不明確的局部區域。
- ▶ 結構化格子點可在可控制的鄰域內近似模型輸出，避免隨機擾動造成的外插偏誤。
- ▶ 群內局部刻劃模型可將模型的決策轉為具體的局部重要特徵與方向性資訊。

## 結論

- ▶ 本研究提出一套適用於高維、缺失嚴重且類別不平衡製程資料的分析流程。
- ▶ 透過先分群再於群內建模，可降低異質性對模型學習與局部解釋的干擾。
- ▶ 透過中心點與格子點設計，可在較低外插風險下建立局部線性刻劃模型。
- ▶ 研究結果顯示，不同子群對應不同的分類模型之局部決策結構，分群式局部刻劃具分析價值。

# 未來工作

# 附錄

## References I



Mia Hubert, Peter J. Rousseeuw, and Karlien Vanden Branden.  
ROBPCA: A New Approach to Robust Principal Component  
Analysis.

*Technometrics*, 47(1):64–79, 2005.

<https://doi.org/10.1198/004017004000000563>.



Scott Lundberg and Su-In Lee.

A Unified Approach to Interpreting Model Predictions.

(arXiv:1705.07874), 2017.

arXiv. <https://doi.org/10.48550/arXiv.1705.07874>.

## References II



Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin.

「Why Should I Trust You?」: Explaining the Predictions of Any Classifier.

*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, 2016.

<https://doi.org/10.1145/2939672.2939778>.



賴立夫.

使用 KNN 和決策樹方法對填補缺失值的製造數據進行失效預測和原因追蹤分析.

2022.

<https://hdl.handle.net/11296/ub6st3>.

# 謝謝聆聽

問題