

國立東華大學 應用數學系

統計碩士班

碩士論文

指導教授：曹振海 博士

中文論文標題

English Title



研究生：黃丞暘 撰

中華民國 115 年 X 月



這頁放審定書





這頁放原創性聲明書





致謝

這頁寫致謝內容



國立東華大學應用數學系統計碩士班 黃丞暘 謹致
民國 115 年 X 月



摘要

這頁寫中文摘要



關鍵字：關鍵字 1、關鍵字 2、關鍵字 3



Abstract

這頁寫英文摘要



Keywords: keyword 1, keyword 2, keyword 3



Contents

1	緒論	1
1.1	研究背景與動機	1
1.2	研究問題與既有方法限制	1
1.3	研究目的與方法概述	1
1.4	研究貢獻	1
1.5	章節介紹	1
2	研究資料	2
2.1	資料背景	2
2.2	資料前處理	2
2.2.1	目標變數與資料切分單位	3
2.2.2	缺失值與特徵保留	3
2.2.3	重複特徵	3
2.2.4	補值	3
2.2.5	極端值處理	3
2.2.6	類別不平衡	3
3	研究方法	5
3.1	流程與問題設定	5
3.2	資料處理與分群標記建立流程	6
3.3	降維	7
3.3.1	主成分分析 (Principal Component Analysis)	7
3.4	分群	7
3.4.1	k-平均演算法 (k-means)	7
3.5	重抽樣	8

3.5.1	合成少數過度取樣技術 (Synthesized Minority Over-sampling Technique)	8
3.6	黑箱模型	8
3.6.1	極限梯度提升 (Extreme Gradient Boosting)	8
3.7	局部擾動 (Lattice cube)	9
3.8	局部模型 (Local surrogate)	10
3.9	實驗設計與交叉驗證	11
3.10	評估指標	11
3.10.1	黑箱分類效能	11
3.10.2	局部代理擬合品質	11
4	研究結果	12
4.1	分群結果	13
4.2	黑箱預測	13
4.3	關鍵案例分析	13
4.4	討論與限制	13
5	結論	14
5.1	總結	14
5.2	未來工作	14





Chapter 1

緒論

- 1.1 研究背景與動機
- 1.2 研究問題與既有方法限制
- 1.3 研究目的與方法概述
- 1.4 研究貢獻
- 1.5 章節介紹

第二章介紹研究資料與前處理；第三章說明研究方法，包含分群、黑箱模型、局部擾動與局部代理模型；第四章呈現實驗結果與案例分析；第五章總結研究結論與未來工作方向。

Chapter 2

研究資料

2.1 資料背景

本研究使用半導體製程量測資料—SECOM 作為分析對象，源自 (McCann, M., et al, 2010)。資料以單一樣本為單位，共 1567 筆；每筆樣本包含一個時間欄位 (Time, 範圍自 2008-01-08 02:02:00 至 2008-12-10 18:47:00)、590 個已匿名化的量測變項 (以 x_1 至 x_{590} 表示)，以及一個品質結果欄位 (二元變數, Pass/Fail) 作為目標變數，其中 Fail (-1) 共 1463 筆 (93.36%)，Pass (1) 共 104 筆 (6.64%)，存在明顯的類別不平衡。且存在缺失值問題，整體缺失率為 4.54%，但缺失分佈不均，部分特徵缺失筆數極高，單一特徵最高缺失達 1429 筆 (91.19%)，且有 20 個特徵之缺失筆數超過 1000 筆 (占樣本數 63.82% 以上)。本研究的目的是：在高維、缺失嚴重且類別不平衡的情境下，先以分群切分資料結構，再以黑箱分類模型學習品質結果，並在群內建立局部 linear surrogate 以描述可解釋的分析 (後續章節說明)。

2.2 資料前處理

本節說明資料清理與特徵處理流程。

2.2.1 目標變數與資料切分單位

為方便辨識將目標欄位 Pass (1)、Fail (-1)，轉為 Pass (1)、Fail (0)。時間欄位 Time 不作為模型特徵，於建模前移除。

2.2.2 缺失值與特徵保留

製程量測資料常見大量缺失，本研究資料亦不例外。為避免高度缺失的特徵在直接補值後造成誤差，本研究以「單一特徵的缺失筆數」作為篩選指標，先移除缺失筆數高於門檻的特徵；同時，亦發現特徵中出現近乎常數或取值種類極少的欄位，對分類模型貢獻有限，以「特徵的不同數值」作為篩選指標，移除特徵數值種類低於門檻的特徵。

2.2.3 重複特徵

為避免模型被冗餘特徵影響，本研究以欄位（特徵）完全相同作為判準並移除，只保留首次出現者。

2.2.4 補值

保留上述處理在門檻內的特徵後，再進行補值。此處採用 KNN 補值 (KNNImputer)，以鄰近樣本的距離加權估計缺失值，使補值結果可反映整體資料結構，具有足夠變異的特徵供後續建模。

2.2.5 極端值處理

資料為高維且單位不一致，若以原始空間判別離群點並不穩定；因此先以 PCA 投影至二維平面觀察整體樣貌，並在 PCA 平面上以明確門檻規則移除極端點。移除後重新編號樣本索引，以確保後續分群與交叉驗證索引一致。

2.2.6 類別不平衡

前面有提到資料存在類別不平衡的問題，Fail (-1) 共 1463 筆，佔整體的 93.36%，Pass (1) 共 104 筆，佔整體的 6.64%，為避免模型分類偏向

多數類別，於訓練折內採用重抽樣策略（如 SMOTE）及其放置位置（僅限訓練資料內），以避免資料洩漏。



Chapter 3

研究方法

本章節將說明本研究之方法流程，包含分群、黑箱分類模型、局部資料生成、局部代理模型建構，同時提供實驗環境與評估指標以確保結果具可重現性與可比較性。

3.1 流程與問題設定

本研究以高維製程量測特徵 $X \in \mathbb{R}^{N \times p}$ 與二元品質標記 $y \in \{0, 1\}^N$ 為基礎，目標為同時達成（1）品質預測（2）局部可解釋性分析。整體流程如下：

1. 資料前處理後取得特徵矩陣 X 與標記 y 。
2. 對 X 進行分群，得到群標記 $c \in \{0, 1, \dots, C-1\}^N$ 。
3. 於各群 c 內訓練黑箱分類器 $f_c(\cdot)$ ，輸出機率 $\hat{p}_c(x) = P(y = 1 \mid x, c)$ 。
4. 於各群內挑選 $\hat{p}_c(x) \approx 0.5$ 的代表點集合，定義局部中心點 x_0 。
5. 以 lattice cube 於 x_0 周圍生成局部設計點，並以黑箱輸出作為標記建立局部代理模型 $g(\cdot)$ 。
6. 以分類效能與局部擬合指標彙整結果，並進行關鍵案例分析。

3.2 資料處理與分群標記建立流程

本研究將原始資料記為 D_1 。由於資料呈現高維度、缺失嚴重且類別不平衡等特性，若直接以距離為基礎進行分群，群中心容易受到少數極端點與多數類別主導，造成分群結構不穩定，且少數類別在分群目標中被弱化。

為提升分群的穩定性並使少數類別在分群過程中具有足夠影響，本研究採以下流程建立最終分群標記，並將分群結果回填至真實樣本資料以供後續建模使用：

1. **初步降維與分群 (D_1)**：對 D_1 進行 PCA 投影至二維平面，並於該平面以 k-means 進行初步分群，用於檢視資料幾何結構與辨識極端樣本。
2. **極端樣本剔除 (得到 D_2)**：於 PCA 二維平面中，依主成分座標之門檻規則辨識遠離主要資料雲之樣本並予以剔除，得到去除極端樣本後的資料 D_2 。此步驟目的在於避免少數遠離點拉動 k-means 群中心位置，影響後續分群結構。
3. **以 SMOTE 調整類別權重 (得到 D_3)**：由於 D_2 之目標類別分佈高度不平衡，若直接以 k-means 最小化群內平方誤差，分群結果傾向由多數類別主導。因此本研究於 D_2 上使用 SMOTE 產生少數類別的合成樣本，得到類別較為平衡之資料 D_3 。需注意，SMOTE 僅用於調整分群時的樣本分佈（等價於調整類別在距離目標中的權重），並不作為後續分類模型之訓練資料來源。
4. **在 D_3 上建立最終分群 (取得質心與群標記規則)**：對 D_3 進行 PCA 與 k-means 分群，取得分群質心（或其對應的指派規則），使分群結果能反映少數類別在資料結構中的區域性特徵，而不被多數類別完全主導。
5. **移除合成樣本並回到真實資料 (D_2 含 clusters)**：將 D_3 中由 SMOTE 生成之合成樣本移除，回到真實樣本資料 D_2 ，並以先前在 D_3 所建立之分群質心/指派規則，為 D_2 中每一筆真實樣本賦予群標記，得到最終資料 D_2 (含 clusters)，供後續黑箱模型與群內局部代理模型建構使用。

為避免評估偏誤，凡涉及參數估計或結構學習之步驟（如標準化、PCA、k-means 與 SMOTE）僅可在訓練資料（或交叉驗證之訓練折）上進行，再將其轉換與指派規則套用至驗證/測試資料。

3.3 降維

本研究資料屬於高維度的特徵空間，若直接在原始高維空間進行計算，則容易受到尺度差異、雜訊影響，使得後續分群結果不穩定。因此，本研究先以降維方法建立可觀察的二維平面。

3.3.1 主成分分析 (Principal Component Analysis)

主成分分析 (PCA) 是機器學習的非監督式降維方法，利用正交線性轉換將原始特徵表示為相互正交的主成分，使得前幾個主成分能保留原始數據中較大的變異量。在本研究中，PCA 主要用於 (1) 將高維資料投影至低維空間以進行視覺化檢視與極端值辨識；(2) 作為後續分群的輔助，以降低高維空間的距離度量不穩定所造成的干擾。

3.4 分群

本研究採用分群以處理資料異質性，將原始樣本依特徵空間的結構切分為多個子群，使後續黑箱模型可在群內學習較一致的決策邊界。令分群演算法輸出 c_i 為第 i 筆樣本之群標記，並以 $X_c = \{x_i : c_i = c\}$ 表示第 c 群之樣本集合。

3.4.1 k-平均演算法 (k-means)

k-平均演算法 (k-means) 是機器學習的非監督式分群方法，將數據集劃分為 k 個不同的群組 (clusters)，目標為使群內平方誤差最小，使群內資料點相對集中、群間差異相對明顯，其做法為給定群數 k 以及自資料點中隨機選取群中心的情況下，不斷進行：(1) 將每個資料點指派至最近的群中心；(2) 更新群中心為群內資料點的平均值，直到收斂。本研究以手肘法 (elbow method) 評估不同群數 k 下之群內平方誤差 (within-cluster sum of

squares, WCSS)，選取誤差下降趨勢開始趨緩之轉折點作為群數，最終採用 $k = 2$ 進行分群。

3.5 重抽樣

3.5.1 合成少數過度取樣技術 (Synthesized Minority Oversampling Technique)

合成少數過度取樣技術 (SMOTE) 是在機器學習中解決數據類別不平衡問題的常見方法，透過生成新的合成少數類別樣本來平衡數據集，核心概念在利用少數類樣本的鄰近樣本，並在彼此之間插值產生新的樣本點。本研究中，SMOTE 僅用於第 ?? 節所述之分群標記建立流程，以調整分群時的樣本分佈，並不作為後續分類模型之訓練資料來源。

3.6 黑箱模型

本研究使用梯度提升樹模型作為黑箱分類器，於各群內分別訓練以捕捉非線性關係；黑箱模型輸出為類別機率，用於後續局部代理模型的近似目標。黑箱模型於第 c 群定義為 $f_c: \mathbb{R}^p \rightarrow [0, 1]$ ，其輸出

$$\hat{p}_c(x) = f_c(x) = P(y = 1 \mid x, c)$$

並以 $\hat{y} = \mathbb{I}(\hat{p}_c(x) \geq t)$ 產生分類結果，其中 t 為分類門檻。

3.6.1 極限梯度提升 (Extreme Gradient Boosting)

極限梯度提升 (XGBoost) 為監督式學習方法，基於梯度提升決策樹 (Gradient Boosting Decision Tree)，可用於解決迴歸與分類問題，以加法模型逐步疊加弱學習器 (決策樹)，並透過損失函數的梯度資訊進行更新，同時引入多種優化以提升效能與模型泛化能力。在本研究中，XGboost 用於 SECOM 製程量測資料的二元分類，在分群後於各群內分別訓練一個模型 f_c ，同時獲得群內的分類機率輸出至後續局部代理模型使用。

3.7 局部擾動 (Lattice cube)

局部代理模型 (local surrogate model) 的目的是在黑箱函數附近，用可解釋模型對特定點的局部行為做近似。

本研究中，特定點為各群內的黑箱函數輸出機率值接近決策邊界與高信心區域之樣本集合，分別定義為

$$\mathcal{I}_0 = \{i : \hat{p}_c(x_i) \approx 0.5\}, \quad \mathcal{I}_1 = \{i : \hat{p}_c(x_i) \approx 1\},$$

並將各集合取平均作為中心點

$$x_0 = \frac{1}{|\mathcal{I}_0|} \sum_{i \in \mathcal{I}_0} x_i, \quad x_1 = \frac{1}{|\mathcal{I}_1|} \sum_{i \in \mathcal{I}_1} x_i.$$

接著於標準化空間生成格子點形成局部設計點。令標準化轉換為 $S(\cdot)$ ，並分別令

$$z_0 = S(x_0), \quad z_1 = S(x_1).$$

給定步長 (半徑) $\delta > 0$ 與層數 $k \in \mathbb{N}$ ，定義偏移集合

$$\mathcal{M} = \{-k, -k+1, \dots, k\}^p,$$

則以中心點 z_ℓ ($\ell \in \{0, 1\}$) 生成之局部設計點為

$$z_\ell(m) = z_\ell + \delta m, \quad m \in \mathcal{M}.$$

故完整的格子點有 $(2k+1)^p$ ，再映射回原始空間

$$x_\ell(m) = S^{-1}(z_\ell(m)),$$

並以黑箱模型計算局部標記

$$y_\ell^{\text{bb}}(m) = \hat{p}_c(x_\ell(m)).$$

由於本研究特徵維度的 $p = 459$ ，考慮到 $k = 1$ 時，完整格子點為 3^{459} ，於現有的實驗環境下難以枚舉所有格子點，因此本研究採下列方式控制

局部樣本數並降低計算成本：

1. **Stagewise 分段建模**：由於完整格子點有 $(2k+1)^p$ 個，在高維情況下不可行。本研究將特徵依固定順序分段（blockwise）處理。令總特徵維度為 p （本研究資料處理後之特徵維度為 $p = 459$ ），分段數為 B ，則第 b 段包含 p_b 個特徵，且滿足 $\sum_{b=1}^B p_b = p$ 。對於第 b 段而言，於標準化空間以層數參數 k 生成該段的格子點，其格子點為 $(2k+1)^{p_b}$ ；同時將未納入該段的其餘特徵固定為中心點值，使局部擾動僅發生在該段特徵子空間中。

每一個 block 皆為獨立建立的多元線性局部代理模型，以該 block 的格子點樣本作為解釋變數，且以黑箱模型輸出作為反應變數進行擬合，並計算該 block 中各特徵係數之顯著性檢定（p-value）。最後將所有 block 的 p-value 匯總並排序，作為特徵影響性比較與後續特徵選取的依據。

另外，考量單一 block 的格子點數量龐大，可能造成記憶體負擔，本研究在實作上採用分批（batch）方式生成與評分格子點：將該 block 的格子點集合切分為多批次，逐批映射回原始空間並計算黑箱輸出，並在每批次完成後累積回歸所需之統計量（例如 $X^T X$ 、 $X^T y$ 與殘差平方和等），以避免一次載入全部格子點導致記憶體爆炸。待所有批次完成後，再由累積統計量求得該 block 的回歸係數與 p-value。本研究之 p-value 主要作為特徵影響性之排序指標，用於後續特徵選取與解釋，並不作為嚴格統計推論之結論。

3.8 局部模型（Local surrogate）

以局部設計點之標準化表示 $z(m)$ 作為解釋變數，以黑箱輸出 $y^b(m)$ 作為反應變數，建立局部線性代理模型 $g(z) = \beta_0 + \beta^T z$ 。係數 β 反映在 x_0 鄰域內黑箱輸出對各特徵方向之局部敏感度；同時保留 z 空間係數以避免尺度混淆，並可再依 $S(\cdot)$ 轉回原始尺度進行詮釋。

3.9 實驗設計與交叉驗證

本研究將資料切分為訓練集與測試集，測試集不參與模型訓練；並於訓練集進行 K 折交叉驗證以估計泛化能力，同時固定隨機種子以確保結果可重現。分群後之評估採「群內交叉驗證」：對每一群 c 的樣本索引集合分別進行分層抽樣交叉驗證，並彙整各群之 out-of-fold (OOF) 預測機率與混淆矩陣。

3.10 評估指標

本研究評估分為兩類：黑箱分類效能與局部代理擬合品質。

3.10.1 黑箱分類效能

3.10.2 局部代理擬合品質



Chapter 4

研究結果




圖 4.1: PCA




圖 4.2: PCA

4.1 分群結果

4.2 黑箱預測

4.3 關鍵案例分析

4.4 討論與限制



Chapter 5

結論

5.1 總結

5.2 未來工作



Bibliography

