

國立東華大學 應用數學系

統計碩士班

碩士論文

指導教授：曹振海 博士

中文論文標題

English Title



研究生：黃丞暘 撰

中華民國 115 年 X 月



這頁放審定書





這頁放原創性聲明書





致謝

這頁寫致謝內容



國立東華大學應用數學系統計碩士班 黃丞暘 謹致
民國 115 年 X 月



摘要

這頁寫中文摘要



關鍵字：關鍵字 1、關鍵字 2、關鍵字 3



Abstract

這頁寫英文摘要



Keywords: keyword 1, keyword 2, keyword 3



Contents

1	緒論	1
1.1	研究背景與動機	1
1.2	研究問題與既有方法限制	1
1.3	研究目的與方法概述	1
1.4	研究貢獻	1
1.5	章節介紹	1
2	研究資料	2
2.1	資料背景	2
2.2	資料前處理	3
2.2.1	目標變數與資料切分單位	3
2.2.2	缺失值	3
2.2.3	少數類別特徵	3
2.2.4	補值	4
2.2.5	極端值處理	4
2.2.6	前處理後之最終資料集	6
3	研究方法與流程	7
3.1	流程細部	7
3.1.1	資料降維與分群	8
3.1.2	黑箱模型訓練	9
3.1.3	中心點選取與局部生成格子點適配模型	10
3.1.4	評估一致性與資料洩漏控制	11

4	研究結果	12
4.1	分群結果	12
4.2	黑箱預測	15
4.3	關鍵案例分析	16
4.3.1	群 0 (cluster_0)	16
4.3.2	群 1 (cluster_1)	17
4.4	討論與限制	17
5	結論	18
5.1	總結	18
5.2	未來工作	18





Chapter 1

緒論

- 1.1 研究背景與動機
- 1.2 研究問題與既有方法限制
- 1.3 研究目的與方法概述
- 1.4 研究貢獻
- 1.5 章節介紹

第二章介紹研究資料與前處理；第三章說明研究方法，包含分群、黑箱模型、局部擾動與局部代理模型；第四章呈現實驗結果與案例分析；第五章總結研究結論與未來工作方向。

Chapter 2

研究資料

2.1 資料背景

本研究使用半導體製程量測資料—SECOM 作為分析對象，源自 (McCann, M., et al, 2010)。資料以單一樣本為單位，共 1567 筆；每筆樣本包含一個時間欄位 (Time, 範圍自 2008-01-08 02:02:00 至 2008-12-10 18:47:00)、590 個已匿名化的量測變項 (以 x_1 至 x_{590} 表示)，以及一個品質結果欄位 (二元變數, Pass/Fail) 作為目標變數，其中 Fail (-1) 共 1463 筆 (93.36%)，Pass (1) 共 104 筆 (6.64%)，存在明顯的類別不平衡，同時存在缺失值問題，整體缺失率為 4.54%，但缺失分佈不均，部分特徵缺失筆數極高，單一特徵最高缺失達 1429 筆 (91.19%)，且有 20 個特徵之缺失筆數超過 1000 筆 (占樣本數 63.82% 以上)。本研究的目的是在於：在高維、缺失嚴重且類別不平衡的情境下，先以分群切分資料結構，再在各群建立黑箱分類模型，並在群內建立局部 linear surrogate 以描述可解釋的分析 (後續章節說明)。

表 2.1: 資料格式示意 (僅顯示前 3 與後 3 個特徵；中間以 ... 省略)

idx	Time	x_1	x_2	x_3	...	x_{588}	x_{589}	x_{590}	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1

2.2 資料前處理

本節說明資料清理與特徵處理流程。

2.2.1 目標變數與資料切分單位

為方便辨識將目標欄位 Pass (1)、Fail (-1)，轉為 Pass (1)、Fail (0)。時間欄位 Time 不作為模型特徵，於建模前移除。

2.2.2 缺失值

如同第 2.1 節所述，本研究資料有高度缺失的狀況。為避免高度缺失的特徵在補值後造成誤差，本研究以「單一特徵的缺失筆數」作為篩選指標，先移除缺失筆數高於 1000 筆的特徵；




圖 2.1: missingvalue

2.2.3 少數類別特徵

同時，亦發現少數特徵的值為單一或僅數個常數的欄位，我們認為這些特徵對分類模型的影響有限，並以「特徵的不同數值」作為篩選指標，移除特徵值種類低於門檻的特徵。




圖 2.2: uniquevalue

2.2.4 補值

保留上述處理在門檻內的特徵後，再進行補值。此處採用 KNN 補值 (KNNImputer)，以鄰近樣本的距離加權估計缺失值，使補值結果可反映整體資料結構，具有足夠變異的特徵供後續建模。

2.2.5 極端值處理

本研究資料屬於高維度的特徵空間，若直接在原始高維空間進行計算，則容易受到尺度差異、雜訊影響，使得後續分群結果不穩定。因此，本研究先以主成分分析 (Principal Component Analysis) 建立可觀察的二維平面。

主成分分析 (PCA) 是機器學習的非監督式降維方法，利用正交線性轉換將原始特徵表示為相互正交的主成分，使得前幾個主成分能保留原始數據中較大的變異量。

在本研究中，PCA 主要用於

- (1) 將高維資料投影至低維空間以進行視覺化檢視與極端值辨識；
- (2) 作為後續分群的輔助，以降低高維空間的距離度量不穩定所造成的干擾。

因此先以投影至二維平面觀察整體樣貌，並在 PCA 平面上以明確門檻規則移除極端點。移除後重新編號樣本索引，以確保後續分群與交叉驗證索引一致。




圖 2.3: 未移除 outlier 做 pca

如圖 2.3 所示，在未移除我們認為的極端值之前，二維主成分明顯被少數點拉開，我們懷疑這是資料存在極端值，導致資料在計算投影矩陣被少數極端值影響，而產生差距。

我們根據圖 2.3 設定主成分條件 $PC1 \leq 10$ 和 $PC2 \leq 10$ ，於資料重新讀取後，直接刪除未達條件的樣本點，重複同樣的資料前處理、降維的步驟，便得到移除疑似的極端值後的二維主成分平面圖，如圖 2.4。




圖 2.4: 移除 outlier 做 pca

資料清理後的二維主成分平面較均勻的分散，可顯示資料不受極端值影響甚。

2.2.6 前處理後之最終資料集

表 2.2: 資料前處理後之特徵矩陣預覽 (僅顯示前 3 與後 3 個特徵)

idx	x1	x2	x3	...	x588	x589	x590
0	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450
1	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895
2	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694
3	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061
4	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061



Chapter 3

研究方法與流程

本研究以高維製程量測特徵 $X \in \mathbb{R}^{N \times p}$ 與二元品質標記 $y \in \{0, 1\}^N$ 為基礎，目標為黑箱在局部的可解釋性分析。本章節將說明本研究用到的方法，降維、分群、黑箱分類模型、局部資料生成、局部代理模型建構，同時提供實驗環境與評估指標以確保結果具可重現性與可比較性。

流程大綱：

1. 資料前處理後取得特徵矩陣 X 與標記 y 。
2. 對 X 進行分群，得到群標記 $c \in \{0, 1, \dots, C-1\}^N$ 。
3. 於各群 c 內訓練黑箱分類器 $f_c(\cdot)$ ，輸出機率 $\hat{p}_c(x)$ 。
4. 於各群內挑選 $\hat{p}_c(x) \approx 0.5$ 的代表點集合，取該集合的平均並定義為中心點 x_0 。
5. 以 lattice cube 方式於 x_0 周圍生成格子點，並經由黑箱輸出的值作為應變數建立多元線性回歸模型 $g(\cdot)$ 。
6. 以多元線性回歸模型的指標彙整結果，並進行關鍵案例分析。

3.1 流程細部

本研究以研究資料 2.2.6 為起點

3.1.1 資料降維與分群

1. 合成少數過度取樣技術用於降維：

由於目標類別分佈高度不平衡，若直接對資料 2.2.6 降維，降維結果傾向由多數類別的資料訊息主導。因此對該資料使用合成少數過度取樣技術 (SMOTE) 產生少數類別的合成樣本。

合成少數過度取樣技術 (Synthesized Minority Oversampling Technique, SMOTE) 是在機器學習中解決數據類別不平衡問題的常見方法，透過生成新的合成少數類別樣本來平衡數據集，核心概念在利用少數類樣本的鄰近樣本，並在彼此之間插值產生新的樣本點。

在使用 SMOTE 將少數類別資料增至於與多數類別資料相近比例，可達到在降維不完全受到多數類別的資料的訊息影響，以調整隱藏在資料訊息中的樣本分佈，接著再使用 PCA 做降維，如圖 3.1




圖 3.1: 移除 outlier 做 pca 的 SMOTEdata

更使後續分群的結果能反映少數類別在資料結構中的區域性特徵，而不被多數類別完全主導。

2. 分群後移除合成樣本供後續建模使用：

本研究採用 k-平均演算法 (k-means) 做分群以處理資料異質性，將資料依特徵空間的結構切分為數個子群，使後續黑箱模型可在群內學習較一致的決策邊界。

k-平均演算法 (k-means) 是機器學習的非監督式分群方法，將數據集劃分為 k 個不同的群組 (clusters)，目標為使群內平方誤差最小，使群內資料點相對集中、群間差異相對明顯，其做法為給定群數 k 以及自資料點中隨機選取群中心的情況下，不斷進行：(1) 將每個資料點指派至最近的群中心；(2) 更新群中心為群內資料點的平均值，直到收斂。

本研究以手肘法 (elbow method) 評估不同群數 k 下之群內平方誤差 (within-cluster sum of squares, WCSS)，選取誤差下降趨勢開始趨緩之轉折點作為群數，最終採用 $k = 2$ 進行分群。分群結果如圖 4.4




圖 3.2: 移除 outlier 做 pca+kmeans 的 SMOTEdata

而在本研究中，會將合成樣本移除，僅保留真實資料集及其類別標記，供後續各群內黑箱建模使用。

3.1.2 黑箱模型訓練

1. 各群全體訓練黑箱模型：

在每一群的全體真實資料上訓練一個黑箱模型，本研究中採用樹模型中的 XGBoost，亦作為後續局部格子點的黑箱輸出函數。

極限梯度提升 (Extreme Gradient Boosting, XGBoost) 為監督式學習方法，基於梯度提升決策樹 (Gradient Boosting Decision Tree)，可用於解決迴歸與分類問題，以加法模型逐步疊加弱學習器 (決策樹)，並透過損失函數的梯度資訊進行更新，同時引入多種優化以提升效能與

模型泛化能力。亦是目前最常被使用在 Kaggle 資料分析競賽當中的機器學習模型。

本研究以 (TN, FP, FN, TP) 彙整黑箱分類結果，並以此計算分類效能指標，包含 Accuracy、False Alarm Rate 與 ROC-AUC。其中 Accuracy 與 False Alarm Rate 定義如下：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{False Alarm Rate} = \frac{FP}{FP + TN}$$

ROC-AUC 則以模型輸出機率 $\hat{p}(x)$ 於不同門檻下所形成之 ROC 曲線面積表示。此外，本研究同時呈現整體與各群的混淆矩陣，以比較整體模型與分群後模型表現之差異。

2. 各群內交叉驗證訓練黑箱模型取得各測試集之機率值為 0.5 的點)：

同時，對每一群 $c \in 0, 1$ ，以 K -fold 進行交叉驗證 (Cross Validation, CV)。

本研究中，設定五折的交叉驗證，其目的在於模型訓練不會只針對單一結果，而是將資料切分成 80% 作為訓練集資料，20% 作為測試集資料，共依序訓練五次 (五折)。

其中，在每一折當中，僅對訓練集作 SMOTE 以提升少數類別可分性，測試集則不做 SMOTE，並以該折訓練之模型輸出測試集資料為 Pass 或 Fail 的預測機率值 (介於 0, 1 之間)。彙整各折測試集輸出得到每筆真實樣本的機率，用於後續挑選欲分析的中心點。

3.1.3 中心點選取與局部生成格子點適配模型

1. 群內中心點選取 (以邊界附近樣本聚合)：

於五折訓練中挑選機率最接近決策邊界 (例如 0.5) 的前幾筆資料點集合。將這些資料的標準化特徵向量取平均，得到該集合的局部分析中心點。

2. 局部的格子點生成：

於中心點附近生成格子點形成局部設計點，

局部生成適配模型的目的是在黑箱函數附近，用可解釋模型對特定點的局部行為做近似。

給定步長（半徑） $\delta > 0$ 與層數 $k \in \mathbb{N}$ ，定義偏移集合

$$\mathcal{M} = \{-k, -k+1, \dots, k\}^p,$$

則以中心點 z_ℓ ($\ell \in \{0, 1\}$) 生成之局部設計點為

$$z_\ell(m) = z_\ell + \delta m, \quad m \in \mathcal{M}.$$

故完整的格子點有 $(2k+1)^p$ ，並以黑箱模型計算該點的機率值

3. 特徵顯著性彙整與排序：

對每個 block 的每一個特徵，將其局部線性係數與 p-value 彙整成一張特徵重要度表，並依 p-value（及輔助的 $|\beta|$ ）排序，得到該群在中心點附近的局部解釋結果。

4. 重訓局部線性模型：

以局部資料評估代理模型對黑箱輸出的近似程度，指標包含 R^2 與 SSE。當不同 (k, δ) 或局部樣本數設定改變時，以相同指標比較局部近似的穩定性。

3.1.4 評估一致性與資料洩漏控制

凡涉及參數估計或結構學習之步驟（標準化、PCA、k-means、SMOTE、以及各群黑箱模型訓練）需置於訓練資料或交叉驗證訓練折內完成；驗證/測試資料僅套用訓練端估計所得之轉換、群指派規則與模型參數，以避免資料洩漏造成的評估偏誤。

為避免評估偏誤，凡涉及參數估計或結構學習之步驟（如標準化、PCA、k-means 與 SMOTE）僅可在訓練資料（或交叉驗證之訓練折）上進行，再將其轉換與指派規則套用至驗證/測試資料。

Chapter 4

研究結果

4.1 分群結果




圖 4.1: 未移除 outlier 做 pca+kmeans

cluster	0	1
$y = 0$	1460	3
$y = 1$	103	1




圖 4.2: 未移除 outlier 做 pca+kmeans 的 SMOTEdat




圖 4.3: 移除 outlier 做 pca+kmeans 的原始 data 含 y

cluster	0	1
$y = 0$	660	770
$y = 1$	58	37




圖 4.4: 移除 outlier 做 pca+kmeans 的 SMOTEdata




圖 4.5: 移除 outlier 做 pca+kmeans 的 SMOTEdata 含 y

cluster	0	1
$y = 0$	743	687
$y = 1$	205	510

我們對資料實施 SMOTE，是為了讓資料在做降維與分群時，可抓到少數類別樣本點的資訊，因此分群後的結果，我們推測應資料應同時具有 Pass 和 Fail 的資訊，並且後續的建模僅用原始的資料點，而不包含經由 SMOTE 的生成點

cluster	0	1
$y = 0$	743	687
$y = 1$	29	66

表 4.1: 資料格式示意 (僅顯示前 3 與後 3 個特徵；中間以 ... 省略)

idx	x1	x2	x3	...	x588	x589	x590	cluster
1	0.2164	0.8565	-0.4346	...	-0.1409	-0.0501	0.2015	1
2	1.0940	-0.3748	1.0208	...	0.4219	0.2582	1.1679	1
3	-1.1142	0.8060	-0.4796	...	3.6316	3.3164	-0.1717	1
4	-0.3548	-0.1909	-0.0493	...	-0.1678	-0.2979	-0.2681	1
5	0.2341	0.0952	1.1212	...	-0.1678	-0.2979	-0.2681	1

4.2 黑箱預測

表 4.2: Black-box classification performance (OOF) overall and by cluster.

group	n	ACC	FAR	ROC-AUC
ALL	1525	0.9318	0.0126	0.6745
cluster_0	676	0.9039	0.0226	0.6996
cluster_1	849	0.9482	0.0099	0.6266

Confusion matrix (rows=true [0, 1], cols=pred [0, 1])

表 4.3: Confusion matrix (ALL), mean over 5 folds.

	pred 0	pred 1
true 0	282.4	3.6
true 1	17.2	1.8

表 4.4: Confusion matrix (cluster_0), mean over 5 folds.

	pred 0	pred 1
true 0	121.0	2.8
true 1	10.2	1.2

表 4.5: Confusion matrix (cluster_1), mean over 5 folds.

	pred 0	pred 1
true 0	160.6	1.6
true 1	7.2	0.4

4.3 關鍵案例分析

本節針對分群後之資料，彙整各群用於「局部線性代理模型（local surrogate）」建構的關鍵案例（中心點）索引（index）。所列索引係指完成資料清理與重設索引（reset_index(drop=True)）後之列序號，用於確保後續的局部格點抽樣、分段（block-wise）線性回歸估計、係數與顯著性（ p -value）排序等流程具可重現性。

對第 c 群，將其關鍵案例索引集合記為 $\mathcal{I}_c = \{i_1, \dots, i_m\}$ ，其中每個 i 對應一筆樣本 $x^{(i)}$ ，並以該樣本作為局部代理模型之中心點 x_0 。由於本研究的「關鍵案例清單」在目前輸出中各群僅提供 $m = 10$ 筆（未達規劃之 30 筆），因此本節先完整列示現有可用之全部索引，並保留擴充至每群 30 筆之彈性，供後續以相同準則增補。

4.3.1 群 0 (cluster_0)

群 0 的關鍵案例索引如表 4.6。此群之中心點黑箱輸出機率（在本次彙整結果中為固定值）為

$$p_{\text{oor}}(x_0) = 0.500756, \quad p_{\text{final}}(x_0) = 0.086943,$$

後續所有局部線性係數與顯著性估計均以表中索引對應之 x_0 為起點建立局部樣本並計算。

表 4.6: Cluster 0 重要特徵（依 $|\hat{\beta}|$ 排序，Top 10）

rank_p	feature	coef	R_{block}^2	p
1	x112	-0.098230	0.861	0.000
2	x130	+0.080726	0.730	0.000
3	x489	-0.074666	0.892	0.000
4	x69	-0.071716	0.896	0.000
5	x557	-0.056932	0.792	0.000
6	x551	-0.050496	0.750	0.000
7	x36	-0.044920	0.746	0.000
8	x337	+0.038257	0.767	0.000
9	x369	-0.038089	0.749	0.000
10	x282	-0.035327	0.647	0.000

4.3.2 群 1 (cluster_1)

群 1 的關鍵案例索引如表 4.7。此群之中心點黑箱輸出機率（在本次彙整結果中為固定值）為

$$p_{\text{oor}}(x_0) = 0.494366, \quad p_{\text{final}}(x_0) = 0.025957,$$

後續局部代理模型之分段線性估計與特徵顯著性排序皆以表中索引對應之中心點 x_0 為基準進行。

表 4.7: Cluster 1 重要特徵（依 $|\hat{\beta}|$ 排序，Top 10）

rank_p	feature	coef	R^2_{block}	p
1	x1	-0.036000	0.834	0.000
2	x576	-0.024446	0.627	0.000
3	x585	+0.020591	0.744	0.000
4	x123	-0.020540	0.787	0.000
5	x127	+0.017246	0.787	0.000
6	x64	+0.016939	0.446	0.000
7	x324	-0.016182	0.684	0.000
8	x87	+0.015838	0.697	0.000
9	x176	+0.015564	0.891	0.000
10	x118	-0.014974	0.707	0.000

總結而言，本節提供各群用於局部線性代理模型之中心點索引，作為「關鍵案例」的可重現輸入介面；後續若需將每群案例數擴充至 30 筆，僅需在相同分群與相同選取準則下對 $\mathcal{I}_c$ 進行增補，即可不改動下游的局部建模與統計檢定流程。

4.4 討論與限制

Chapter 5

結論

5.1 總結

5.2 未來工作



Bibliography

