

國立東華大學 應用數學系

統計碩士班

碩士論文

指導教授：曹振海 博士

中文論文標題

English Title



研究生：黃丞暘 撰

中華民國 115 年 X 月



這頁放審定書





這頁放原創性聲明書





致謝

這頁寫致謝內容



國立東華大學應用數學系統計碩士班 黃丞暘 謹致
民國 115 年 X 月



摘要

這頁寫中文摘要



關鍵字：關鍵字 1、關鍵字 2、關鍵字 3



Abstract

這頁寫英文摘要



Keywords: keyword 1, keyword 2, keyword 3



Contents

1	緒論	1
1.1	研究背景與動機	1
1.2	文獻回顧	2
1.3	研究目的	4
1.4	章節介紹	4
2	研究資料	5
2.1	資料背景	5
2.2	資料前處理	5
2.2.1	目標變數與資料切分單位	6
2.2.2	缺失值	6
2.2.3	少數類別特徵	6
2.2.4	補值	7
2.2.5	極端點處理	8
2.2.6	前處理後最終資料集摘要	10
3	研究方法與流程	12
3.1	流程大綱	12
3.2	流程細部	13
3.2.1	分群	13
3.2.2	訓練分類模型	14
3.2.3	中心點選取與局部生成格子點擬合模型	14
3.3	評估方法	17

4	研究結果	19
4.1	各群分類模型之評估與決策邊界樣本之採用	19
4.1.1	各群之類別分布與分類模型設定	19
4.1.2	各群分類模型之評估結果比較	20
4.1.3	各群中接近決策邊界之樣本	21
4.2	各群局部刻劃模型之建立與結果分析	21
5	結論	25
5.1	總結	25
5.2	未來工作	26





Chapter 1

緒論

1.1 研究背景與動機

半導體產業是現代科技發展的核心基礎之一，從消費性電子產品到通訊、運算及自動化設備，皆高度依賴半導體元件的技術與品質表現。隨著科技持續進步，半導體製程亦朝向高精密與高複雜度的方向發展，尤其在製造端，不僅要維持產品功能的正確性，還要兼顧產品的生產效率、成本控制及品質穩定。而良率（Yield）一直是實務上最直接且最重要的指標之一，良率的高低不只影響出貨與製造成本，也會牽動工廠產線的資源配置與製程上的改善。因此，如何在環環相扣且複雜的製程中保持產品的穩定，同時又提升品質，至始至終都是半導體產業的重要課題。

在此背景下，晶圓（wafer）製造為半導體生產中的重要環節，從原料到成品，通常需要日以繼夜的經過數道高精密的程序反覆進行，才逐步形成可以用的晶片（Chip），如圖 1.1 所示。由於各製程步驟彼此相依，且在生產過程中伴隨著機台參數、感測訊號、量測結果與紀錄，製造端因而累積了大量的製程與量測資料。




圖 1.1: 晶圓程序

這些資料除了用來記錄生產過程，也被用來監控制程狀態、辨識異常，以降低不良品產出。也因此，為了良率的進步與品質的穩定需求，就必須進一步透過資料分析來理解製程狀態與品質結果之間的關係。就半導體資料而言，常見的任務便是如何透過分析量測變數來判斷產品最終是屬於良品 (Pass) 還是不良品 (Fail)，

近年來，多項研究使用機器學習方法進行產品品質的預測，並以準確度 (Accuracy) 等指標來比較模型表現。然而在實務情境中，僅有準確度往往不足以支援製程的決策。工程部門更關心的是：哪些製程變數是對產品品質最具重要性及影響性的。換言之，當產業開始利用機器學習方法分析製程資料時，研究焦點不只注重在分類結果的好壞，而是將問題轉向如何利用製程資料，來回答工程師哪些變數對產品品質的結果是具決定性的。

1.2 文獻回顧

在既有的研究中，已經有不少以 McCann and Johnston (2008) 的 SEMi COnductor Manufacturing (SECOM) 資料作為半導體製程品質分析的代表性資料來源。該資料集包含大量半導體製程量測變數，並對各樣本標記 Pass 或 Fail 的品質類別，因此常被用於資料前處理方法與製程品質分類的比較研究。Park et al. (2024) 提到該資料除了具有高維度與高缺失值等等特性外，不同樣本亦可能對應不同的製程狀態，使資料在統計分布上呈現異質

性，因此常作為製程品質分類與前處理方法的基準資料集。

在分析的方法上，賴立夫 (2022) 透過補值、特徵選擇與決策樹 (Decision Tree) 建立分類模型，並利用決策樹的節點結構追溯影響模型分類的關鍵變數，此類方法的優點是在於結果較容易說明；但是當使用的資料量不大且形態呈現高維度特性時，僅依賴少量層數的樹狀結構，其表達能力可能不足。因此，實務上常改用預測能力表現較強的方法作為分類基準。例如 Breiman (2001) 提出的隨機森林 (Random Forest)，透過數棵的隨機化決策樹以集成方式提升分類的穩定性；Friedman (2001) 提出的梯度提升樹 (Gradient Boosting Machine) 則以逐步加法方式建立強預測模型在此基礎上，Chen and Guestrin (2016) 提出的極限梯度提升 (Extreme Gradient Boosting, XGBoost)，進一步在樹模型與梯度提升的計算效率和資料稀疏的處理加以改良，因此與隨機森林等方法常被視為高維度資料分析的強基準分類方法。

然而，當方法愈能處理複雜的關係時，其判斷的依據也愈不易直接理解；若仍將分類準確度作為主要評估標準，並不足以支援實務上的決策；因為實務上更在意的是為何某些樣本被分類為不良，又或者哪些量測變數在分類中扮演重要的角色。所以仍需額外方法說明單一樣本被分類時的原因。

基於此，Lundberg and Lee (2017) 以合作賽局理論的 Shapley value 為基礎提出 SHapley Additive exPlanations (SHAP)，將單一樣本的預測結果分解為各特徵貢獻度的加法表示，同時可用於整體樣本的彙整比較。此方法可作為複雜分類方法的事後解釋，以量化特徵對分類結果的影響，可以應用於不同的數據類型，包括文字、表格資料和影像。

Ribeiro et al. (2016) 提出 (Local Interpretable Model-agnostic Explanations (LIME))，以「局部可解釋」為目標，在欲解釋樣本附近生成擾動樣本，並以距離為權重給予相鄰的樣本較高權重，再以簡單線性模型描述分類方法在局部範圍內的分類行為，以提供單一樣本被分類時的解釋依據。

整體而言，既有研究已提供不少製程品質分類的方法，也發展出可用於事後說明分類結果的工具。然而，面對高維度、可能具有多種製程狀態的半導體製程資料時，對分類結果的可解釋性仍有進一步討論的空間。

1.3 研究目的

然而，現有的解釋方法仍可能不穩定，主要來自以下幾個原因。

第一，面對高維度的製程資料，其特性是量測變數數量龐大，但是觀察樣本數不足以支撐對各變數的影響；若採用結構較淺的模型（如決策樹）進行解釋，其表現可能受限於模型本身的能力。

第二，製程資料可能存在多種製程狀態，亦即混合的結構。若以單一分類基準描述全體樣本，其決策方面可能同時存在多種不同的規則，則對單一樣本的局部解釋，得到的可能是混合後的分類標準，導致局部解釋缺乏穩定及信任。舉個簡單的例子：好比像是在一間咖啡廳，我們想要知道這間咖啡廳的顧客在消費能力與咖啡價的關係，可是咖啡廳的顧客千奇百種，有老人、有年輕人、有工程師、有服務業各式各樣的人群，若我們以整群下去做分析，那可能得到的結果是混雜的。可是如果我們能先把相似的族群放一群，也就是資料中彼此相似的樣本，可能是變數調查結果是一群學生、一群老年人或一群上班族，那是不是對於整個分析的結果會更加分明？所以這也是我們的假設，在整筆資料中有彼此相似的個體，個體內部所形成的群與群之間存在明顯差異，因此，透過分群或許能讓分析結果更具有信心與穩定。

第三，在高維空間中，以隨機擾動的方式生成鄰近樣本時，樣本容易偏離真實資料分布，使局部刻劃模型可能在外插的區域擬合，導致局部的解釋與實際資料機制不一致。

因此，本研究進一步建立一套能對複雜分類結果提供局部可解釋的分析方法。具體而言：先透過分群降低資料異質性及其對訓練模型時的干擾；再設計局部範圍中的樣本生成方式，以便在局部模型擬合時，可提升模型的穩定性，同時降低樣本生成時偏離資料分布所造成的外插風險；最後建立局部刻劃模型，使分類結果不只是看預測表現，還能轉為對製程改善具有參考價值的資訊。

1.4 章節介紹

第二章介紹研究資料；第三章說明研究方法與流程，包含分群、訓練分類模型、擬合局部刻劃模型；第四章呈現研究結果與分析；第五章總結研究結論與未來工作方向。

Chapter 2

研究資料

2.1 資料背景

本研究使用半導體製程量測資料—SECOM 作為分析對象 McCann and Johnston (2008)，共 1567 筆；每筆樣本包含一個時間欄位（Time, 範圍自 2008-01-08 02:02:00 至 2008-12-10 18:47:00）、590 個已匿名化的量測變項（以 x_1 至 x_{590} 表示），以及一個品質類別欄位（二元變數，Pass/Fail）作為目標變數，其中 Pass（-1）共 1463 筆（93.36%），Fail（1）共 104 筆（6.64%），存在明顯的類別不平衡，同時存在缺失值問題，整體缺失率為 4.54%，但缺失分布不均，部分特徵缺失筆數極高，單一特徵最高缺失達 1429 筆（91.19%），且有 20 個特徵之缺失筆數超過 1000 筆（占樣本數 63.82% 以上）。

表 2.1: SECOM 原始資料集摘要

idx	Time	x_1	x_2	x_3	...	x_{588}	x_{589}	x_{590}	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1

2.2 資料前處理

本節說明資料清理與特徵處理流程。

2.2.1 目標變數與資料切分單位

為方便後續建模與評估，本研究將原始目標欄位 Pass (-1)、Fail (1)，重新編碼為 Pass (0)、Fail (1)。時間欄位 Time 不作為模型特徵，於建模前移除。

2.2.2 缺失值

如同第 2.1 節所述，本研究資料有高度缺失的狀況。為避免高度缺失的特徵在補值後造成誤差，本研究以「單一特徵的缺失筆數」作為篩選指標，先移除缺失筆數高於 1000 筆的特徵。




圖 2.1: SECOM 原始資料各變數缺失值筆數分布

2.2.3 少數類別特徵

同時，亦發現部分特徵的值為單一或僅數個常數的欄位，我們認為這些特徵對分類模型的影響有限，並以「特徵的不同數值」作為篩選指標，移除特徵值種類低於門檻的特徵。




圖 2.2: SECOM 原始資料各變數相異值數量分布

2.2.4 補值

保留上述處理在門檻內的特徵後，再進行補值。本研究採用 KNN 補值 (k -Nearest Neighbors Imputer, KNN imputer)，其核心概念為：對於一個缺失值，在樣本空間中尋找與該樣本距離最近的 k 個鄰近樣本，再以鄰近樣本在該特徵上的觀測值進行距離加權平均，以估計缺失值。Troyanskaya et al. (2001) 比較多種缺失值估計方法後指出，KNN 型式的補值方法在缺失值估計上具有良好的穩健性，其表現優於單純以平均值進行填補的方法。因此，相較於以整體平均數進行補值，KNN 補值可利用樣本間的相似性資訊，作為估計缺失值的依據。

設樣本 i 在第 j 個特徵的缺失值為 x_{ij} ，則欲估計的缺失值定義為：

$$\hat{x}_{ij} = \frac{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r) x_{rj}}{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r)}$$

其中 $\mathcal{N}_k(i,j)$ 表示在「第 j 個特徵有觀測值」的樣本中，與樣本 i 距離最近的 k 個鄰近樣本的集合（本研究設定 $k = 10$ ）；並且採用距離反比作為權重，使距離較近之鄰近樣本對補值結果具有較大影響。令 $w(i,r) = 1/d(i,r)$ 。距離 $d(i,r)$ 依照 nan-euclidean distance（缺失值下的歐式距離）定義為

$$d(i,r) = \left(\frac{p}{|\Omega_{ir}|} \sum_{\ell \in \Omega_{ir}} (x_{i\ell} - x_{r\ell})^2 \right)^{1/2}$$

其中 Ω_{ir} 為樣本 i 與樣本 r 同時具有觀測值的特徵集合。 $|\Omega_{ir}|$ 為其元素個數， p 為特徵總數。

2.2.5 極端點處理

本研究資料屬於高維度的特徵空間，若直接在原始高維空間進行計算，則容易受到尺度差異、雜訊影響，使得後續分群結果不穩定。因此，本研究先以主成分分析 (Principal Component Analysis, PCA) 將高維資料投影至可觀察的二維平面，作為極端點檢視與後續分群的輔助。

PCA 為非監督式降維方法，利用正交線性轉換將原始特徵表示為相互正交的主成分，使得前幾個主成分能保留原始數據中較大的變異量。

在本研究中，PCA 主要用於：

- (1) 將高維資料投影至低維空間，以進行視覺化檢視與極端點辨識；
- (2) 作為後續分群的輔助，以降低高維空間的距離度量不穩定所造成的干擾。

此外，Hubert et al. (2005) 指出 PCA 對極端值較敏感，少數離群樣本可能對主成分方向與投影結果造成明顯影響。因此，本研究先將資料投影至二維 PCA 平面觀察整體分布，再依據投影結果設定明確的篩選門檻，移除明顯偏離整體樣本分布的極端點，以降低其對後續分群分析的干擾。




圖 2.3: 未移除 PCA 極端點的原始資料之 PCA 投影

如圖 2.3 所示，在未移除極端點之前，二維主成分明顯被少數點拉開，使大多數樣本集中於狹小的區域。因此，本研究依據 PCA 投影的分布情形，採用的門檻規則為 $PC1 \leq 10$ 及 $PC2 \leq 10$ 。於資料重新讀取後，將明顯偏離整體樣本分布的樣本視為極端點並移除，再重複同樣的資料前處理與 PCA 步驟，移除極端點後的二維主成分平面如圖 2.4 所示。




圖 2.4: 移除 PCA 極端點後的原始資料之 PCA 投影

其分布較均勻，可顯示資料在投影與距離結構上受到極端點干擾的程度降低。

2.2.6 前處理後最終資料集摘要

完成特徵清理、缺失處理與極端點移除後，本研究得到最終分析資料 $(\mathbf{X}, \mathbf{y})$ ，其中 $\mathbf{X} \in \mathbb{R}^{n \times p}$ 為輸入變數， $\mathbf{y} \in \{0, 1\}^n$ 為對應標籤。 n 為樣本數， p 為前處理後的特徵數。為避免不同單位與尺度造成距離計算與模型訓練偏差， $\mathbf{X}$ 已進一步進行標準化處理。

表 2.2 為最終分析資料的預覽表。其中 Pass/Fail 欄位即為標籤 $\mathbf{y}$ 。此時資料已不含缺失值，且於移除極端點後重新對樣本編號，以確保後續分群、訓練分類模型與建立局部刻劃模型時的樣本編號一致。並且皆以此資料集作為分析。

表 2.2: 資料前處理後之最終資料集

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0



Chapter 3

研究方法與流程

本章節將說明本研究用到的方法，包含分群、建立分類模型、生成局部資料、擬合局部刻劃模型，首先介紹大綱，再來呈現每個流程的細部動作。

3.1 流程大綱




圖 3.1: 流程大綱

如圖 3.1 為整個研究流程大綱，細部說明如 ??。

3.2 流程細部

3.2.1 分群

1. 合成少數過度取樣技術用於降維：

本研究使用 PCA 降維空間的主成分作為分群的訊息。然而，由於目標類別分布高度不平衡，若直接對資料進行降維，其結果傾向由多數類別的訊息主導，使少數類別在特徵空間中的結構不容易辨識。

因此，本研究先於訓練資料中使用合成少數過度取樣技術（Synthesized Minority Oversampling Technique, SMOTE）產生少數類別的合成資料。以不改變多數類別分布的前提下，補足少數類別於降維的特徵空間中的資訊。

SMOTE 是在機器學習中解決數據類別不平衡問題的常見方法，其核心概念為針對每個少數類別的樣本 x_i ，尋找其鄰近樣本 $x_{neighbor}$ ，並在兩者之間進行插值產生合成資料 x_{new} ；其合成資料的生成式如下。

$$\mathbf{x}_{new} = \mathbf{x}_i + \lambda (\mathbf{x}_{neighbor} - \mathbf{x}_i), \quad \lambda \sim \text{Uniform}(0, 1)$$

將少數類別資料增至與多數類別資料相近比例後，接著再使用 PCA 做降維。

2. 分群與合成資料移除（僅保留真實資料供後續建模）：

本研究採用 k-平均演算法 (k-means) 做分群以處理資料異質性，在 PCA 空間中依照樣本結構將資料切分為數個子群，使後續分類模型可在群內學習較一致的決策邊界。

k-means 是機器學習的非監督式分群方法，其做法為給定群數 k 以及自資料點中隨機選取群中心後，不斷進行：(1) 將每個資料點指派至最近的群中心；(2) 更新群中心為群內資料點的平均值，直到收斂。

本研究以手肘法 (elbow method) 評估不同群數 k 下的群內平方誤差 (within-cluster sum of squares, WCSS)，WCSS 定義如下。

$$\text{WCSS}(k) = \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2, \quad \boldsymbol{\mu}_i = \frac{1}{|S_i|} \sum_{\mathbf{x} \in S_i} \mathbf{x}$$

其中 S_i 為第 i 群， μ_i 為該群中心，WCSS 隨著 k 增加必然下降，因此選擇 k 值在 WCSS 降幅最大時作為分成 k 群的依據。本研究最終採用 $k = 2$ 進行分群。

另外，需強調的是：SMOTE 僅用於降維與分群的階段，以改善少數類別在降維空間的資訊；完成分群後，會將合成資料移除，只保留真實資料集以便後續在各群內分別進行分類模型的訓練與評估。

3.2.2 訓練分類模型

本研究在建立模型方面採用樹模型中的極限梯度提升 (Extreme Gradient Boosting, XGBoost)。

XGBoost 為監督式學習方法，基於梯度提升決策樹 (Gradient Boosting Decision Tree)，以加法模型逐步疊加弱學習器 (決策樹)，並透過損失函數的梯度資訊進行更新，同時引入多種優化以提升效能與模型泛化能力，可用於解決預測與分類問題，亦是目前最常被使用在 Kaggle 資料分析競賽當中的機器學習模型。

3.2.3 中心點選取與局部生成格子點擬合模型

1. 群內樣本挑選與中心點建立：

本研究在建立模型階段有採用五折交叉驗證 (k -fold Cross Validation, $k = 5$)。將資料切分成 80% 作為訓練集資料，20% 作為測試集資料，共依序訓練五次 (五折) 以降低單次切分造成的評估偏差，由於資料具有類別不平衡，僅對訓練集執行 SMOTE 以提升少數類別可分性，測試集則維持不變。

在每一折交叉驗證中，使用該折的訓練集所訓練的模型，輸出該折的測試集之機率為 $\hat{p}$ ($\hat{p} \in [0, 1]$)，並轉為類別 Pass 或 Fail。本研究採用分類閾值為 0.5，亦即，當 $\hat{p} \geq 0.5$ 時，模型預測為 $\hat{y} = 1$ (Fail)；當 $\hat{p} < 0.5$ 時，模型預測為 $\hat{y} = 0$ (Pass)。在五折交叉驗證後，可得到所有樣本在模型輸出後的機率，

而當該機率愈接近 0.5 時，表示該樣本愈接近模型的決策邊界。換句話說，就是模型預測該樣本為哪一類很不明確。因此本研究設定篩選

的門檻為：

$$|\hat{p} - 0.5| \leq 0.05$$

並令其為群 c 下的樣本集合 S_n^c 。此處的 0.05 並非理論上唯一的門檻，而是基於研究操作上的考量所設定，一方面可保留足夠接近決策邊界的樣本，另一方面亦可避免門檻過於嚴格而使樣本數太少，不利後續分析與比較。接著定義群 c 的局部刻劃中心點：

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$

其中 $\mathbf{x}_i$ 為接近決策邊界的樣本點之特徵向量。

2. 局部格子點生成：

為了在群 c 中心點 $\mathbf{x}_{\text{center}}^c = (x_1^c, \dots, x_p^c)$ 附近建立可控制的局部範圍，所以設定每一個維度有一個固定的位移步長 δ ，然後令第 j 維可取的位移倍數為

$$m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$$

因此每一維共有 $2k+1$ 個可取的位移倍數，而實際對應的位移量為

$$\{-k\delta, (-k+1)\delta, \dots, 0, \dots, (k-1)\delta, k\delta\}$$

因此，對任一維度的位移倍數可組成一個 p 維的位移向量 $\mathbf{m} = (m_1, \dots, m_p)$ ，可生成一個以中心點為基準的局部格子點

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m} = (x_1^{(c)} + \delta m_1, \dots, x_p^{(c)} + \delta m_p)$$

亦即，對任一格子點而言，其各維度座標皆由中心點對應維度的值加上 δm_j 所形成。以下舉一個簡單例子：

如圖 3.2 以二維為例子說明中心點附近之局部格子點生成方式，假設二維情況下群 c 的中心點為 $\mathbf{x}_{\text{center}}^c = (1.2, -0.5)$ ，令 $\delta = 0.1$ 且 $k = 2$ ，則每一維可取的實際位移量為 $\{-0.2, -0.1, 0, 0.1, 0.2\}$ 。若位移向量

取 $\mathbf{m} = (-1, 2)$ ，則可得到該格子點為

$$\mathbf{x}_{\mathbf{m}}^c = (1.2 + 0.1 \times (-1), -0.5 + 0.1 \times 2) = (1.1, -0.3)$$

此例表示該格子點由中心點在 x_1 方向減少 0.1、在 x_2 方向增加 0.2 所形成。若在二維情況下取所有組合，則總共可形成 $5^2 = 25$ 個格子點，構成局部範圍。




圖 3.2: 以二維例子說明中心點附近的局部格子點生成方式。圖中橫軸與縱軸分別表示特徵維度 x_1 與 x_2 ，各格子點座標由中心點 $(1.2, -0.5)$ 沿兩維依固定步長 $\delta = 0.1$ 進行位移後形成；其中藍點為位移向量 $\mathbf{m} = (-1, 2)$ 所對應之格子點 $(1.1, -0.3)$ 。

3. 特徵選擇與建立局部刻劃模型：

然而，本研究 $p = 459$ 且令 $k = 2$ ，若對整個 p 維度取所有組合，則

理論上的格子點總數為

$$(2k + 1)^p = 5^{459}$$

其數量極為龐大，無法完整列舉。因此，本研究將所有格子點視為理論上某個局部的範圍，實作上並非窮舉全部組合，而是透過隨機抽樣的方式建立該局部空間，以進行後續分析。

首先，自所有格子點鐘隨機抽樣 100 萬筆，以其特徵向量作為自變數，以分類模型對該其所輸出的預測機率作為應變數，建立多元迴歸線性模型，並以普通最小平方法（Ordinary least squares, OLS）估計其迴歸係數。OLS 是透過最小化殘差平方和（Residual Sum of Squares）進行評估，當 X 滿秩使 $X^T X$ 可逆時，其估計式為

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

在此基礎上，為篩選在局部範圍中具有穩定影響的特徵，本研究進行重複抽樣與特徵選擇的流程：於每次抽樣與模型擬合中，依序以顯著水準 $p\text{-value} = \{0.05, 0.01, 0.005, 0.001, 0.0005\}$ 逐步選擇特徵，並重複執行 50 次，統計各特徵在最後一輪被保留的次數；將 50 次重複中皆在最後一輪被保留的特徵視為該群的局部範圍中最具穩定的特徵。

在決定最終的特徵後，再從相同的格子點生成方法中重新抽取 200 萬筆格子點，以最終的特徵作為自變數，並以其分類模型輸出的預測機率作為應變數，重新以 OLS 擬合最終的局部線性模型。

3.3 評估方法

Bengio and Grandvalet (2004) 表示 k -折交叉驗證在不同折之間會使用相同的資料作為訓練集，使各折的評估結果具有相關性，倘若直接以各折的分數去建立信賴區間，在統計上並不直觀且可能產生偏差。

因此，本研究改採重抽樣（Bootstrap）方法，以有放回的方式反覆抽取相同的格子點生成方法中 200 萬筆格子點，並於每次重抽當中計算評估指標，以其抽樣分布估計其點估計與其 95% 信賴區間來判斷群間是否有差異。

評估指標包含準確率 (Accuracy, ACC)、誤報率 (False Alarm Rate, FAR) 與 ROC-AUC，其定義如下：

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}, \quad FAR = \frac{FP}{FP + TN}$$

ROC-AUC 則以模型輸出機率於不同門檻下所形成的 ROC 曲線面積表示。其中真陰性 (TN)、假陽性 (FP)、假陰性 (FN)、真陽性 (TP) 分別對應「Pass 判為 Pass」、「Pass 判為 Fail」、「Fail 判為 Pass」、「Fail 判為 Fail」。其說明如表 3.1 所示。

表 3.1: 二元分類之混淆矩陣

	預測為 Pass	預測為 Fail
真實為 Pass	TN	FP
真實為 Fail	FN	TP

針對局部刻劃模型，同樣採用重抽樣方法，以估計決定係數 R^2 之點估計與其 95% 信賴區間，以評估局部模型對分類模型在該範圍的擬合程度。此外，亦透過各特徵之迴歸係數，觀察分類模型在中心點附近的局部行為，以分析不同特徵對預測結果的影響方向與重要性。

Chapter 4

研究結果

本章節先呈現分群後的分類模型評估，接著比較「未分群單一模型」與「分群後各群模型」的差異；最後說明在分類模型擬合局部刻劃模型的結果。

4.1 各群分類模型之評估與決策邊界樣本之採用

4.1.1 各群之類別分布與分類模型設定

依研究方法與流程內容，本研究於完成分群後，統計各群內真實類別的分布，如表 4.1 所示。

表 4.1: 各群之真實目標類別分布

	群 0	群 1
Pass	619	811
Fail	57	38

可見兩群皆包含 Pass 與 Fail 的樣本，各群皆滿足建立二元分類模型的基本門檻，後續將分別建立各群之分類模型，以觀察不同群之預測表現是否存在差異。為提高實驗結果的可重現性，本研究提供相關環境與主要參數設定如表 4.2 所示。

表 4.2: 分類模型之環境與主要參數設定

項目	設定內容
程式版本	Python 3.12.7
分類模型	XGBClassifier
隨機種子	42
n_estimators	300
max_depth	3
learning_rate	0.1
subsample	0.8
colsample_bytree	0.8
min_child_weight	10
gamma	1.0
reg_lambda	2.0
reg_alpha	0.5
objective	binary:logistic
eval_metric	logloss

4.1.2 各群分類模型之評估結果比較

各群指標的點估計與 95% 信賴區間整理如表 4.3 所示，從中可知，群 0 的 ACC 較低、 FAR 較高，其 $FAR = 0.0468$ 約為群 1 之 $FAR = 0.0099$ 的 4.73 倍，而 $ROC - AUC$ 則是群 0 較高。顯示不同群的分類正確率、錯誤回報率及整體排序能力存在差異，故整體資料存在異質性。

因此若未做分群而只使用整體資料，可能會把不同群在分類時的判斷依據被稀釋掉，使後續局部範圍內的模型分類判斷更複雜，進而影響局部刻劃的擬合效果與解釋一致性。

表 4.3: 各群分類模型評估指標之點估計與 95% 信賴區間

群名	樣本數	ACC	FAR	$ROC - AUC$
全體	1525	0.9272 [0.9141, 0.9397]	0.0189 [0.0120, 0.0264]	0.6623 [0.6054, 0.7178]
群 0	676	0.8846 [0.8595, 0.9083]	0.0468 [0.0308, 0.0639]	0.6983 [0.6308, 0.7631]
群 1	849	0.9482 [0.9329, 0.9623]	0.0099 [0.0037, 0.0172]	0.6224 [0.5228, 0.7171]

4.1.3 各群中接近決策邊界之樣本

表 4.4 列出群 0 和群 1 中模型輸出機率最接近 0.5 的前 30 個樣本，從中可知，兩群中皆存在輸出機率接近決策邊界的樣本，其中又以群 0 符合門檻的樣本數多於群 1。

依門檻 $|\hat{p}-0.5| \leq 0.05$ 篩選後，群 0 共有 12 個樣本符合門檻，其樣本編號為 82、225、44、144、345、298、484、105、111、247、653 與 109；群 1 共有 7 個樣本符合門檻，其樣本編號為 1158、990、1361、1189、1187、458 與 1054；後續皆作為各群局部刻劃中心點建立之依據。

表 4.4: 模型輸出機率最接近 0.5 的樣本摘要（由近到遠）

群 0			群 1		
樣本編號	$\hat{p}$	$ \hat{p}-0.5 $	樣本編號	$\hat{p}$	$ \hat{p}-0.5 $
82	0.498364	0.001636	1158	0.493004	0.006996
225	0.516134	0.016134	990	0.513882	0.013882
44	0.481022	0.018978	1361	0.521811	0.021811
144	0.527558	0.027558	1189	0.473835	0.026165
345	0.470658	0.029342	1187	0.528723	0.028723
298	0.468458	0.031542	458	0.464450	0.035550
484	0.533517	0.033517	1054	0.540420	0.040420
105	0.458454	0.041546	1254	0.421225	0.078775
111	0.457258	0.042742	1116	0.581546	0.081546
247	0.544061	0.044061	995	0.415044	0.084956
653	0.548375	0.048375	866	0.404468	0.095532
109	0.548989	0.048989	1108	0.395613	0.104387
359	0.436062	0.063938	1410	0.388741	0.111259
292	0.570125	0.070125	1009	0.357085	0.142915
20	0.570457	0.070457	1233	0.353403	0.146597

4.2 各群局部刻劃模型之建立與結果分析

本節呈現各群局部刻劃模型之結果。依研究方法與流程之特徵選擇程序，群 0 與群 1 分別有 96 個與 56 個特徵於 50 次實驗中於最終輪皆被保留，故後續以這些特徵作為局部線性模型之擬合的自變數；以局部格子點對應之模型輸出機率作為應變數。

首先，表 4.5 彙整重複隨機抽取局部格子點後，各群的局部線性模型決定係數 R^2 之點估計及其 95% 信賴區間。結果顯示，群 0 與群 1 之 R^2 點估計分別為 0.584160 與 0.592644，表示局部線性模型對各群的分類模型輸出在局部範圍之變異皆可解釋約六成。此外，兩群的信賴區間皆十分集中，表示局部線性模型在各自固定的中心點、局部範圍與特徵下具有一定的穩定性。

表 4.5: 局部線性模型決定係數 R^2 之點估計與 95% 信賴區間

群名	點估計	95% 信賴區間
群 0	0.584160	[0.583563, 0.584737]
群 1	0.592644	[0.590905, 0.594560]

再者，表 4.6 與表 4.7 分別列出群 0 與群 1 之單次擬合局部線性模型中，依係數絕對值由大到小排序的前 30 個特徵及其係數。由表可之，兩群在局部範圍內具有不同的主要影響特徵，其中，群 0 以 x291、x7、x141、x87 與 x217 等特徵的影響性較大；群 1 則以 x386、x117、x420、x456 與 x28 等特徵較大。就係數分布而言，各群僅少數特徵具有較大的係數絕對值，其餘特徵的影響相對有限。

表 4.6: 群 0 之局部刻劃模型係數摘要（依係數絕對值由大到小）

特徵	係數	特徵	係數	特徵	係數
(intercept)	1.005144	x153	0.013929	x554	0.008468
x291	0.034033	x426	0.013283	x324	-0.008034
x7	-0.029912	x588	0.011796	x361	0.007764
x141	-0.028171	x585	0.010932	x247	-0.007745
x87	0.022993	x253	0.009463	x274	-0.007529
x217	0.022274	x144	-0.009319	x282	-0.007520
x461	0.019723	x470	0.009020	x525	0.007486
x20	0.017796	x103	-0.008795	x578	-0.006877
x58	-0.015820	x518	-0.008775	x240	0.006598
x1	-0.014731	x358	0.008565	x164	0.006592
x378	0.014099				

表 4.7: 群 1 之局部刻劃模型係數摘要 (依係數絕對值由大到小)

特徵	係數	特徵	係數	特徵	係數
(intercept)	0.996643	x8	0.004151	x196	0.002293
x386	0.016675	x92	0.003006	x337	0.002250
x117	-0.012556	x112	-0.002733	x81	0.002090
x420	-0.011799	x288	0.002681	x276	0.001966
x456	0.010252	x252	0.00264	x51	0.001769
x28	-0.009172	x17	0.002646	x355	-0.001724
x36	-0.008981	x347	0.002574	x145	-0.001689
x287	-0.007539	x82	0.002374	x431	0.001613
x103	-0.006848	x551	-0.002365	x571	-0.001550
x583	0.005797	x497	0.002339	x247	0.001472
x184	0.005055				

最後，本研究進一步評估局部線性模型在跨群時的表現，以觀察某群所建立的局部刻劃模型，在另一群的局部範圍是否仍具有良好的擬合度。重抽 1 萬點做評估後的結果如表 4.8 所示，並以決定係數 (R^2) 及相關係數 (ρ) 作為評估指標。其中， $f_c(\mathbf{x}_m^d)$ 表示第 c 群分類模型對第 d 群局部格子點 $\mathbf{x}_m^d$ 所輸出的 Fail 預測機率； $g_c(\mathbf{x}_m^d)$ 表示第 c 群所建立之局部線性模型，對第 d 群局部格子點 $\mathbf{x}_m^d$ 所輸出的預測分數，其中 $c, d \in \{0, 1\}$ ， $\mathbf{m}$ 為局部格子點索引。

表 4.8: 各群的局部線性模型於群內與跨群套用下之評估結果

設置	R^2	ρ
$f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$	0.584211	0.764337
$f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$	0.642828	0.801765
$f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$	-4.153173	0.217520
$f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$	-2.024091	0.051963

結果顯示，當群 0 所建立的局部線性模型套用至群 1 的局部範圍時，其 $R^2 = -4.1532$ 、 $\rho = 0.2175$ ；反之，當群 1 所建立的局部線性模型亦套用至群 0 的局部範圍時；其 $R^2 = -2.0241$ 、 $\rho = 0.0520$ 。相較於各群模型在原本的局部範圍內可取得約六成左右的 R^2 與較高的相關係數，跨群套用後的 R^2 皆轉為負值，且相關係數亦明顯下降至兩成或接近 0，顯示模型跨群後，已無法有效刻劃另一群分類模型輸出的關係。

綜合而言，兩群的局部模型在跨群後皆明顯失去解釋力，顯示各群的分

類模型在局部範圍內進行決策時所依賴的特徵結構並不一致，其局部範圍的決策具有群間差異。此結果說明局部刻劃模型具有明顯的區域性，因此不宜將某一群所建立之局部解釋直接套用至另一群。亦與前述分群的分析結果相互呼應，表示資料中的異質性不僅反映於整體分類表現，亦反映於各群局部刻劃模型的重要特徵組成與影響方向。



Chapter 5

結論

5.1 總結

本研究建立一套從資料前處理、分群、分類模型建構，到局部線性模型擬合的分析流程。透過選取接近決策邊界的樣本來建立中心點，並於中心點附近作為局部範圍內生成的格子點，以降低外插風險，再利用局部線性模型來近似分類模型在該範圍內的輸出函數，以掌握模型的局部決策行為。研究結果顯示：

1. 整體資料中可能存在資料結構上具有差異的子群。以具高維度、高缺失性且類別不平衡的半導體製程資料 SECOM 資料為例，本研究比較整體建模與與分群後建模之結果，發現資料在 PCA 降維投影空間中呈現群與群之間的差異，且各群在分類表現指標上亦存在差異。此結果顯示，先對資料進行分群，有助於將原本具有異質性的整體資料加以區分，使得後續在分類模型與局部線性模型的建立能在較一致的群內進行，進而提升局部刻劃結果的穩定性與可解釋性。
2. 在各群內分別建立分類模型及其對應的局部線性模型後，可觀察到各群的重要特徵及其影響大小和方向並不相同，顯示不同子群在局部的決策行為上存在明顯差異。此結果說明，若僅以整體模型進行解釋，容易忽略群與群之間在決策行為上的差異，因而降低模型在局部的決策行為之掌握程度，
3. 本研究所建立的局部線性刻劃模型，可在分類模型之外提供局部範圍

內較明確的特徵影響資訊，使原本難以直接說明的模型分類結果，可以轉化為由係數方向與大小所表示的決策描述。相較於僅關注模型分類的準確率之分析方式，本研究更進一步說明分類模型在特定局部範圍內是如何做出分類的判斷，有助於提升模型在半導體製程資料分析中的可解釋性與提升其應用價值。

5.2 未來工作



Bibliography

- Bengio, Y. and Grandvalet, Y. (2004). No Unbiased Estimator of the Variance of K-Fold Cross-Validation. *Journal of Machine Learning Research*, 5(Sep), 1089–1105. <https://www.jmlr.org/papers/v5/grandvalet04a.html?92f58540>.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>.
- Chen, T. and Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>.
- Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>.
- Hubert, M., Rousseeuw, P. J., and Vanden Branden, K. (2005). ROBPCA: A New Approach to Robust Principal Component Analysis. *Technometrics*, 47(1), 64–79. <https://doi.org/10.1198/004017004000000563>.
- Lundberg, S. and Lee, S. (2017). A Unified Approach to Interpreting Model Predictions. (arXiv:1705.07874). arXiv. <https://doi.org/10.48550/arXiv.1705.07874>.
- McCann, M. and Johnston, A. (2008). Secom. UCI Machine Learning Repository, <https://doi.org/10.24432/C54305>.

- Park, H., Koo, Y., Yang, H., Han, Y., and Nam, C. (2024). Study on Data Pre-processing for Machine Learning Based on Semiconductor Manufacturing Processes. *Sensors*, 24(17), 5461. <https://doi.org/10.3390/s24175461>.
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). 「Why Should I Trust You?」: Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144. <https://doi.org/10.1145/2939672.2939778>.
- Troyanskaya, O., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., and Altman, R. B. (2001). Missing value estimation methods for DNA microarrays. *Bioinformatics*, 17(6), 520–525. <https://api.semanticscholar.org/CorpusID:1105917>.
- 賴立夫 (2022). 使用 KNN 和決策樹方法對填補缺失值的製造數據進行失效預測和原因追蹤分析. <https://hdl.handle.net/11296/ub6st3>.

