

國立東華大學 應用數學系

統計碩士班

碩士論文

指導教授：曹振海 博士

中文論文標題

English Title



研究生：黃丞暘 撰

中華民國 115 年 X 月



這頁放審定書





這頁放原創性聲明書





致謝

這頁寫致謝內容



國立東華大學應用數學系統計碩士班 黃丞暘 謹致
民國 115 年 X 月



摘要

這頁寫中文摘要



關鍵字：關鍵字 1、關鍵字 2、關鍵字 3



Abstract

這頁寫英文摘要



Keywords: keyword 1, keyword 2, keyword 3



Contents

1	緒論	1
1.1	研究背景與動機	1
1.2	研究問題與既有方法限制	1
1.3	研究目的與方法概述	1
1.4	研究貢獻	1
1.5	章節介紹	1
2	研究資料	2
2.1	資料背景	2
2.2	資料前處理	2
2.2.1	目標變數與資料切分單位	3
2.2.2	缺失值與特徵保留	3
2.2.3	重複特徵	3
2.2.4	補值	3
2.2.5	極端值處理	3
2.2.6	類別不平衡	3
3	研究方法	5
3.1	流程與問題設定	5
3.2	資料處理與分群標記建立流程	6
3.3	降維	7
3.3.1	主成分分析 (Principal Component Analysis)	7
3.4	分群	7
3.4.1	k-平均演算法 (k-means)	7
3.5	重抽樣	8

3.5.1	合成少數過度取樣技術 (Synthesized Minority Over-sampling Technique)	8
3.6	黑箱模型	8
3.6.1	極限梯度提升 (Extreme Gradient Boosting)	8
3.7	局部擾動 (Lattice cube)	9
3.8	局部模型 (Local surrogate)	9
3.9	實驗設計與交叉驗證	9
3.10	評估指標	9
3.10.1	黑箱分類效能	10
3.10.2	局部代理擬合品質	10
4	研究結果	11
4.1	分群結果	11
4.2	黑箱預測	11
4.3	關鍵案例分析	11
4.4	討論與限制	11
5	結論	12
5.1	總結	12
5.2	未來工作	12





Chapter 1

緒論

- 1.1 研究背景與動機
- 1.2 研究問題與既有方法限制
- 1.3 研究目的與方法概述
- 1.4 研究貢獻
- 1.5 章節介紹

第二章介紹研究資料與前處理；第三章說明研究方法，包含分群、黑箱模型、局部擾動與局部代理模型；第四章呈現實驗結果與案例分析；第五章總結研究結論與未來工作方向。

Chapter 2

研究資料

2.1 資料背景

本研究使用半導體製程量測資料—SECOM 作為分析對象，源自 (McCann, M., et al, 2010)。資料以單一樣本為單位，共 1567 筆；每筆樣本包含一個時間欄位 (Time, 範圍自 2008-01-08 02:02:00 至 2008-12-10 18:47:00)、590 個已匿名化的量測變項 (以 x_1 至 x_{590} 表示)，以及一個品質結果欄位 (二元變數, Pass/Fail) 作為目標變數，其中 Fail (-1) 共 1463 筆 (93.36%)，Pass (1) 共 104 筆 (6.64%)，存在明顯的類別不平衡。且存在缺失值問題，整體缺失率為 4.54%，但缺失分佈不均，部分特徵缺失筆數極高，單一特徵最高缺失達 1429 筆 (91.19%)，且有 20 個特徵之缺失筆數超過 1000 筆 (占樣本數 63.82% 以上)。本研究的目的是：在高維、缺失嚴重且類別不平衡的情境下，先以分群切分資料結構，再以黑箱分類模型學習品質結果，並在群內建立局部 linear surrogate 以描述可解釋的分析 (後續章節說明)。

2.2 資料前處理

本節說明資料清理與特徵處理流程。

2.2.1 目標變數與資料切分單位

為方便辨識將目標欄位 Pass (1)、Fail (-1)，轉為 Pass (1)、Fail (0)。時間欄位 Time 不作為模型特徵，於建模前移除。

2.2.2 缺失值與特徵保留

製程量測資料常見大量缺失，本研究資料亦不例外。為避免高度缺失的特徵在直接補值後造成誤差，本研究以「單一特徵的缺失筆數」作為篩選指標，先移除缺失筆數高於門檻的特徵；同時，亦發現特徵中出現近乎常數或取值種類極少的欄位，對分類模型貢獻有限，以「特徵的不同數值」作為篩選指標，移除特徵數值種類低於門檻的特徵。

2.2.3 重複特徵

為避免模型被冗餘特徵影響，本研究以欄位（特徵）完全相同作為判準並移除，只保留首次出現者。

2.2.4 補值

保留上述處理在門檻內的特徵後，再進行補值。此處採用 KNN 補值 (KNNImputer)，以鄰近樣本的距離加權估計缺失值，使補值結果可反映整體資料結構，具有足夠變異的特徵供後續建模。

2.2.5 極端值處理

資料為高維且單位不一致，若以原始空間判別離群點並不穩定；因此先以 PCA 投影至二維平面觀察整體樣貌，並在 PCA 平面上以明確門檻規則移除極端點。移除後重新編號樣本索引，以確保後續分群與交叉驗證索引一致。

2.2.6 類別不平衡

前面有提到資料存在類別不平衡的問題，Fail (-1) 共 1463 筆，佔整體的 93.36%，Pass (1) 共 104 筆，佔整體的 6.64%，為避免模型分類偏向

多數類別，於訓練折內採用重抽樣策略（如 SMOTE）及其放置位置（僅限訓練資料內），以避免資料洩漏。



Chapter 3

研究方法

本章節將說明本研究之方法流程，包含分群、黑箱分類模型、局部資料生成、局部代理模型建構，同時提供實驗環境與評估指標以確保結果具可重現性與可比較性。

3.1 流程與問題設定

本研究以高維製程量測特徵 $X \in \mathbb{R}^{N \times p}$ 與二元品質標記 $y \in \{0, 1\}^N$ 為基礎，目標為同時達成（1）品質預測（2）局部可解釋性分析。整體流程如下：

1. 資料前處理後取得特徵矩陣 X 與標記 y 。
2. 對 X 進行分群，得到群標記 $c \in \{0, 1, \dots, C-1\}^N$ 。
3. 於各群 c 內訓練黑箱分類器 $f_c(\cdot)$ ，輸出機率 $\hat{p}_c(x) = P(y = 1 \mid x, c)$ 。
4. 於各群內挑選 $\hat{p}_c(x) \approx 0.5$ 的代表點集合，定義局部中心點 x_0 。
5. 以 lattice cube 於 x_0 周圍生成局部設計點，並以黑箱輸出作為標記建立局部代理模型 $g(\cdot)$ 。
6. 以分類效能與局部擬合指標彙整結果，並進行關鍵案例分析。

3.2 資料處理與分群標記建立流程

本研究將原始資料記為 D_1 。由於資料呈現高維度、缺失嚴重且類別不平衡等特性，若直接以距離為基礎進行分群，群中心容易受到少數極端點與多數類別主導，造成分群結構不穩定，且少數類別在分群目標中被弱化。

為提升分群的穩定性並使少數類別在分群過程中具有足夠影響，本研究採以下流程建立最終分群標記，並將分群結果回填至真實樣本資料以供後續建模使用：

1. **初步降維與分群 (D_1)**：對 D_1 進行 PCA 投影至二維平面，並於該平面以 k-means 進行初步分群，用於檢視資料幾何結構與辨識極端樣本。
2. **極端樣本剔除 (得到 D_2)**：於 PCA 二維平面中，依主成分座標之門檻規則辨識遠離主要資料雲之樣本並予以剔除，得到去除極端樣本後的資料 D_2 。此步驟目的在於避免少數遠離點拉動 k-means 群中心位置，影響後續分群結構。
3. **以 SMOTE 調整類別權重 (得到 D_3)**：由於 D_2 之目標類別分佈高度不平衡，若直接以 k-means 最小化群內平方誤差，分群結果傾向由多數類別主導。因此本研究於 D_2 上使用 SMOTE 產生少數類別的合成樣本，得到類別較為平衡之資料 D_3 。需注意，SMOTE 僅用於調整分群時的樣本分佈（等價於調整類別在距離目標中的權重），並不作為後續分類模型之訓練資料來源。
4. **在 D_3 上建立最終分群 (取得質心與群標記規則)**：對 D_3 進行 PCA 與 k-means 分群，取得分群質心（或其對應的指派規則），使分群結果能反映少數類別在資料結構中的區域性特徵，而不被多數類別完全主導。
5. **移除合成樣本並回到真實資料 (D_2 含 clusters)**：將 D_3 中由 SMOTE 生成之合成樣本移除，回到真實樣本資料 D_2 ，並以先前在 D_3 所建立之分群質心/指派規則，為 D_2 中每一筆真實樣本賦予群標記，得到最終資料 D_2 (含 clusters)，供後續黑箱模型與群內局部代理模型建構使用。

為避免評估偏誤，凡涉及參數估計或結構學習之步驟（如標準化、PCA、k-means 與 SMOTE）僅可在訓練資料（或交叉驗證之訓練折）上進行，再將其轉換與指派規則套用至驗證/測試資料。

3.3 降維

本研究資料屬於高維度的特徵空間，若直接在原始高維空間進行計算，則容易受到尺度差異、雜訊影響，使得後續分群結果不穩定。因此，本研究先以降維方法建立可觀察的二維平面。

3.3.1 主成分分析 (Principal Component Analysis)

主成分分析 (PCA) 是機器學習的非監督式降維方法，利用正交線性轉換將原始特徵表示為相互正交的主成分，使得前幾個主成分能保留原始數據中較大的變異量。在本研究中，PCA 主要用於 (1) 將高維資料投影至低維空間以進行視覺化檢視與極端值辨識；(2) 作為後續分群的輔助，以降低高維空間的距離度量不穩定所造成的干擾。

3.4 分群

本研究採用分群以處理資料異質性，將原始樣本依特徵空間的結構切分為多個子群，使後續黑箱模型可在群內學習較一致的決策邊界。令分群演算法輸出 c_i 為第 i 筆樣本之群標記，並以 $X_c = \{x_i : c_i = c\}$ 表示第 c 群之樣本集合。

3.4.1 k-平均演算法 (k-means)

k-平均演算法 (k-means) 是機器學習的非監督式分群方法，將數據集劃分為 k 個不同的群組 (clusters)，目標為使群內平方誤差最小，使群內資料點相對集中、群間差異相對明顯，其做法為給定群數 k 以及自資料點中隨機選取群中心的情況下，不斷進行：(1) 將每個資料點指派至最近的群中心；(2) 更新群中心為群內資料點的平均值，直到收斂。本研究以手肘法 (elbow method) 評估不同群數 k 下之群內平方誤差 (within-cluster sum of

squares, WCSS)，選取誤差下降趨勢開始趨緩之轉折點作為群數，最終採用 $k = 2$ 進行分群。

3.5 重抽樣

3.5.1 合成少數過度取樣技術 (Synthesized Minority Oversampling Technique)

合成少數過度取樣技術 (SMOTE) 是在機器學習中解決數據類別不平衡問題的常見方法，透過生成新的合成少數類別樣本來平衡數據集，核心概念在利用少數類樣本的鄰近樣本，並在彼此之間插值產生新的樣本點。本研究中，SMOTE 僅用於第 ?? 節所述之分群標記建立流程，以調整分群時的樣本分佈，並不作為後續分類模型之訓練資料來源。

3.6 黑箱模型

本研究使用梯度提升樹模型作為黑箱分類器，於各群內分別訓練以捕捉非線性關係；黑箱模型輸出為類別機率，用於後續局部代理模型的近似目標。黑箱模型於第 c 群定義為 $f_c: \mathbb{R}^p \rightarrow [0, 1]$ ，其輸出

$$\hat{p}_c(x) = f_c(x) = P(y = 1 \mid x, c)$$

並以 $\hat{y} = \mathbb{I}(\hat{p}_c(x) \geq t)$ 產生分類結果，其中 t 為分類門檻。

3.6.1 極限梯度提升 (Extreme Gradient Boosting)

極限梯度提升 (XGBoost) 是一種監督式機器學習，基於梯度提升決策樹，作為解決迴歸、分類等問題而設計，透過並行計算和多種優化，在 Kaggle 等機器學習競賽中亦表現出色，應用的領域有數據科學競賽、推薦系統、金融、生物基因等。在本研究中，主要用於半導體資料的分類問題，在分好的群建立模型

3.7 局部擾動 (Lattice cube)

局部代理模型的目的為在 x_0 附近以簡單模型近似黑箱函數。首先於各群內選取黑箱輸出接近 0.5 的樣本集合 $\mathcal{I}_0 = \{i : \hat{p}_c(x_i) \approx 0.5\}$ ，並以其平均作為中心點 $x_0 = \frac{1}{|\mathcal{I}_0|} \sum_{i \in \mathcal{I}_0} x_i$

為避免量綱影響，於標準化空間生成格點。令標準化轉換為 $S(\cdot)$ ，則 $z_0 = S(x_0)$ 。給定步長（半徑） $\delta > 0$ 與層數 $k \in \mathbb{N}$ ，定義偏移集合 $\mathcal{M} = \{-k, -k+1, \dots, k\}^p$ 並生成局部設計點（標準化空間） $z(m) = z_0 + \delta m$, $m \in \mathcal{M}$

再映射回原始空間 $x(m) = S^{-1}(z(m))$ ，並以黑箱模型計算局部標記 $y^{\text{bb}}(m) = \hat{p}_c(x(m))$

當完整格點數 $(2k+1)^p$ 過大時，以抽樣方式自 $\mathcal{M}$ 取子集以控制局部樣本數。

3.8 局部模型 (Local surrogate)

以局部設計點之標準化表示 $z(m)$ 作為解釋變數，以黑箱輸出 $y^{\text{b}}(m)$ 作為反應變數，建立局部線性代理模型 $g(z) = \beta_0 + \beta^\top z$ 。係數 β 反映在 x_0 鄰域內黑箱輸出對各特徵方向之局部敏感度；同時保留 z 空間係數以避免尺度混淆，並可再依 $S(\cdot)$ 轉回原始尺度進行詮釋。

3.9 實驗設計與交叉驗證

本研究將資料切分為訓練集與測試集，測試集不參與模型訓練；並於訓練集進行 K 折交叉驗證以估計泛化能力，同時固定隨機種子以確保結果可重現。分群後之評估採「群內交叉驗證」：對每一群 c 的樣本索引集合分別進行分層抽樣交叉驗證，並彙整各群之 out-of-fold (OOF) 預測機率與混淆矩陣。

3.10 評估指標

本研究評估分為兩類：黑箱分類效能與局部代理擬合品質。

3.10.1 黑箱分類效能

3.10.2 局部代理擬合品質



Chapter 4

研究結果

4.1 分群結果

4.2 黑箱預測

4.3 關鍵案例分析

4.4 討論與限制



Chapter 5

結論

5.1 總結

5.2 未來工作



Bibliography

