

國立東華大學 應用數學系

統計碩士班

碩士論文

指導教授：曹振海 博士

中文論文標題

English Title



研究生：黃丞暘 撰

中華民國 115 年 X 月



這頁放審定書





這頁放原創性聲明書





致謝

這頁寫致謝內容



國立東華大學應用數學系統計碩士班 黃丞暘 謹致
民國 115 年 X 月



摘要

這頁寫中文摘要



關鍵字：關鍵字 1、關鍵字 2、關鍵字 3



Abstract

這頁寫英文摘要



Keywords: keyword 1, keyword 2, keyword 3



Contents

1	緒論	1
1.1	研究背景與動機	1
1.2	研究問題與既有方法限制	2
1.3	研究目的與方法概述	3
1.4	研究貢獻	3
1.5	章節介紹	4
2	研究資料	5
2.1	資料背景	5
2.2	資料前處理	5
2.2.1	目標變數與資料切分單位	6
2.2.2	缺失值	6
2.2.3	少數類別特徵	6
2.2.4	補值	7
2.2.5	極端值處理	8
2.2.6	前處理後最終資料集摘要	9
3	研究方法與流程	10
3.1	流程大綱	10
3.2	流程細部	10
3.2.1	資料降維與分群	11
3.2.2	黑箱模型訓練	12
3.2.3	中心點選取與局部生成格子點擬合模型	13

4	研究結果	15
4.1	分群建立黑箱	15
4.2	分群黑箱的預測	16
4.3	關鍵案例分析	18
4.3.1	群 0 (cluster_0)	18
4.3.2	群 1 (cluster_1)	19
4.4	討論與限制	20
5	結論	21
5.1	總結	21
5.2	未來工作	21





Chapter 1

緒論

1.1 研究背景與動機

隨著科技時代的發展與進步，半導體製程亦朝向高精密與高複雜度的方向發展，尤其在製造端，它們在各據點已累積大量製程與量測資料。這些資料被用來監控製程狀態，以降低不良品產出。

在半導體製程中，良率是最直接且重要的品質指標之一，良率的提升不只影響出貨與成本，亦影響產線資源配置與製程改善的狀況。因此，如何透過資料分析建立品質預測模型，一直是製造過程與品質管制的重要課題。

近年來，多項研究使用機器學習方法進行品質的預測及分類，並以準確度等指標比較模型表現。然而在實務情境中，僅有準確度往往不足以支援製程的決策。工程部門更關心的是：模型為何判斷結果為不良，或者哪些製造過程及變數對預測具有影響性。

尤其在非線性的模型當中，模型雖然能透過大量計算以捕捉其中複雜的關係，但其判斷的機制不容易由參數的設定而直接地理解，形成所謂的黑箱問題。此外，半導體製程資料內容大都具有高缺失率、大量變數、類別高度不平衡等狀況，使得預測結果可能受到訓練模型方法的順序或參數設定影響，進而降低在工程上的可用性。

基於上述原因，本研究建立一套可在黑箱模型中，提供局部且可解釋性的分析方法，使品質預測不僅只看分類結果的好壞，亦能轉為對製程判斷與改善上具有參考價值的資訊。

1.2 研究問題與既有方法限制

本研究以 UCI Machine Learning Repository 之 SEmi COnductor Manufacturing (SECOM) 資料集作為研究素材 UCI Machine Learning Repository (2008)。該資料集提供半導體製程量測變數，並對各樣本標記 Pass 或 Fail 的二元類別。資料除了具有高維度與高缺失值等等特性外，不同樣本亦可能對應不同的製程狀態，使資料在統計分佈上呈現異質性。因此常做為製程品質預測與前處理方法的基準資料集 Park et al. (2024)。

在既有的研究中，賴利夫 (Lai, 2022) 以 SECOM 為例，透過補值、特徵篩選與決策樹建立分類模型，並利用決策樹的節點結構追溯影響模型分類的關鍵變數 Lai (2022)，此類方法的優點是模型本身具可解釋性，但是當使用的資料量不大且形態呈現高維變量時，單以少數層數的決策樹作為可解釋模型的表達能力可能不足，因此實務上常改用表現較強的黑箱模型作為分類基準。

例如樹模型與梯度提升方法常在高維度的資料上取得較佳表現，其中以 XGBoost 為代表的梯度提升樹模型常被作為高維度資料的強基準分類模型 Chen and Guestrin (2016)。然而，僅追求預測準確度不足以支援實務上的決策；當模型為黑箱時，仍需額外方法說明單一樣本被分類時的特徵的依據。

而在可解釋性方法層面，SHAP 建立在合作賽局理論的 Shapley value 觀點上，將單一樣本分類分解為各特徵貢獻度的加法表示，同時可用於整體樣本的彙整比較。並可用於黑箱模型的事後解釋，以量化特徵對預測輸出的影響 Lundberg and Lee (2017)。可以應用於不同的數據類型，包括文字、表格資料和影像。

LIME 則以「局部可解釋」為目標，在欲解釋樣本附近生成擾動樣本，並以距離為權重給予相鄰的樣本較高權重，再以簡單的線性模型近似黑箱在局部的分類行為，以提供單一樣本被分類時的局部解釋 Ribeiro et al. (2016)。

然而，在製程資料的高維與異質性的情況下，上述的局部解釋方法在實作上仍可能不穩定，主要來自兩個原因。

第一，製程資料可能存在多種製程狀態，亦即混合的子群結構。若以單一黑箱模型描述全體樣本，其決策邊界可能同時存在多種不同的規則，則對單一樣本的局部解釋，得到的可能是混合後的分類標準，導致局部解釋

在不同樣本間缺乏可比性。因此，本研究先以分群切分資料，在群內建立黑箱分類模型與局部刻劃模型，以降低資料的異質性干擾對單一模型學習與解釋穩定性的影響。

第二，在高維空間中，以隨機擾動的方式生成鄰近樣本時，樣本容易偏離真實資料分佈，使局部刻劃模型可能在外插的區域擬合，導致解釋與實際資料機制不一致。因此，本研究在群內另外定義局部的範圍與擾動的方式，降低外插可能造成的偏誤，並以可檢視的局部刻劃模型評估。

綜合以上，本研究聚焦於兩個核心問題：

(1) 面對製程資料的異質性，如何以分群切分後在群內建立黑箱分類模型，使其決策規則與後續解釋在群內具可比性。

(2) 在不產生明顯的外插風險下，如何在群內建立可檢視的局部刻劃模型，提供局部的可解釋性。

1.3 研究目的與方法概述

本研究的目的為：在高維、缺失嚴重且類別不平衡的情境下，先以分群切分資料結構，於群內建立可檢視的局部線性刻劃模型，提供單一樣本在分類上的局部可解釋之依據。同時，我們建立一個「分群一群內黑箱一群內局部刻劃」的流程。

首先，對樣本進行分群以切分資料為若干子群，接著於各群內訓練黑箱分類模型，並輸出每筆樣本的預測機率。

本研究以接近分類閾值（即決策邊界附近）的樣本作為局部刻劃的代表點，在代表點附近建立具結構性的格子點，控制取樣範圍並降低外插風險，後續以指標來檢視模型在局部刻劃的結果。

1.4 研究貢獻

本研究的主要貢獻如下：

1. 建立以分群各自建立黑箱模型的建模流程，以處理製程資料的異質性。
2. 設計局部資料的格子點生成方法，以提升局部模型擬合的可解釋性。

3. 提出以決策邊界區域為目標的局部刻劃框架，使黑箱輸出轉化為可解釋的局部特徵。

1.5 章節介紹

第二章介紹研究資料與前處理；第三章說明研究方法與流程，包含分群、黑箱模型、局部刻劃模型；第四章呈現實驗結果與案例分析；第五章總結研究結論與未來工作方向。



Chapter 2

研究資料

2.1 資料背景

本研究使用半導體製程量測資料－SECOM 作為分析對象 UCI Machine Learning Repository (2008)，共 1567 筆；每筆樣本包含一個時間欄位 (Time, 範圍自 2008-01-08 02:02:00 至 2008-12-10 18:47:00)、590 個已匿名化的量測變項 (以 x_1 至 x_{590} 表示)，以及一個品質結果欄位 (二元變數, Pass/Fail) 作為目標變數，其中 Pass (−1) 共 1463 筆 (93.36%)，Fail (1) 共 104 筆 (6.64%)，存在明顯的類別不平衡，同時存在缺失值問題，整體缺失率為 4.54%，但缺失分佈不均，部分特徵缺失筆數極高，單一特徵最高缺失達 1429 筆 (91.19%)，且有 20 個特徵之缺失筆數超過 1000 筆 (占樣本數 63.82% 以上)。

表 2.1: SECOM 原始資料集摘要

idx	Time	x_1	x_2	x_3	...	x_{588}	x_{589}	x_{590}	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1

2.2 資料前處理

本節說明資料清理與特徵處理流程。




圖 2.2: SECOM 原始資料各變數相異值數量分佈

2.2.4 補值

保留上述處理在門檻內的特徵後，再進行補值。本研究採用 KNN 補值 (k -Nearest Neighbors Imputer, KNN imputer)，其核心概念為：對於一個缺失值，在樣本空間中尋找與該樣本距離最近的 k 個鄰近樣本，再以鄰近樣本在該特徵上的觀測值進行距離加權平均，以估計缺失值。

設樣本 i 在第 j 個特徵的缺失值為 x_{ij} ，則欲估計的缺失值定義為：

$$\hat{x}_{ij} = \frac{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r) x_{rj}}{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r)}$$

其中 $\mathcal{N}_k(i,j)$ 表示在「第 j 個特徵有觀測值」的樣本中，與樣本 i 距離最近的 k 個鄰近樣本的集合（本研究設定 $k = 10$ ）；並且採用距離反比作為權重，令 $w(i,r) = 1/d(i,r)$ 。距離 $d(i,r)$ 依照 nan-euclidean distance（缺失值下的歐式距離）定義為

$$d(i,r) = \left(\frac{p}{|\Omega_{ir}|} \sum_{\ell \in \Omega_{ir}} (x_{i\ell} - x_{r\ell})^2 \right)^{1/2}$$

其中 Ω_{ir} 為樣本 i 與樣本 r 同時具有觀測值的特徵集合。 $|\Omega_{ir}|$ 為其元素個數， p 為特徵總數。

2.2.5 極端值處理

本研究資料屬於高維度的特徵空間，若直接在原始高維空間進行計算，則容易受到尺度差異、雜訊影響，使得後續分群結果不穩定。因此，本研究先以主成分分析 (Principal Component Analysis, PCA) 將高維資料投影至可觀察的二維平面，作為極端值檢視與後續分群的輔助。

PCA 為非監督式降維方法，利用正交線性轉換將原始特徵表示為相互正交的主成分，使得前幾個主成分能保留原始數據中較大的變異量。

在本研究中，PCA 主要用於：

- (1) 將高維資料投影至低維空間，以進行視覺化檢視與極端值辨識；
- (2) 作為後續分群的輔助，以降低高維空間的距離度量不穩定所造成的干擾。

因此，本研究先將資料投影至二維 PCA 平面觀察整體分佈，並以明確的門檻規則移除極端點。移除後重新編號樣本索引，以確保後續分群與交叉驗證索引一致。




圖 2.3: 未移除 PCA 極端值的原始資料之 PCA 投影結果

如圖 2.3 所示，在未移除極端值之前，二維主成分明顯被少數點拉開，使大多數樣本集中於狹小的區域。本研究推測，少數極端值可能在 PCA 投影的估計過程當中造成主導的效果，會影響後續已以距離為基礎的分析產生差距。

我們根據圖 2.3 的分佈，設定主成分門檻規則為 $PC1 \leq 10$ 及 $PC2 \leq 10$ 。於資料重新讀取後，直接刪除未達門檻規則的樣本，並重複同樣的資料前處理與 PCA 步驟，移除疑似的極端值後之二維主成分平

面如圖 2.4 所示。




圖 2.4: 移除 PCA 極端值後的原始資料之 PCA 投影結果

其分佈較均勻，可顯示資料在投影與距離結構上受到極端值干擾的程度降低。

2.2.6 前處理後最終資料集摘要

完成特徵清理、缺失處理與極端值移除後，本研究得到最終分析資料 $(\mathbf{X}, \mathbf{y})$ ，其中 $\mathbf{X} \in \mathbb{R}^{n \times p}$ 為輸入變數， $\mathbf{y} \in \{0, 1\}^n$ 為對應標籤。 n 為樣本數， p 為前處理後之特徵數。為避免不同單位與尺度造成距離計算與模型訓練偏差， $\mathbf{X}$ 已進一步進行標準化處理。

表 2.2 為最終分析資料的預覽表。其中 Pass/Fail 欄位即為標籤 $\mathbf{y}$ 。此時資料已不含缺失值，且於移除極端值後重新編號索引，以確保後續分群、交叉驗證與模型訓練時索引一致。後續章節之分群、群內黑箱模型訓練與局部刻劃分析，皆以此資料集作為輸入。

表 2.2: 資料前處理後之最終資料集

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0

Chapter 3

研究方法與流程

本研究以高維製程量測特徵與二元品質標記為基礎，目標為黑箱在局部的可解釋性分析。本章節將說明本研究用到的方法，降維、分群、黑箱分類模型、局部資料生成、局部代理模型建構，同時提供實驗環境與評估指標以確保結果具可重現性與可比較性。

3.1 流程大綱

1. 資料前處理後取得特徵矩陣 X 與標記 y 。
2. 以 SMOTE 後執行 PCA 的特徵進行分群，後續建模移除合成樣本。
3. 於各群內訓練黑箱分類模型 $f_c(\cdot)$ ，輸出機率 $\hat{p}_c(x)$ 。
4. 於各群內挑選決策邊界附近的代表點集合，取該集合的平均並定義為中心點 x_0 。
5. 於 x_0 附近生成格子點，並經由黑箱輸出的值作為應變數建立多元線性回歸模型 $g(\cdot)$ 。
6. 以多元線性回歸模型的指標彙整結果，並進行關鍵案例分析。

3.2 流程細部

本研究以研究資料 2.2.6 為起點

3.2.1 資料降維與分群

1. 合成少數過度取樣技術用於降維：

由於目標類別分佈高度不平衡，若直接對資料 2.2.6 降維，降維結果傾向由多數類別的資料訊息主導，使少數類別在特徵空間中的結構不容易辨識。因此，本研究先於訓練資料中使用合成少數過度取樣技術（Synthesized Minority Oversampling Technique, SMOTE）產生少數類別的合成樣本。以不改變多數類別分佈的前提下，補足少數類別於降維的特徵空間中的資訊。

SMOTE 是在機器學習中解決數據類別不平衡問題的常見方法，其核心概念為針對每個少數類別的樣本 x_i ，尋找其鄰近樣本 x_{nn} ，並在兩者之間進行插值產生新的樣本點 x_{new} ；其合成樣本的生成式如下。

$$\mathbf{x}_{new} = \mathbf{x}_i + \lambda (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim \text{Uniform}(0, 1)$$

本研究在使用 SMOTE 將少數類別資料增至與多數類別資料相近比例後，接著再使用 PCA 做降維，以降低降維結果被多數類別的訊息主導的情況；其降維視覺化結果如圖 3.1。




圖 3.1: 移除 PCA 極端值後的 SMOTE 資料之 PCA 投影結果

2. 分群建構與合成樣本移除（僅保留真實資料供後續建模）：

本研究採用 k-平均演算法 (k-means) 做分群以處理資料異質性，在 PCA 空間中依照樣本結構將資料切分為數個子群，使後續黑箱模型可在群內學習較一致的決策邊界。

k-means 是機器學習的非監督式分群方法，其做法為給定群數 k 以及自資料點中隨機選取群中心後，不斷進行：(1) 將每個資料點指派至最近的群中心；(2) 更新群中心為群內資料點的平均值，直到收斂。

本研究以手肘法 (elbow method) 評估不同群數 k 下之群內平方誤差 (within-cluster sum of squares, WCSS)，WCSS 定義如下。

$$WCSS(k) = \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2, \quad \boldsymbol{\mu}_i = \frac{1}{|S_i|} \sum_{\mathbf{x} \in S_i} \mathbf{x}$$

其中 S_i 為第 i 群， $\boldsymbol{\mu}_i$ 為該群中心，目標為最小化 WCSS。最後選取下降幅度開始趨緩時的轉折點作為分為 k 群的依據。本研究最終採用 $k = 2$ 進行分群。分群結果如圖 3.2。




圖 3.2: 移除 PCA 極端值後的 SMOTE 資料在 PCA 空間之分群結果

另外，需強調的是：SMOTE 僅用於降維與分群的階段，以改善少數類別在降維空間的資訊；完成分群後，會將合成樣本移除，並保留真實資料集及其原始類別標記，供後續各群內黑箱模型之訓練與評估使用。

3.2.2 黑箱模型訓練

1. 全體與各群內訓練黑箱模型與效能評估：

在全體資料與各群內資料各自訓練一個黑箱模型，以作為後續局部格子點的黑箱輸出函數。本研究採用樹模型中的極限梯度提升

(Extreme Gradient Boosting, XGBoost) 進行二元分類，

XGBoost 為監督式學習方法，基於梯度提升決策樹 (Gradient Boosting Decision Tree)，以加法模型逐步疊加弱學習器 (決策樹)，並透過損失函數的梯度資訊進行更新，同時引入多種優化以提升效能與模型泛化能力，可用於解決迴歸與分類問題，亦是目前最常被使用在 Kaggle 資料分析競賽當中的機器學習模型。

本研究以 (TN, FP, FN, TP) 彙整分類結果，並以此計算分類效能指標，包含 Accuracy(ACC)、誤報率 (False Alarm Rate, FAR)。其定義如下：

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{FAR} = \frac{FP}{FP + TN}$$

ROC-AUC 則以模型輸出機率於不同門檻下所形成之 ROC 曲線面積表示。

此外，對各群內採用五折交叉驗證 (k -fold Cross Validation, $k = 5$)。

設定五折的交叉驗證，其目的在於模型不會僅依據單次切分造成的結果偏差，而是將資料切分成 80% 作為訓練集資料，20% 作為測試集資料，共依序訓練五次 (五折)。其中每一折，僅對訓練集進行 SMOTE 以提升少數類別可分性，測試集則不進行 SMOTE。

本研究同時呈現整體與各群模型的混淆矩陣，以比較整體模型與分群後模型表現之差異。

2. 依各群內交叉驗證之測試集機率挑選樣本：

接著在每一折中，使用該折訓練之模型對測試集資料輸出預測為 Pass 或 Fail 的預測機率值 (介於 0, 1 之間)。彙整五折測試集輸出得到每筆真實樣本的交叉驗證機率值，用於後續挑選欲分析的樣本。

3.2.3 中心點選取與局部生成格子點擬合模型

1. 群內樣本挑選與中心點建立：

如同前一步驟所述，取得預測機率後，於該群內挑選預測機率最接近決策邊界 (例如 0.5) 的前幾筆樣本，並將其標準化後的特徵向量取

平均，作為該群的局部刻劃中心點。

2. 局部格子點生成：

以中心點為基準，設定每一個維度位移的步長 ($\delta = 0.1$) 與位移集合 $m \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$ ，其中 $k = 2$ ，故每一維共有 $(2k+1) = 5$ 個位移的位置，而該資料集的特徵維度為 $p = 459$ 所以完整格子點數量有 $(2k+1)^p$ ，即 5^{459} 個；每一個格子點可視為由中心點加上「步長 δ 乘上位移集合 m 」所形成之鄰域格點。

3. 抽樣做局部線性刻劃與多輪篩選：

本研究雖定義完整格點集合，但實際僅由該集合中隨機抽樣格子點建立局部刻劃模型，且採用多輪門檻的篩選。其過程如下：每一輪抽取固定數量格子點（80 萬筆），以黑箱輸出機率作為應變數，以抽樣格子點的特徵向量作為自變數，採用多元線性迴歸模型 (Ordinary least squares, OLS) 建立局部線性刻劃模型，

OLS 的核心概念為給定自變數 X 與應變數 y 的情況下，以最小殘差平方和 (Residual Sum of Squares) 來估計迴歸係數，即選取使 $\sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2$ 最小的 $\hat{\beta}$ ；當 X 滿秩使 $X^T X$ 可逆時，則 $\hat{\beta} = (X^T X)^{-1} X^T y$ 。

最後根據 p-value 門檻保留通過的特徵；重複上述流程數輪以縮小特徵集合，直到達到預設的輪數或特徵的集合不再變動。

4. 重複實驗與特徵穩定性統計：

為避免只做一次的多輪門檻篩選造成的偶然性，本研究重複進行多次局部抽樣與多輪篩選（50 次），統計各特徵在最後一輪被保留的次數與比例，並彙整其局部係數的平均值與標準誤，作為群內局部解釋結果的穩定性指標。

5. 局部刻劃評估：

最後另外進行重新抽取格子點（200 萬筆），同樣以其黑箱輸出機率作為應變數，從前一步驟結果中的「被保留 50 次」的特徵作為自變數，以 OLS 重新擬合局部線性模型，估計各特徵的係數，並以 R^2 作為該模型對黑箱輸出的擬合度指標，用來觀察黑箱模型在中心點附近的行為。

Chapter 4

研究結果

4.1 分群建立黑箱

我們對資料實施 SMOTE，是為了在降維與分群階段時，以降低少數類別在 PCA 空間中被多數類別的結構主導，導致難以形成可辨識的群集之風險。依 3.2.1 的步驟 2，本研究在完成分群後，隨即移除 SMOTE 所合成的樣本，後續的建模僅用真實資料集，而不包含經由 SMOTE 合成的樣本集。其移除後在 PCA 空間分群後的視覺化結果如圖 4.1。




圖 4.1: 移除 PCA 極端值與合成樣本後的原始資料在 PCA 空間之分群結果

如表 4.2 可知，尚未分群的時，單一模型於整體資料 (ALL, $n = 1525$) 的平均評估為 $ACC = 0.9272$ 、 $FAR = 0.0189$ 、 $ROC-AUC = 0.6636$ ，進一步將樣本分為兩群後，各群模型的平均表現如下：

$cluster_0$ ($n = 676$) 之 $ROC-AUC = 0.6974$ (相對整體提升 0.0338), $FAR = 0.0468$ (相對整體增加 0.0279)、 $ACC = 0.8847$; 相對地

$cluster_1$ ($n = 849$) 之 $ROC-AUC = 0.6266$ (相對整體降低 0.0370), $FAR = 0.0099$ (相對整體降低 0.0090)、 $ACC = 0.9482$ 。

此結果顯示整體資料中存在呈現明顯異質性，尤其是兩群之 FAR 相差約 $0.0468/0.0099 \approx 4.73$ 倍，顯示不同群之錯誤回報程度與可分類程度（以 AUC 衡量）並不一致；若僅以未分群的單一平均指標呈現，將掩蓋高誤報率群體（ $cluster_0$ ）的存在。

表 4.1: 分群後的各群之真實目標類別數目

群	0	1
Pass	619	811
Fail	57	38

表 4.2: 黑箱模型分類之表現：全體與分群比較

group	n	ACC	FAR	ROC-AUC
全體	1525	0.9272	0.0189	0.6636
群 0	676	0.8847	0.0468	0.6974
群 1	849	0.9482	0.0099	0.6266

4.2 分群黑箱的預測

本研究以分群為單位訓練黑箱模型，並在各群內採用 5-fold 交叉驗證取得 out-of-fold (OOF) 之測試集預測機率 p_{test} 。針對 $cluster=0$ ，我們以 $|p_{\text{test}} - 0.5|$ 由小到大排序，選取最接近 0.5 的前 5 個樣本點 (global_idx: 82、225、44、144、345)，其部分特徵、真實標籤 y_{true} 與黑箱輸出 p_{test} 如表 4.3。

表 4.3: 群 0 的黑箱輸出最接近 0.5 的前五個樣本摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
82	-0.921323	-0.263777	...	1.057470	0.172921	0	0.4984
225	0.794818	-1.815294	...	-0.332622	-0.154877	0	0.5161
44	0.367305	2.479558	...	0.779451	0.095199	0	0.4810
144	-1.446410	-0.375622	...	-0.610641	-0.546260	0	0.5276
345	-0.439136	-2.580404	...	-0.402127	0.549533	0	0.4707

表 4.4: 群 1 的黑箱輸出最接近 0.5 的前五個樣本點摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
1158	-0.978433	0.898024	...	-0.645393	-0.554204	0	0.4930
990	0.747317	0.821800	...	-0.089356	-0.360851	0	0.5139
1361	0.514817	0.252607	...	0.223414	-0.494009	1	0.5218
1189	0.575310	-0.470903	...	0.014901	0.332787	1	0.4738
1187	0.760444	-0.100990	...	-0.714898	-0.478764	0	0.5287

為了在決策邊界附近建立局部刻劃的參考中心點，我們取上述 5 個樣本在標準化特徵空間的特徵向量平均，定義

$$x_{center} = \frac{1}{5} \sum_{i \in \{82, 225, 44, 144, 345\}} x_i. \quad (4.1)$$

後續如節 3.2.3 所述方式，以 x_{center} 為中心生成格子點並輸入該群黑箱模型，以取得局部鄰域內的黑箱輸出，如表 4.5 用於後續的局部刻劃分析。

表 4.5: Cluster 0：以 x_{center} 生成之格子點（示例特徵）與黑箱輸出

x1	x2	...	x589	x590	$y_{blackbox}$
-0.328949	-0.511108	...	0.098306	0.023303	0.966755
-0.528949	-0.411108	...	-0.001694	0.223303	0.940804
-0.528949	-0.711108	...	0.098306	0.123303	0.983204
-0.328949	-0.711108	...	0.098306	0.123303	0.889116
-0.228949	-0.611108	...	0.098306	0.123303	0.881310

表 4.6: 群 0 的黑箱輸出最接近 1 的前二個樣本點摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
348	-1.887997	0.224832	...	1.717764	1.004471	0	0.975609
212	-0.692748	1.225590	...	1.787268	0.824068	1	0.848101

表 4.7: 群 1 的黑箱輸出最接近 1 的前二個樣本點摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
1326	2.015375	-0.306746	...	-0.958164	-0.602983	1	0.846026
1056	0.045893	-0.705555	...	-0.054604	-0.222966	0	0.843086

4.3 關鍵案例分析

本節介紹最後的局部線性模型，我們在各群篩選特徵，並建立局部線性模型。是根據 50 次的篩選後，我們統計在最後一輪被篩選到 50 次的特徵，總共有 97 個特徵被篩選到 50 次，並從格子點中隨機抽 200 萬筆，以這些特徵與其黑箱機率值做為擬合線性模型的資料集，

4.3.1 群 0 (cluster_0)

$r^2 = 0.6128$ ，以及各特徵在線性模型上的斜率（特徵係數），如表 4.8，列出前 30 個



表 4.8: Cluster 0 重要特徵 (p 值小到大前 30 個)

feature	coef	p
(intercept)	1.164411	0.000
x11	-0.012369	0.000
x18	-0.012340	0.000
x91	-0.012102	0.000
x578	-0.011193	0.000
x580	-0.009745	0.000
x85	-0.008851	0.000
x113	-0.008834	0.000
x446	-0.012711	0.000
x384	-0.008593	0.000
x317	-0.008226	0.000
x118	-0.008092	0.000
x128	-0.006833	0.000
x9	-0.006802	0.000
x280	-0.006217	0.000
x528	-0.006047	0.000
x486	-0.006024	0.000
x332	-0.008584	0.000
x391	-0.005936	0.000
x36	-0.014250	0.000
x311	-0.014851	0.000
x7	-0.038076	0.000
x58	-0.031087	0.000
x563	-0.030969	0.000
x1	-0.029007	0.000
x274	-0.029081	0.000
x518	-0.027012	0.000
x103	-0.026372	0.000
x581	-0.014603	0.000
x247	-0.020698	0.000

4.3.2 群 1 (cluster_1)

$$r^2 = 0.6368 ,$$

表 4.9: Cluster 1 重要特徵 (p 值小到大前 30 個)

feature	coef	p
(intercept)	1.019421	0.000
x420	-0.017542	0.000
x456	0.001629	0.000
x433	0.001564	0.000
x292	0.001592	0.000
x341	0.001458	0.000
x412	0.001471	0.000
x146	0.001403	0.000
x484	0.001320	0.000
x557	-0.001248	0.000
x369	-0.001415	0.000
x64	0.002007	0.000
x118	-0.001808	0.000
x85	-0.002418	0.000
x500	-0.002933	0.000
x419	-0.003011	0.000
x355	-0.004019	0.000
x56	-0.004285	0.000
x112	-0.004563	0.000
x103	-0.011539	0.000
x287	-0.011932	0.000
x28	-0.013828	0.000
x36	-0.014241	0.000
x551	-0.002193	0.000
x26	0.002127	0.000
x432	0.001746	0.000
x247	0.002301	0.000
x386	0.028210	0.000
x92	0.015615	0.000
x248	0.010597	0.000
x288	0.007676	0.000

結果敘述

4.4 討論與限制

Chapter 5

結論

5.1 總結

5.2 未來工作



Bibliography

- Chen, T. and Guestrin, C. (2016), Xgboost: A scalable tree boosting system, *in* ‘Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)’, pp. 785–794.
- Lai, L.-F. (2022), Use knn and decision tree methods to perform failure prediction and cause tracking analysis on manufacturing data with imputed values, Master’s thesis, National Chung Hsing University.
- Lundberg, S. M. and Lee, S.-I. (2017), A unified approach to interpreting model predictions, *in* ‘Advances in Neural Information Processing Systems’.
- Park, H. J. et al. (2024), ‘Study on data preprocessing for machine learning based on semiconductor manufacturing processes’, *Sensors* **24**(17), 5461.
- Ribeiro, M. T., Singh, S. and Guestrin, C. (2016), “why should i trust you?”: Explaining the predictions of any classifier, *in* ‘Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)’, pp. 1135–1144.
- UCI Machine Learning Repository (2008), ‘Secom’, <https://archive.ics.uci.edu/ml/datasets/SECOM>. Accessed: 2026-02-21.