

國立東華大學 應用數學系

統計碩士班

碩士論文

指導教授：曹振海 博士

中文論文標題

English Title



研究生：黃丞暘 撰

中華民國 115 年 X 月



這頁放審定書





這頁放原創性聲明書





致謝

這頁寫致謝內容



國立東華大學應用數學系統計碩士班 黃丞暘 謹致
民國 115 年 X 月



摘要

這頁寫中文摘要



關鍵字：關鍵字 1、關鍵字 2、關鍵字 3



Abstract

這頁寫英文摘要



Keywords: keyword 1, keyword 2, keyword 3



Contents

1	緒論	1
1.1	研究背景與動機	1
1.2	文獻回顧與研究問題	2
1.3	研究目的與方法概述	3
1.4	研究貢獻	3
1.5	章節介紹	4
2	研究資料	5
2.1	資料背景	5
2.2	資料前處理	5
2.2.1	目標變數與資料切分單位	6
2.2.2	缺失值	6
2.2.3	少數類別特徵	6
2.2.4	補值	7
2.2.5	極端值處理	8
2.2.6	前處理後最終資料集摘要	9
3	研究方法與流程	10
3.1	流程大綱	10
3.2	流程細部	10
3.2.1	資料降維與分群	11
3.2.2	黑箱模型訓練	12
3.2.3	中心點選取與局部生成格子點擬合模型	13

4	研究結果	15
4.1	分群建立黑箱	15
4.2	分群黑箱的預測	16
4.3	關鍵案例分析	18
4.3.1	群 0 (cluster_0)	18
4.3.2	群 1 (cluster_1)	19
4.4	討論與限制	20
5	結論	21
5.1	總結	21
5.2	未來工作	21





Chapter 1

緒論

1.1 研究背景與動機

隨著科技時代的發展與進步，半導體製程亦朝向高精密與高複雜度的方向發展，尤其在製造端，它們在各據點已累積大量製程與量測資料。這些資料被用來監控製程狀態，以降低不良品產出。

在半導體製程中，良率是最直接且重要的品質指標之一，良率的提升不只影響出貨與成本，亦影響產線資源配置與製程改善的狀況。因此，如何透過資料分析建立品質預測模型，一直是製造過程與品質管制的重要課題。

近年來，多項研究使用機器學習方法進行品質的預測及分類，並以準確度等指標比較模型表現。然而在實務情境中，僅有準確度往往不足以支援製程的決策。工程部門更關心的是：模型為何判斷結果為不良，或者哪些製造過程及變數對預測具有影響性。

尤其在非線性的模型當中，模型雖然能透過大量計算以捕捉其中複雜的關係，但其判斷的機制不容易由參數的設定而直接地理解，形成所謂的黑箱問題。此外，半導體製程資料內容大都具有高缺失率、大量變數、類別高度不平衡等狀況，使得預測結果可能受到訓練模型方法的順序或參數設定影響，進而降低在工程上的可用性。

基於上述原因，本研究建立一套可在黑箱模型中，提供局部且可解釋性的分析方法，使品質預測不僅只看分類結果的好壞，亦能轉為對製程判斷與改善上具有參考價值的資訊。

1.2 文獻回顧與研究問題

本研究以 McCann and Johnston (2008) 的 SEmi COnductor Manufacturing (SECOM) 資料集作為研究素材。該資料集提供半導體製程量測變數，並對各樣本標記 Pass 或 Fail 的二元類別。Park et al. (2024) 提到該資料除了具有高維度與高缺失值等等特性外，不同樣本亦可能對應不同的製程狀態，使資料在統計分佈上呈現異質性。因此常做為製程品質預測與前處理方法的基準資料集。

在既有的研究中，賴立夫 (2022) 以 SECOM 為例，透過補值、特徵篩選與決策樹建立分類模型，並利用決策樹的節點結構追溯影響模型分類的關鍵變數，此類方法的優點是模型本身具可解釋性，但是當使用的資料量不大且形態呈現高維變量時，單以少數層數的決策樹作為可解釋模型的表達能力可能不足，因此實務上常改用表現較強的黑箱模型作為分類基準。

例如樹模型與梯度提升方法常在高維度的資料上取得較佳表現，其中以 Chen and Guestrin (2016) 提出的 Extreme Gradient Boosting(XGBoost) 為代表的梯度提升樹模型常被作為高維度資料的強基準分類模型。然而，僅追求預測準確度不足以支援實務上的決策；當模型為黑箱時，仍需額外方法說明單一樣本被分類時的特徵的依據。

而在可解釋性方法層面，Lundberg and Lee (2017) 以合作賽局理論的 Shapley value 為基礎提出 SHapley Additive exPlanations(SHAP)，將單一樣本分類分解為各特徵貢獻度的加法表示，同時可用於整體樣本的彙整比較。並可用於黑箱模型的事後解釋，以量化特徵對預測輸出的影響。可以應用於不同的數據類型，包括文字、表格資料和影像。

Ribeiro et al. (2016) 提出 (Local Interpretable Model-agnostic Explanations(LIME))，以「局部可解釋」為目標，在欲解釋樣本附近生成擾動樣本，並以距離為權重給予相鄰的樣本較高權重，再以簡單的線性模型近似黑箱在局部的分類行為，以提供單一樣本被分類時的局部解釋。

然而，在製程資料的高維與異質性的情況下，上述的局部解釋方法在實作上仍可能不穩定，主要來自兩個原因。

第一，製程資料可能存在多種製程狀態，亦即混合的子群結構。若以單一黑箱模型描述全體樣本，其決策邊界可能同時存在多種不同的規則，則對單一樣本的局部解釋，得到的可能是混合後的分類標準，導致局部解釋在不同樣本間缺乏可比性。因此，本研究先以分群切分資料，在群內建立

黑箱分類模型與局部刻劃模型，以降低資料的異質性干擾對單一模型學習與解釋穩定性的影響。

第二，在高維空間中，以隨機擾動的方式生成鄰近樣本時，樣本容易偏離真實資料分佈，使局部刻劃模型可能在外插的區域擬合，導致解釋與實際資料機制不一致。因此，本研究在群內另外定義局部的範圍與擾動的方式，降低外插可能造成的偏誤，並以可檢視的局部刻劃模型評估。

綜合以上，本研究聚焦於兩個核心問題：

(1) 面對製程資料的異質性，如何以分群切分後在群內建立黑箱分類模型，使其決策規則與後續解釋在群內具可比性。

(2) 在不產生明顯的外插風險下，如何在群內建立可檢視的局部刻劃模型，提供局部的可解釋性。

1.3 研究目的與方法概述

本研究的目的為：在高維、缺失嚴重且類別不平衡的情境下，先以分群切分資料結構，於群內建立可檢視的局部線性刻劃模型，提供單一樣本在分類上的局部可解釋之依據。同時，我們建立一個「分群一群內黑箱一群內局部刻劃」的流程。

首先，對樣本進行分群以切分資料為若干子群，接著於各群內訓練黑箱分類模型，並輸出每筆樣本的預測機率。

本研究以接近分類閾值（即決策邊界附近）的樣本作為局部刻劃的代表點，在代表點附近建立具結構性的格子點，控制取樣範圍並降低外插風險，後續以指標來檢視模型在局部刻劃的結果。

1.4 研究貢獻

本研究的主要貢獻如下：

1. 建立以分群各自建立黑箱模型的建模流程，以處理製程資料的異質性。
2. 設計局部資料的格子點生成方法，以提升局部模型擬合的可解釋性。

3. 提出以決策邊界區域為目標的局部刻劃框架，使黑箱輸出轉化為可解釋的局部特徵。

1.5 章節介紹

第二章介紹研究資料與前處理；第三章說明研究方法與流程，包含分群、黑箱模型、局部刻劃模型；第四章呈現實驗結果與案例分析；第五章總結研究結論與未來工作方向。



Chapter 2

研究資料

2.1 資料背景

本研究使用半導體製程量測資料－SECOM 作為分析對象 McCann and Johnston (2008)，共 1567 筆；每筆樣本包含一個時間欄位（Time, 範圍自 2008-01-08 02:02:00 至 2008-12-10 18:47:00）、590 個已匿名化的量測變項（以 x_1 至 x_{590} 表示），以及一個品質結果欄位（二元變數，Pass/Fail）作為目標變數，其中 Pass（-1）共 1463 筆（93.36%），Fail（1）共 104 筆（6.64%），存在明顯的類別不平衡，同時存在缺失值問題，整體缺失率為 4.54%，但缺失分佈不均，部分特徵缺失筆數極高，單一特徵最高缺失達 1429 筆（91.19%），且有 20 個特徵之缺失筆數超過 1000 筆（占樣本數 63.82% 以上）。

表 2.1: SECOM 原始資料集摘要

idx	Time	x_1	x_2	x_3	...	x_{588}	x_{589}	x_{590}	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1

2.2 資料前處理

本節說明資料清理與特徵處理流程。

2.2.1 目標變數與資料切分單位

為方便後續建模與評估，本研究將原始目標欄位 Pass (1)、Fail (-1)，重新編碼為 Pass (0)、Fail (1)。時間欄位 Time 不作為模型特徵，於建模前移除。

2.2.2 缺失值

如同第 2.1 節所述，本研究資料有高度缺失的狀況。為避免高度缺失的特徵在補值後造成誤差，本研究以「單一特徵的缺失筆數」作為篩選指標，先移除缺失筆數高於 1000 筆的特徵。




圖 2.1: SECOM 原始資料各變數缺失值筆數分佈

2.2.3 少數類別特徵

同時，亦發現少數特徵的值為單一或僅數個常數的欄位，我們認為這些特徵對分類模型的影響有限，並以「特徵的不同數值」作為篩選指標，移除特徵值種類低於門檻的特徵。




圖 2.2: SECOM 原始資料各變數相異值數量分佈

2.2.4 補值

保留上述處理在門檻內的特徵後，再進行補值。本研究採用 KNN 補值 (k -Nearest Neighbors Imputer, KNN imputer)，其核心概念為：對於一個缺失值，在樣本空間中尋找與該樣本距離最近的 k 個鄰近樣本，再以鄰近樣本在該特徵上的觀測值進行距離加權平均，以估計缺失值。

設樣本 i 在第 j 個特徵的缺失值為 x_{ij} ，則欲估計的缺失值定義為：

$$\hat{x}_{ij} = \frac{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r) x_{rj}}{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r)}$$

其中 $\mathcal{N}_k(i,j)$ 表示在「第 j 個特徵有觀測值」的樣本中，與樣本 i 距離最近的 k 個鄰近樣本的集合（本研究設定 $k = 10$ ）；並且採用距離反比作為權重，令 $w(i,r) = 1/d(i,r)$ 。距離 $d(i,r)$ 依照 nan-euclidean distance（缺失值下的歐式距離）定義為

$$d(i,r) = \left(\frac{p}{|\Omega_{ir}|} \sum_{\ell \in \Omega_{ir}} (x_{i\ell} - x_{r\ell})^2 \right)^{1/2}$$

其中 Ω_{ir} 為樣本 i 與樣本 r 同時具有觀測值的特徵集合。 $|\Omega_{ir}|$ 為其元素個數， p 為特徵總數。

2.2.5 極端值處理

本研究資料屬於高維度的特徵空間，若直接在原始高維空間進行計算，則容易受到尺度差異、雜訊影響，使得後續分群結果不穩定。因此，本研究先以主成分分析 (Principal Component Analysis, PCA) 將高維資料投影至可觀察的二維平面，作為極端值檢視與後續分群的輔助。

PCA 為非監督式降維方法，利用正交線性轉換將原始特徵表示為相互正交的主成分，使得前幾個主成分能保留原始數據中較大的變異量。

在本研究中，PCA 主要用於：

- (1) 將高維資料投影至低維空間，以進行視覺化檢視與極端值辨識；
- (2) 作為後續分群的輔助，以降低高維空間的距離度量不穩定所造成的干擾。

因此，本研究先將資料投影至二維 PCA 平面觀察整體分佈，並以明確的門檻規則移除極端點。移除後重新編號樣本索引，以確保後續分群與交叉驗證索引一致。




圖 2.3: 未移除 PCA 極端值的原始資料之 PCA 投影結果

如圖 2.3 所示，在未移除極端值之前，二維主成分明顯被少數點拉開，使大多數樣本集中於狹小的區域。本研究推測，少數極端值可能在 PCA 投影的估計過程當中造成主導的效果，會影響後續已以距離為基礎的分析產生差距。

我們根據圖 2.3 的分佈，設定主成分門檻規則為 $PC1 \leq 10$ 及 $PC2 \leq 10$ 。於資料重新讀取後，直接刪除未達門檻規則的樣本，並重複同樣的資料前處理與 PCA 步驟，移除疑似的極端值後之二維主成分平

面如圖 2.4 所示。




圖 2.4: 移除 PCA 極端值後的原始資料之 PCA 投影結果

其分佈較均勻，可顯示資料在投影與距離結構上受到極端值干擾的程度降低。

2.2.6 前處理後最終資料集摘要

完成特徵清理、缺失處理與極端值移除後，本研究得到最終分析資料 $(\mathbf{X}, \mathbf{y})$ ，其中 $\mathbf{X} \in \mathbb{R}^{n \times p}$ 為輸入變數， $\mathbf{y} \in \{0, 1\}^n$ 為對應標籤。 n 為樣本數， p 為前處理後之特徵數。為避免不同單位與尺度造成距離計算與模型訓練偏差， $\mathbf{X}$ 已進一步進行標準化處理。

表 2.2 為最終分析資料的預覽表。其中 Pass/Fail 欄位即為標籤 $\mathbf{y}$ 。此時資料已不含缺失值，且於移除極端值後重新編號索引，以確保後續分群、交叉驗證與模型訓練時索引一致。後續章節之分群、群內黑箱模型訓練與局部刻劃分析，皆以此資料集作為輸入。

表 2.2: 資料前處理後之最終資料集

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0

Chapter 3

研究方法與流程

本研究以高維製程量測特徵與二元品質標記為基礎，目標為黑箱在局部的可解釋性分析。本章節將說明本研究用到的方法，降維、分群、黑箱分類模型、局部資料生成、局部代理模型建構，同時提供實驗環境與評估指標以確保結果具可重現性與可比較性。

3.1 流程大綱

1. 資料前處理後取得特徵矩陣 X 與標記 y 。
2. 以 SMOTE 後執行 PCA 的特徵進行分群，後續建模移除合成樣本。
3. 於各群內訓練黑箱分類模型 $f_c(\cdot)$ ，輸出機率 $\hat{p}_c(x)$ 。
4. 於各群內挑選決策邊界附近的代表點集合，取該集合的平均並定義為中心點 x_0 。
5. 於 x_0 附近生成格子點，並經由黑箱輸出的值作為應變數建立多元線性回歸模型 $g(\cdot)$ 。
6. 以多元線性回歸模型的指標彙整結果，並進行關鍵案例分析。

3.2 流程細部

本研究以研究資料 2.2.6 為起點

3.2.1 資料降維與分群

1. 合成少數過度取樣技術用於降維：

由於目標類別分佈高度不平衡，若直接對資料 2.2.6 降維，降維結果傾向由多數類別的資料訊息主導，使少數類別在特徵空間中的結構不容易辨識。因此，本研究先於訓練資料中使用合成少數過度取樣技術（Synthesized Minority Oversampling Technique, SMOTE）產生少數類別的合成樣本。以不改變多數類別分佈的前提下，補足少數類別於降維的特徵空間中的資訊。

SMOTE 是在機器學習中解決數據類別不平衡問題的常見方法，其核心概念為針對每個少數類別的樣本 x_i ，尋找其鄰近樣本 x_{nn} ，並在兩者之間進行插值產生新的樣本點 x_{new} ；其合成樣本的生成式如下。

$$\mathbf{x}_{new} = \mathbf{x}_i + \lambda (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim \text{Uniform}(0, 1)$$

本研究在使用 SMOTE 將少數類別資料增至與多數類別資料相近比例後，接著再使用 PCA 做降維，以降低降維結果被多數類別的訊息主導的情況；其降維視覺化結果如圖 3.1。




圖 3.1: 移除 PCA 極端值後的 SMOTE 資料之 PCA 投影結果

2. 分群建構與合成樣本移除（僅保留真實資料供後續建模）：

本研究採用 k-平均演算法 (k-means) 做分群以處理資料異質性，在 PCA 空間中依照樣本結構將資料切分為數個子群，使後續黑箱模型可在群內學習較一致的決策邊界。

k-means 是機器學習的非監督式分群方法，其做法為給定群數 k 以及自資料點中隨機選取群中心後，不斷進行：(1) 將每個資料點指派至最近的群中心；(2) 更新群中心為群內資料點的平均值，直到收斂。

本研究以手肘法 (elbow method) 評估不同群數 k 下之群內平方誤差 (within-cluster sum of squares, WCSS)，WCSS 定義如下。

$$WCSS(k) = \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2, \quad \boldsymbol{\mu}_i = \frac{1}{|S_i|} \sum_{\mathbf{x} \in S_i} \mathbf{x}$$

其中 S_i 為第 i 群， $\boldsymbol{\mu}_i$ 為該群中心，目標為最小化 WCSS。最後選取下降幅度開始趨緩時的轉折點作為分為 k 群的依據。本研究最終採用 $k = 2$ 進行分群。分群結果如圖 3.2。




圖 3.2: 移除 PCA 極端值後的 SMOTE 資料在 PCA 空間之分群結果

另外，需強調的是：SMOTE 僅用於降維與分群的階段，以改善少數類別在降維空間的資訊；完成分群後，會將合成樣本移除，並保留真實資料集及其原始類別標記，供後續各群內黑箱模型之訓練與評估使用。

3.2.2 黑箱模型訓練

1. 全體與各群內訓練黑箱模型與效能評估：

在全體資料與各群內資料各自訓練一個黑箱模型，以作為後續局部格子點的黑箱輸出函數。本研究採用樹模型中的極限梯度提升

(Extreme Gradient Boosting, XGBoost) 進行二元分類，

XGBoost 為監督式學習方法，基於梯度提升決策樹 (Gradient Boosting Decision Tree)，以加法模型逐步疊加弱學習器 (決策樹)，並透過損失函數的梯度資訊進行更新，同時引入多種優化以提升效能與模型泛化能力，可用於解決迴歸與分類問題，亦是目前最常被使用在 Kaggle 資料分析競賽當中的機器學習模型。

本研究以 (TN, FP, FN, TP) 彙整分類結果，並以此計算分類效能指標，包含 Accuracy(ACC)、誤報率 (False Alarm Rate, FAR)。其定義如下：

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{FAR} = \frac{FP}{FP + TN}$$

ROC-AUC 則以模型輸出機率於不同門檻下所形成之 ROC 曲線面積表示。

此外，對各群內採用五折交叉驗證 (k -fold Cross Validation, $k = 5$)。

設定五折的交叉驗證，其目的在於模型不會僅依據單次切分造成的結果偏差，而是將資料切分成 80% 作為訓練集資料，20% 作為測試集資料，共依序訓練五次 (五折)。其中每一折，僅對訓練集進行 SMOTE 以提升少數類別可分性，測試集則不進行 SMOTE。

本研究同時呈現整體與各群模型的混淆矩陣，以比較整體模型與分群後模型表現之差異。

2. 依各群內交叉驗證之測試集機率挑選樣本：

接著在每一折中，使用該折訓練之模型對測試集資料輸出預測為 Pass 或 Fail 的預測機率值 (介於 0, 1 之間)。彙整五折測試集輸出得到每筆真實樣本的交叉驗證機率值，用於後續挑選欲分析的樣本。

3.2.3 中心點選取與局部生成格子點擬合模型

1. 群內樣本挑選與中心點建立：

如同前一步驟所述，取得預測機率後，於該群內挑選預測機率最接近決策邊界 (例如 0.5) 的前幾筆樣本，並將其標準化後的特徵向量取

平均，作為該群的局部刻劃中心點。

2. 局部格子點生成：

以中心點為基準，設定每一個維度位移的步長 ($\delta = 0.1$) 與位移集合 $m \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$ ，其中 $k = 2$ ，故每一維共有 $(2k+1) = 5$ 個位移的位置，而該資料集的特徵維度為 $p = 459$ 所以完整格子點數量有 $(2k+1)^p$ ，即 5^{459} 個；每一個格子點可視為由中心點加上「步長 δ 乘上位移集合 m 」所形成之鄰域格點。

3. 抽樣做局部線性刻劃與多輪篩選：

本研究雖定義完整格點集合，但實際僅由該集合中隨機抽樣格子點建立局部刻劃模型，且採用多輪門檻的篩選。其過程如下：每一輪抽取固定數量格子點（80 萬筆），以黑箱輸出機率作為應變數，以抽樣格子點的特徵向量作為自變數，採用多元線性迴歸模型 (Ordinary least squares, OLS) 建立局部線性刻劃模型，

OLS 的核心概念為給定自變數 X 與應變數 y 的情況下，以最小殘差平方和 (Residual Sum of Squares) 來估計迴歸係數，即選取使 $\sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2$ 最小的 $\hat{\beta}$ ；當 X 滿秩使 $X^T X$ 可逆時，則 $\hat{\beta} = (X^T X)^{-1} X^T y$ 。

最後根據 p-value 門檻保留通過的特徵；重複上述流程數輪以縮小特徵集合，直到達到預設的輪數或特徵的集合不再變動。

4. 重複實驗與特徵穩定性統計：

為避免只做一次的多輪門檻篩選造成的偶然性，本研究重複進行多次局部抽樣與多輪篩選（50 次），統計各特徵在最後一輪被保留的次數與比例，並彙整其局部係數的平均值與標準誤，作為群內局部解釋結果的穩定性指標。

5. 局部刻劃評估：

最後另外進行重新抽取格子點（200 萬筆），同樣以其黑箱輸出機率作為應變數，從前一步驟結果中的「被保留 50 次」的特徵作為自變數，以 OLS 重新擬合局部線性模型，估計各特徵的係數，並以 R^2 作為該模型對黑箱輸出的擬合度指標，用來觀察黑箱模型在中心點附近的行為。

Chapter 4

研究結果

4.1 分群建立黑箱

我們對資料實施 SMOTE，是為了在降維與分群階段時，以降低少數類別在 PCA 空間中被多數類別的結構主導，導致難以形成可辨識的群集之風險。依 3.2.1 的步驟 2，本研究在完成分群後，隨即移除 SMOTE 所合成的樣本，後續的建模僅用真實資料集，而不包含經由 SMOTE 合成的樣本集。其移除後在 PCA 空間分群後的視覺化結果如圖 4.1。




圖 4.1: 移除 PCA 極端值與合成樣本後的原始資料在 PCA 空間之分群結果

如表 4.2 可知，尚未分群的時，單一模型於整體資料 (ALL, $n = 1525$) 的平均評估為 $ACC = 0.9272$ 、 $FAR = 0.0189$ 、 $ROC-AUC = 0.6636$ ，進一步將樣本分為兩群後，各群模型的平均表現如下：

$cluster_0$ ($n = 676$) 之 $ROC-AUC = 0.6974$ (相對整體提升 0.0338), $FAR = 0.0468$ (相對整體增加 0.0279)、 $ACC = 0.8847$; 相對地

$cluster_1$ ($n = 849$) 之 $ROC-AUC = 0.6266$ (相對整體降低 0.0370), $FAR = 0.0099$ (相對整體降低 0.0090)、 $ACC = 0.9482$ 。

此結果顯示整體資料中存在呈現明顯異質性，尤其是兩群之 FAR 相差約 $0.0468/0.0099 \approx 4.73$ 倍，顯示不同群之錯誤回報程度與可分類程度（以 AUC 衡量）並不一致；若僅以未分群的單一平均指標呈現，將掩蓋高誤報率群體（ $cluster_0$ ）的存在。

表 4.1: 分群後的各群之真實目標類別數目

群	0	1
Pass	619	811
Fail	57	38

表 4.2: 黑箱模型分類之表現：全體與分群比較

group	n	ACC	FAR	ROC-AUC
全體	1525	0.9272	0.0189	0.6636
群 0	676	0.8847	0.0468	0.6974
群 1	849	0.9482	0.0099	0.6266

4.2 分群黑箱的預測

本研究以分群為單位訓練黑箱模型，並在各群內採用 5-fold 交叉驗證取得 out-of-fold (OOF) 之測試集預測機率 p_{test} 。針對 $cluster=0$ ，我們以 $|p_{\text{test}} - 0.5|$ 由小到大排序，選取最接近 0.5 的前 5 個樣本點 (global_idx: 82、225、44、144、345)，其部分特徵、真實標籤 y_{true} 與黑箱輸出 p_{test} 如表 4.3。

表 4.3: 群 0 的黑箱輸出最接近 0.5 的前五個樣本摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
82	-0.921323	-0.263777	...	1.057470	0.172921	0	0.4984
225	0.794818	-1.815294	...	-0.332622	-0.154877	0	0.5161
44	0.367305	2.479558	...	0.779451	0.095199	0	0.4810
144	-1.446410	-0.375622	...	-0.610641	-0.546260	0	0.5276
345	-0.439136	-2.580404	...	-0.402127	0.549533	0	0.4707

表 4.4: 群 1 的黑箱輸出最接近 0.5 的前五個樣本點摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
1158	-0.978433	0.898024	...	-0.645393	-0.554204	0	0.4930
990	0.747317	0.821800	...	-0.089356	-0.360851	0	0.5139
1361	0.514817	0.252607	...	0.223414	-0.494009	1	0.5218
1189	0.575310	-0.470903	...	0.014901	0.332787	1	0.4738
1187	0.760444	-0.100990	...	-0.714898	-0.478764	0	0.5287

為了在決策邊界附近建立局部刻劃的參考中心點，我們取上述 5 個樣本在標準化特徵空間的特徵向量平均，定義

$$x_{\text{center}} = \frac{1}{5} \sum_{i \in \{82, 225, 44, 144, 345\}} x_i. \quad (4.1)$$

後續如節 3.2.3 所述方式，以 x_{center} 為中心生成格子點並輸入該群黑箱模型，以取得局部鄰域內的黑箱輸出，如表 4.5 用於後續的局部刻劃分析。

表 4.5: Cluster 0：以 x_{center} 生成之格子點（示例特徵）與黑箱輸出

x1	x2	...	x589	x590	y_{blackbox}
-0.328949	-0.511108	...	0.098306	0.023303	0.966755
-0.528949	-0.411108	...	-0.001694	0.223303	0.940804
-0.528949	-0.711108	...	0.098306	0.123303	0.983204
-0.328949	-0.711108	...	0.098306	0.123303	0.889116
-0.228949	-0.611108	...	0.098306	0.123303	0.881310

表 4.6: 群 0 的黑箱輸出最接近 1 的前二個樣本點摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
348	-1.887997	0.224832	...	1.717764	1.004471	0	0.975609
212	-0.692748	1.225590	...	1.787268	0.824068	1	0.848101

表 4.7: 群 1 的黑箱輸出最接近 1 的前二個樣本點摘要

樣本編號	x1	x2	...	x589	x590	y_{true}	p_{test}
1326	2.015375	-0.306746	...	-0.958164	-0.602983	1	0.846026
1056	0.045893	-0.705555	...	-0.054604	-0.222966	0	0.843086

4.3 關鍵案例分析

本節介紹最後的局部線性模型，我們在各群篩選特徵，並建立局部線性模型。是根據 50 次的篩選後，我們統計在最後一輪被篩選到 50 次的特徵，總共有 97 個特徵被篩選到 50 次，並從格子點中隨機抽 200 萬筆，以這些特徵與其黑箱機率值做為擬合線性模型的資料集，

4.3.1 群 0 (cluster_0)

$r^2 = 0.6128$ ，以及各特徵在線性模型上的斜率（特徵係數），如表 4.8，列出前 30 個



表 4.8: Cluster 0 重要特徵 (p 值小到大前 30 個)

feature	coef	p
(intercept)	1.164411	0.000
x11	-0.012369	0.000
x18	-0.012340	0.000
x91	-0.012102	0.000
x578	-0.011193	0.000
x580	-0.009745	0.000
x85	-0.008851	0.000
x113	-0.008834	0.000
x446	-0.012711	0.000
x384	-0.008593	0.000
x317	-0.008226	0.000
x118	-0.008092	0.000
x128	-0.006833	0.000
x9	-0.006802	0.000
x280	-0.006217	0.000
x528	-0.006047	0.000
x486	-0.006024	0.000
x332	-0.008584	0.000
x391	-0.005936	0.000
x36	-0.014250	0.000
x311	-0.014851	0.000
x7	-0.038076	0.000
x58	-0.031087	0.000
x563	-0.030969	0.000
x1	-0.029007	0.000
x274	-0.029081	0.000
x518	-0.027012	0.000
x103	-0.026372	0.000
x581	-0.014603	0.000
x247	-0.020698	0.000

4.3.2 群 1 (cluster_1)

$$r^2 = 0.6368 ,$$

表 4.9: Cluster 1 重要特徵 (p 值小到大前 30 個)

feature	coef	p
(intercept)	1.019421	0.000
x420	-0.017542	0.000
x456	0.001629	0.000
x433	0.001564	0.000
x292	0.001592	0.000
x341	0.001458	0.000
x412	0.001471	0.000
x146	0.001403	0.000
x484	0.001320	0.000
x557	-0.001248	0.000
x369	-0.001415	0.000
x64	0.002007	0.000
x118	-0.001808	0.000
x85	-0.002418	0.000
x500	-0.002933	0.000
x419	-0.003011	0.000
x355	-0.004019	0.000
x56	-0.004285	0.000
x112	-0.004563	0.000
x103	-0.011539	0.000
x287	-0.011932	0.000
x28	-0.013828	0.000
x36	-0.014241	0.000
x551	-0.002193	0.000
x26	0.002127	0.000
x432	0.001746	0.000
x247	0.002301	0.000
x386	0.028210	0.000
x92	0.015615	0.000
x248	0.010597	0.000
x288	0.007676	0.000

結果敘述

4.4 討論與限制

Chapter 5

結論

5.1 總結

5.2 未來工作



Bibliography

- Chen, T. and Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>.
- Lundberg, S. and Lee, S. (2017). A Unified Approach to Interpreting Model Predictions. (arXiv:1705.07874). arXiv. <https://doi.org/10.48550/arXiv.1705.07874>.
- McCann, M. and Johnston, A. (2008). Secom. UCI Machine Learning Repository, <https://doi.org/10.24432/C54305>.
- Park, H., Koo, Y., Yang, H., Han, Y., and Nam, C. (2024). Study on Data Pre-processing for Machine Learning Based on Semiconductor Manufacturing Processes. *Sensors*, 24(17), 5461. <https://doi.org/10.3390/s24175461>.
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). 「Why Should I Trust You?」: Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144. <https://doi.org/10.1145/2939672.2939778>.
- 賴立夫 (2022). 使用 knn 和決策樹方法對填補缺失值的製造數據進行失效預測和原因追蹤分析. Master's thesis. <https://hdl.handle.net/11296/ub6st3>.