

國立東華大學 應用數學系

統計碩士班

碩士論文

指導教授：曹振海 博士

**預測模型局部決策因子之刻劃：以半導體
製程資料為例**

*Characterizing Local Decision Factors of Prediction Models: A
Case Study of Semiconductor Manufacturing Data*



研究生：黃丞暘 撰

中華民國 115 年 X 月



這頁放審定書





這頁放原創性聲明書





致謝

這頁寫致謝內容



國立東華大學應用數學系統計碩士班 黃丞暘 謹致
民國 115 年 X 月



摘要

半導體產業蓬勃發展，製程中所累積的資料逐漸受到重視。然而，半導體製程資料通常具有量測變數多、缺失比例高、類別分布不平衡，以及樣本數取得不易等特性，增加了預測與解釋的困難。近年來，相關研究多以決策樹、隨機森林、XGBoost 等機器學習方法進行預測，並以 SHAP、LIME 等方法輔助說明變數的重要性。然而，對於預測模型在特定樣本附近的局部決策依據，仍有進一步分析與討論的空間。

本研究以 UCI SECOM 半導體製程資料為研究對象，建立一套兼顧預測與局部解釋的分析流程。首先進行資料前處理，其次利用 KMeans 分群，並於訓練資料中結合 SMOTE 與交叉驗證建立 XGBoost 預測模型；最後於關注的局部範圍內，透過資料生成方式建立局部刻劃模型，用來描述預測模型在局部範圍內的決策行為，並說明各變數影響之方向與相對大小。

研究結果顯示，分群後建構的 XGBoost 預測模型，其分類準確度分別為 88.46% 及 94.82%。此外，局部刻劃模型之決定係數約為 0.6，顯示其在局部範圍內可有效刻劃預測模型之決策行為，亦能提供局部決策因子之具體資訊，作為後續製程監控與改善之依據。

關鍵字：SECOM、半導體製程資料、分群、XGBoost、局部刻劃模型、可解釋人工智慧



Abstract

Semiconductor manufacturing data have attracted increasing attention as the semiconductor industry continues to grow. However, such data usually exhibit characteristics such as a large number of measured variables, a high proportion of missing values, imbalanced class distribution, and limited sample availability, which increase the difficulty of prediction and interpretation. In recent years, related studies have commonly employed machine learning methods such as decision tree, random forests, and XGBoost for prediction, and have further used SHAP and LIME to explain feature importance. Nevertheless, there remains room for further analysis and discussion regarding the local decision basis of prediction models around specific samples.

This study uses the UCI SECOM semiconductor manufacturing dataset as the research object and establishes an analytical framework that takes both prediction and local explanation into account. First, data preprocessing is performed. Next, KMeans clustering is applied, and an XGBoost prediction model is constructed by combining SMOTE and cross-validation on the training data. Finally, within a local region of interest, a local characterization model is established through a data generation approach to describe the decision behavior of the prediction model in the local region and to analyze the direction and relative magnitude of the effects of variables.

The results show that the XGBoost prediction models constructed after clustering achieve classification accuracies of 88.46% and 94.82% respectively. In addition, the coefficient of determination of the local characterization model is approximately 0.6, indicating that the model can effectively characterize the decision behavior of the prediction model within the local region. The proposed framework also provides specific information on local decision factors, which may serve as a basis for subsequent process monitoring and improvement.

Keywords: SECOM, semiconductor manufacturing data, clustering, XGBoost, local characterization model, explainable artificial intelligence



Contents

1	緒論	1
1.1	研究背景與動機	1
1.2	文獻回顧	2
1.3	研究問題與目的	4
1.4	章節介紹	5
2	研究資料	6
2.1	資料背景	6
2.2	資料前處理	6
2.2.1	目標變數與資料切分單位	7
2.2.2	缺失值	7
2.2.3	少數類別特徵	7
2.2.4	補值	8
2.2.5	離群樣本處理	9
2.2.6	前處理後最終資料集摘要	11
3	研究方法與流程	13
3.1	流程大綱	13
3.2	流程細部	14
3.2.1	分群	14
3.2.2	訓練預測模型	15
3.2.3	中心點選取與局部生成格子點擬合模型	15
3.3	評估方法	18

4	研究結果	20
4.1	各群預測模型之評估與決策邊界樣本之採用	20
4.1.1	各群之類別分布與預測模型設定	20
4.1.2	各群預測模型之評估結果比較	21
4.1.3	各群中接近決策邊界之樣本	22
4.2	各群局部刻劃模型之建立與結果分析	22
5	結論	26
5.1	總結	26
5.2	未來工作	27





Chapter 1

緒論

1.1 研究背景與動機

半導體產業是現代科技發展的核心基礎之一，從消費性電子產品到通訊、運算及自動化設備，皆高度依賴半導體元件的技術與品質表現。隨著科技持續進步，半導體製程亦朝向高精密與高複雜度的方向發展，尤其在製造端，不僅要維持產品功能的正確性，還要兼顧產品的生產效率、成本控制及品質穩定。而良率（Yield）一直是實務上最直接且最重要的指標之一，良率的高低不只影響出貨與製造成本，也會牽動工廠產線的資源配置與製程上的改善。因此，如何在環環相扣且複雜的製程中保持產品的穩定，同時又提升品質，至始至終都是半導體產業的重要課題。

在此背景下，晶片（Chip）製造為半導體生產中的重要環節，從一塊矽晶圓（Wafer）到一片矽晶片，需要經過如圖 1.1 所示的核心六大程序，分別是薄膜沉積 (Film Deposition)、上光阻劑 (Spin Coating)、微影曝光 (Exposure)、顯影 (Development)、蝕刻 (Etching)、移除光阻 (Photoresist Stripping)，此外，這些程序並不是只有執行一次，而是會在同一晶圓依設計圖的需求反覆進行，逐步堆疊並形成所需的電路結構。

由於各製程步驟彼此相依，且在生產過程中伴隨著機台參數、感測訊號、量測結果與紀錄，製造端因而累積了大量的製程與量測資料。




圖 1.1: 晶圓程序

這些資料除了用來記錄生產過程，也被用來監控制程狀態、辨識異常，以降低不良品產出。也因此，為了良率的進步與品質的穩定需求，就必須進一步透過資料分析來理解製程狀態與品質結果之間的關係。就半導體資料而言，常見的任務便是如何透過分析量測變數來判斷產品最終是屬於良品 (Pass) 還是不良品 (Fail)，

近年來，多項研究使用機器學習方法進行產品品質的預測，並以準確度 (Accuracy) 等指標來比較模型表現。然而在實務情境中，僅有準確度往往不足以支援製程的決策。製程部門更關心的是：哪些製程變數是對產品品質最具重要性及影響性的。換句話說，研究的焦點不應該只注重在預測結果的好壞，而是將問題轉向如何利用製程資料，來回答工程師哪些量測變數對產品品質的結果是具重要性的。

1.2 文獻回顧

在既有的研究中，已經有不少以 McCann and Johnston (2008) 的 SEMi COnductor Manufacturing (SECOM) 資料作為半導體製程品質分析的代表性資料來源。該資料集包含大量半導體製程量測變數以及標記 Pass 或 Fail 的品質類別，且具有高維度、高缺失值與類別不平衡等特性因此常被用於資料前處理方法與製程品質預測的比較研究。此外，從製程資料分析的角度來看，不同樣本亦可能對應不同的製程狀態，使資料在統計分布上呈現異

質性。

針對 SECOM 資料集，前人研究大部分先聚焦於資料前處理的問題。例如，Salem et al. (2018) 針對資料修剪、缺失值填補、特徵選擇與預測方法進行大量組合比較，並提出 In-painting KNN-Imputation 來改善缺失值處理的效果；Park et al. (2024) 則比較缺失值處理、降維、過採樣技術與資料縮放等方法，並強調應先切分成訓練集與測試集，再進行前處理，以避免資料洩漏對模型評估造成偏誤。

在預測模型方面，賴立夫 (2022) 透過補值、特徵選擇與決策樹 (Decision Tree) 建立預測模型，並利用決策樹的節點結構追溯影響模型預測的關鍵變數，此類方法的優點是在於結果較容易說明；但是當使用的資料量不大且形態呈現高維度特性時，僅依賴少量層數的樹狀結構，其表達能力可能不足。因此，後續研究多半也會搭配支援向量機、隨機森林、XGBoost 等方法進行比較，使 SECOM 資料集相關研究的主軸，長期集中在「如何透過前處理與模型選擇提升分類表現」之上。

然而，當方法愈能處理複雜的關係時，其判斷的依據也愈不易直接理解；對半導體製程實務而言，若仍將準確度作為主要評估標準，並不足以支援實務上的決策；因為實務上更在意的是，為何某些樣本被預測為不良，為何預測模型判斷該樣本為哪一類時是模稜兩可的，又或者哪些量測變數在模型預測中扮演重要的角色。所以仍需額外方法說明單一樣本被預測至某一類的原因。

基於此，Lundberg and Lee (2017) 以合作賽局理論的 Shapley value 為基礎提出 SHapley Additive exPlanations(SHAP)，將單一樣本的預測結果分解為各特徵貢獻度的總和，同時可用於整體樣本的彙整比較。此方法可作為預測模型的事後解釋，以量化特徵對預測結果的影響，可以應用於不同的數據類型，包括文字、表格資料和影像。Ribeiro et al. (2016) 提出 Local Interpretable Model-agnostic Explanations(LIME)，以「局部可解釋」為目標，在欲解釋樣本附近生成擾動樣本，並以距離為權重給予相鄰的樣本較高權重，再以簡單線性模型描述預測模型在局部範圍內的預測行為，以提供單一樣本被預測至某一類的解釋依據。Presciuttini et al. (2024) 則進一步將 LIME 應用在 SECOM，嘗試提升預測模型的可解釋性，並提供可用於品質控制與製程改善的解釋資訊。

整體而言，既有以 SECOM 資料集為對象的研究，大致可分為兩個方向：一是以前處理、特徵／步驟選取與預測模型比較為主，著重於提升預

測表現；二是透過決策樹或事後解釋方法說明模型判斷依據，著重於提升結果的可解釋性。

1.3 研究問題與目的

然而，現有研究多半分別著重於預測能力的提升或結果的解釋說明，對於如何兼顧預測表現與特定樣本解釋的具體性，並將解釋結果連結至製程改善與異常原因追蹤，仍有進一步討論的空間。

首先，面對半導體製程資料時，其特性是量測變數數量龐大，且實際資料取得不易，觀察的樣本數相對有限、以及缺失值存在、類別分布極度不平衡等等。在此情況下，若未經過適當的前處理與模型選擇，則所建立的預測模型表現可能受限，進而影響預測結果的可信度。

舉例來說，有一間咖啡廳想分析顧客的消費能力，那可收集到的資訊可能包含年齡、職業、來店時間、頻率和點餐內容等數十種甚至數百種變項。但實際可提供比較的顧客數並不充分，也就是說，即使蒐集到很多資訊（高維度），未必有足夠的樣本數支持模型做穩定的預測，因此不易建立穩定且可靠的預測模型，也難以充分掌握整體資料結構。

其次，即使建立預測能力較佳的模型，但模型本身的結構複雜，仍可能難以直接說明某些樣本為何被預測為某個結果，或者模型對某些樣本的預測是模稜兩可的。就實務而言，不只是想知道模型預測是否正確，更想知道的是造成該次預測結果的可能原因，我們關注的是哪些變數在特定樣本下的預測是具有較明顯的影響，而非只是變數的重要性排序，並提供較具體的可解釋性。

仍以咖啡廳為例，即使店家訓練好的模型已能預測某顧客為高消費能力的族群，但真正的問題應該是為什麼該顧客被預測為高消費能力？是因為來店頻率高、消費金額大、甚至是血型與星座的關聯，還是其他因素造成？此時我們在意的不是整體上哪個變數重要，而是針對某顧客，是哪些因素造成這次的預測。

再者，資料中可能存在彼此相異但群內相近的子群結構。若直接以全體資料訓練模型，則模型學習到的決策結構可能同時存在多種不同的規則，導致後續對單一樣本所建立的解釋，難以清楚表示當下的決策依據，其解釋結果可能缺乏穩定性與可信度。

再回到咖啡廳的例子，顧客的型態千奇百種，可能包含老人、年輕人、

工程師、服務業與退休族群，各類顧客的消費能力與考量因素不盡相同。若將所有顧客視為同一類型，並以單一標準分析，則所得到的結果可能混雜多種不同的消費能力，進而降低局部解釋的穩定及信任。因此，若能先將性質相近的樣本分群，再於群內進行分析，則可能有助於提升預測與解釋的穩定性。

另外，在高維空間中，以隨機擾動的方式生成樣本時，樣本可能偏離真實資料分布，使局部刻劃模型可能在外插的區域擬合，導致局部的解釋與實際資料機制不一致。因此，如何在可控制的範圍內生成局部樣本，使其更接近研究資料附近的結構，亦是建立局部模型時需要處理的重要問題。

基於上述，本研究之目的有二。

第一，針對高維度、具缺失值、類別不平衡且可能存在異質性的半導體製程資料，建立一套較完整的分析流程，以提升預測模型之表現，並作為後續解釋分析的基礎。

第二，在預測模型建立完成後，設計一套能對特定樣本的預測結果提供局部解釋的方法，藉以辨識預測模型在該樣本下較具影響性的變數，並作為後續製程異常原因追蹤與改善之參考依據。

1.4 章節介紹

第二章介紹研究資料；第三章說明研究方法與流程，包含分群、訓練預測模型、擬合局部刻劃模型；第四章呈現研究結果與分析；第五章總結研究結論與未來工作方向。

Chapter 2

研究資料

2.1 資料背景

本研究使用半導體製程量測資料－SECOM 作為分析對象 McCann and Johnston (2008)，共 1567 筆；每筆樣本包含一個時間欄位（Time, 範圍自 2008-01-08 02:02:00 至 2008-12-10 18:47:00）、590 個已匿名化的量測變項（以 x_1 至 x_{590} 表示），以及一個品質類別欄位（二元變數，Pass/Fail）作為目標變數，其中 Pass（-1）共 1463 筆（93.36%），Fail（1）共 104 筆（6.64%），存在明顯的類別不平衡，同時存在缺失值問題，整體缺失率為 4.54%，但缺失分布不均，部分特徵缺失筆數極高，單一特徵最高缺失達 1429 筆（91.19%），且有 20 個特徵之缺失筆數超過 1000 筆（占樣本數 63.82% 以上）。

表 2.1: SECOM 原始資料集摘要

idx	Time	x_1	x_2	x_3	...	x_{588}	x_{589}	x_{590}	Pass/Fail
1	2008-07-19 11:55:00	3030.9300	2564.0000	2187.7333	...	NaN	NaN	NaN	-1
2	2008-07-19 12:32:00	3095.7800	2465.1400	2230.4222	...	0.0201	0.0060	208.2045	-1
3	2008-07-19 13:17:00	2932.6100	2559.9400	2186.4111	...	0.0484	0.0148	82.8602	1
4	2008-07-19 14:43:00	2988.7200	2479.9000	2199.0333	...	0.0149	0.0044	73.8432	-1
5	2008-07-19 15:22:00	3032.2400	2502.8700	2233.3667	...	0.0149	0.0044	73.8432	-1

2.2 資料前處理


本節說明資料清理與特徵處理流程。

2.2.1 目標變數與資料切分單位

為方便後續建模與評估，本研究將原始目標欄位 Pass (-1)、Fail (1)，重新編碼為 Pass (0)、Fail (1)。時間欄位 Time 不作為模型特徵，於建模前移除。

2.2.2 缺失值

如同第 2.1 節所述，資料有高度缺失的狀況。為避免高度缺失的特徵在補值後造成誤差，本研究以「單一特徵的缺失筆數」作為篩選指標，先移除缺失筆數高於 1000 筆的特徵。






圖 2.2: SECOM 原始資料各變數相異值數量分布

2.2.4 補值

保留上述處理在門檻內的特徵後，再進行補值。本研究採用 KNN 補值 (k -Nearest Neighbors Imputer, KNN imputer)，其核心概念為：對於一個缺失值，在樣本空間中尋找與該樣本距離最近的 k 個鄰近樣本，再以鄰近樣本在該特徵上的觀測值進行距離加權平均，以估計缺失值。Troyanskaya et al. (2001) 比較多種缺失值估計方法後指出，KNN 型式的補值方法在缺失值估計上具有良好的穩健性，其表現優於單純以平均值進行填補的方法。因此，相較於以整體平均數進行補值，KNN 補值可利用樣本間的相似性資訊，作為估計缺失值的依據。

設樣本 i 在第 j 個特徵的缺失值為 x_{ij} ，則欲估計的缺失值定義為：

$$\hat{x}_{ij} = \frac{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r) x_{rj}}{\sum_{r \in \mathcal{N}_k(i,j)} w(i,r)}$$

其中 $\mathcal{N}_k(i,j)$ 表示在「第 j 個特徵有觀測值」的樣本中，與樣本 i 距離最近的 k 個鄰近樣本的集合（本研究設定 $k = 10$ ）；並且採用距離反比作為權重，使距離較近之鄰近樣本對補值結果具有較大影響。令 $w(i,r) = 1/d(i,r)$ 。距離 $d(i,r)$ 依照 nan-euclidean distance（缺失值下的歐式距離）定義為

$$d(i,r) = \left(\frac{p}{|\Omega_{ir}|} \sum_{\ell \in \Omega_{ir}} (x_{i\ell} - x_{r\ell})^2 \right)^{1/2}$$

其中 Ω_{ir} 為樣本 i 與樣本 r 同時具有觀測值的特徵集合。 $|\Omega_{ir}|$ 為其元素個數， p 為特徵總數。

2.2.5 離群樣本處理

本研究資料屬於高維度的特徵空間，若直接在原始高維空間進行計算，則容易受到尺度差異、雜訊影響，使得後續分群結果不穩定。因此，本研究先以主成分分析 (Principal Component Analysis, PCA) 將高維資料投影至可觀察的二維平面，作為離群樣本檢視與後續分群的輔助。

PCA 為線性降維方法，利用正交線性轉換將原始特徵表示為相互正交的主成分，使得前幾個主成分能保留原始數據中較大的變異量。此外，本研究後續將以線性迴歸的最小平方法建立局部刻劃模型，而 PCA 與最小平方法同樣建立在線性關係的觀點上。故在本研究中，PCA 主要用於：

- (1) 將高維資料投影至低維空間，進行視覺化檢視整體的分布，並移除明顯偏離分布的離群樣本；
- (2) 作為後續分群的輔助，以降低高維空間的距離度量不穩定所造成的干擾。






圖 2.3: 未移除 PCA 離群樣本的原始資料之 PCA 投影

如圖 2.3 所示，在未移除離群樣本之前，二維主成分明顯被少數點拉開，使大多數樣本集中於狹小的區域。因此，本研究依據 PCA 投影的分布情形，採用的門檻規則為 $PC1 \leq 10$ 及 $PC2 \leq 10$ 。於資料重新讀取後，將明顯偏離真實資料分布的樣本視為離群樣本並移除，再重複同樣的資料前處理與 PCA 步驟，移除離群樣本後的二維主成分平面如圖 2.4 所示。




圖 2.4: 移除 PCA 離群樣本後的原始資料之 PCA 投影

其分布較均勻，可顯示資料在投影與距離結構上受到離群樣本干擾的程度降低。

2.2.6 前處理後最終資料集摘要

完成特徵清理、缺失處理與離群樣本移除後，本研究得到最終分析資料 $(\mathbf{X}, \mathbf{y})$ ，其中 $\mathbf{X} \in \mathbb{R}^{n \times p}$ 為輸入變數， $\mathbf{y} \in \{0, 1\}^n$ 為對應標籤。 n 為樣本數， p 為前處理後的特徵數。為避免不同單位與尺度造成距離計算與模型訓練偏差， $\mathbf{X}$ 已進一步進行標準化處理。

表 2.2 為最終分析資料的預覽表。其中 Pass/Fail 欄位即為標籤 $\mathbf{y}$ 。此時資料已不含缺失值，且於移除離群樣本後重新對樣本編號，以確保後續分群、訓練預測模型與建立局部刻劃模型時的樣本編號一致。並且皆以此資料集作為分析。

表 2.2: 資料前處理後之最終資料集

idx	x1	x2	x3	...	x588	x589	x590	Pass/Fail
1	0.216411	0.856549	-0.434551	...	-0.140893	-0.050083	0.201450	0
2	1.094037	-0.374751	1.020782	...	0.421933	0.258167	1.167895	0
3	-1.114171	0.805982	-0.479627	...	3.631596	3.316370	-0.171694	1
4	-0.354825	-0.190915	-0.049316	...	-0.167828	-0.297870	-0.268061	0
5	0.234139	0.095176	1.121165	...	-0.167828	-0.297870	-0.268061	0



Chapter 3

研究方法與流程

本章節將說明本研究用到的方法，包含分群、建立預測模型、生成局部資料、擬合局部刻劃模型，首先介紹大綱，再來呈現每個流程的細部動作。

3.1 流程大綱




圖 3.1: 流程大綱

如圖 3.1 為整個研究流程大綱，細部說明如下。

3.2 流程細部

3.2.1 分群

1. 合成少數過度取樣技術用於降維：

本研究使用 PCA 降維空間的主成分作為分群的訊息。然而，由於目標類別分布高度不平衡，若直接對資料進行降維，其結果傾向由多數類別的訊息主導，使少數類別在特徵空間中的結構不容易辨識。

因此，本研究先於訓練資料中使用合成少數過度取樣技術 (Synthesized Minority Oversampling Technique, SMOTE) 產生少數類別的合成資料。以不改變多數類別分布的前提下，補足少數類別於降維的特徵空間中的資訊。

SMOTE 是在機器學習中解決數據類別不平衡問題的常見方法，其核心概念為針對每個少數類別的樣本 x_i ，尋找其鄰近樣本 $x_{neighbor}$ ，並在兩者之間進行插值產生合成資料 x_{new} ；其合成資料的生成式如下。

$$\mathbf{x}_{new} = \mathbf{x}_i + \lambda (\mathbf{x}_{neighbor} - \mathbf{x}_i), \quad \lambda \sim \text{Uniform}(0, 1)$$

將少數類別資料增至與多數類別資料相近比例後，接著再使用 PCA 做降維。

2. 分群與合成資料移除 (僅保留真實資料供後續建模)：

本研究採用 k-平均演算法 (k-means) 做分群以處理資料異質性，在 PCA 空間中依照樣本結構將資料切分為數個子群，使後續預測模型可在群內學習較一致的決策邊界。

k-means 是機器學習的非監督式分群方法，其做法為給定群數 k 以及自資料點中隨機選取群中心後，不斷進行：(1) 將每個資料點指派至最近的群中心；(2) 更新群中心為群內資料點的平均值，直到收斂。

本研究以手肘法 (elbow method) 評估不同群數 k 下的群內平方誤差 (within-cluster sum of squares, WCSS)，WCSS 定義如下。

$$\text{WCSS}(k) = \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2, \quad \boldsymbol{\mu}_i = \frac{1}{|S_i|} \sum_{\mathbf{x} \in S_i} \mathbf{x}$$

其中 S_i 為第 i 群， μ_i 為該群中心，WCSS 隨著 k 增加必然下降，因此選擇 k 值在 WCSS 降幅最大時作為分成 k 群的依據。本研究最終採用 $k = 2$ 進行分群。

另外，需強調的是：SMOTE 僅用於降維與分群的階段，以改善少數類別在降維空間的資訊；完成分群後，會將合成資料移除，只保留真實資料集以便後續在各群內分別進行預測模型的訓練與評估。

3.2.2 訓練預測模型

本研究在分群前及分群後的各群皆採用樹模型中的極限梯度提升 (Extreme Gradient Boosting, XGBoost)。

XGBoost 為監督式學習方法，基於梯度提升決策樹 (Gradient Boosting Decision Tree)，以加法模型逐步疊加弱學習器 (決策樹)，並透過損失函數的梯度資訊進行更新，同時引入多種優化以提升效能與模型泛化能力，可用於解決預測與分類問題，亦是目前最常被使用在 Kaggle 資料分析競賽當中的機器學習模型。

3.2.3 中心點選取與局部生成格子點擬合模型

1. 群內樣本挑選與中心點建立：

在建立各個模型時，皆搭配五折交叉驗證 (k -fold Cross Validation, $k = 5$)。將資料切分成 80% 作為訓練集資料，20% 作為測試集資料，共依序訓練五次 (五折) 以降低單次切分造成的評估偏差，由於資料具有類別不平衡，僅對訓練集執行 SMOTE 以提升少數類別可分性，測試集則維持不變。

在每一折交叉驗證中，使用該折的訓練集所訓練的模型，輸出該折的測試集之機率為 $\hat{p}$ ($\hat{p} \in [0, 1]$)，並轉為類別 Pass 或 Fail。本研究採用閾值為 0.5，亦即，當 $\hat{p} \geq 0.5$ 時，模型預測為 $\hat{y} = 1$ (Fail)；當 $\hat{p} < 0.5$ 時，模型預測為 $\hat{y} = 0$ (Pass)。在五折交叉驗證後，可得到所有樣本在模型輸出後的機率，

而當該機率愈接近 0.5 時，表示該樣本愈接近模型的決策邊界。換句話說，就是模型預測該樣本為哪一類很不明確。因此本研究設定篩選

的門檻為：

$$|\hat{p} - 0.5| \leq 0.05$$

並令其為群 c 下的樣本集合 S_n^c 。此處的 0.05 並非理論上唯一的門檻，而是基於研究操作上的考量所設定，一方面可保留足夠接近決策邊界的樣本，另一方面亦可避免門檻過於嚴格而使樣本數太少，不利後續分析與比較。接著定義群 c 的局部刻劃中心點：

$$\mathbf{x}_{\text{center}}^c = \frac{1}{|S_n^c|} \sum_{i \in S_n^c} \mathbf{x}_i = (x_1^c, \dots, x_p^c)$$

其中 $\mathbf{x}_i$ 為接近決策邊界的樣本點之特徵向量。

2. 局部格子點生成：

為了在群 c 中心點 $\mathbf{x}_{\text{center}}^c = (x_1^c, \dots, x_p^c)$ 附近建立可控制的局部範圍，所以設定每一個維度有一個固定的位移步長 δ ，然後令第 j 維可取的位移倍數為

$$m_j \in \{-k, -k+1, \dots, 0, \dots, k-1, k\}$$

因此每一維共有 $2k+1$ 個可取的位移倍數，而實際對應的位移量為

$$\{-k\delta, (-k+1)\delta, \dots, 0, \dots, (k-1)\delta, k\delta\}$$

因此，對任一維度的位移倍數可組成一個 p 維的位移向量 $\mathbf{m} = (m_1, \dots, m_p)$ ，可生成一個以中心點為基準的局部格子點

$$\mathbf{x}_{\mathbf{m}}^c = \mathbf{x}_{\text{center}}^c + \delta \mathbf{m} = (x_1^{(c)} + \delta m_1, \dots, x_p^{(c)} + \delta m_p)$$

亦即，對任一格子點而言，其各維度座標皆由中心點對應維度的值加上 δm_j 所形成。以下舉一個簡單例子：

如圖 3.2 以二維為例子說明中心點附近之局部格子點生成方式，假設二維情況下群 c 的中心點為 $\mathbf{x}_{\text{center}}^c = (1.2, -0.5)$ ，令 $\delta = 0.1$ 且 $k = 2$ ，則每一維可取的實際位移量為 $\{-0.2, -0.1, 0, 0.1, 0.2\}$ 。若位移向量

取 $\mathbf{m} = (-1, 2)$ ，則可得到該格子點為

$$\mathbf{x}_{\mathbf{m}}^c = (1.2 + 0.1 \times (-1), -0.5 + 0.1 \times 2) = (1.1, -0.3)$$

此例表示該格子點由中心點在 x_1 方向減少 0.1、在 x_2 方向增加 0.2 所形成。若在二維情況下取所有組合，則總共可形成 $5^2 = 25$ 個格子點，構成局部範圍。




圖 3.2: 以二維例子說明中心點附近的局部格子點生成方式。圖中橫軸與縱軸分別表示特徵維度 x_1 與 x_2 ，各格子點座標由中心點 $(1.2, -0.5)$ 沿兩維依固定步長 $\delta = 0.1$ 進行位移後形成；其中藍點為位移向量 $\mathbf{m} = (-1, 2)$ 所對應之格子點 $(1.1, -0.3)$ 。

3. 特徵選擇與建立局部刻劃模型：

然而，本研究 $p = 459$ 且令 $k = 2$ ，若對整個 p 維度取所有組合，則

理論上的格子點總數為

$$(2k + 1)^p = 5^{459}$$

其數量極為龐大，無法完整列舉。因此，本研究將所有格子點視為理論上某個局部的範圍，實作上並非窮舉全部組合，而是透過隨機抽樣的方式建立該局部空間，以進行後續分析。

首先，自所有格子點鐘隨機抽樣 100 萬筆，以其特徵向量作為自變數，以預測模型對該其所輸出的機率作為應變數，建立多元迴歸線性模型，並以普通最小平方法（Ordinary least squares, OLS）估計其迴歸係數。OLS 是透過最小化殘差平方和（Residual Sum of Squares）進行評估，當 X 滿秩使 $X^T X$ 可逆時，其估計式為

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

在此基礎上，為篩選在局部範圍中具有穩定影響的特徵，本研究進行重複抽樣與特徵選擇的流程：於每次抽樣與模型擬合中，依序以顯著水準 $p\text{-value} = \{0.05, 0.01, 0.005, 0.001, 0.0005\}$ 逐步選擇特徵，並重複執行 50 次，統計各特徵在最後一輪被保留的次數；將 50 次重複中皆在最後一輪被保留的特徵視為該群的局部範圍中最具穩定的特徵。

在決定最終的特徵後，再從相同的格子點生成方法中重新抽取 200 萬筆格子點，以最終的特徵作為自變數，並以其預測模型輸出的機率作為應變數，重新以 OLS 擬合最終的局部刻劃模型。

3.3 評估方法

針對預測模型，因有採用交叉驗證，故採用的評估指標會取平均，評估指標包含準確度（Accuracy, ACC）、誤報率（False Alarm Rate, FAR）與 ROC-AUC，其定義如下：

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}, \quad FAR = \frac{FP}{FP + TN}$$

ROC-AUC 則以預測模型輸出機率於不同門檻下所形成的 ROC 曲線面積表示。其中真陰性 (TN)、假陽性 (FP)、假陰性 (FN)、真陽性 (TP) 分別對應「Pass 判為 Pass」、「Pass 判為 Fail」、「Fail 判為 Pass」、「Fail 判為 Fail」。其說明如表 3.1 所示。

表 3.1: 混淆矩陣

	預測為 Pass	預測為 Fail
真實為 Pass	TN	FP
真實為 Fail	FN	TP

針對局部刻劃模型，以決定係數 R^2 評估局部刻劃模型對預測模型在該局部範圍的擬合程度。此外，亦透過各特徵之迴歸係數，觀察預測模型在中心點附近的決策行為，以分析不同特徵對預測結果的影響方向與重要性。



Chapter 4

研究結果

本章節先呈現分群後的預測模型評估，接著比較「未分群單一模型」與「分群後各群模型」的差異；最後說明在預測模型擬合局部刻劃模型的結果。

4.1 各群預測模型之評估與決策邊界樣本之採用

4.1.1 各群之類別分布與預測模型設定

依研究方法與流程內容，本研究於完成分群後，統計各群內真實類別的分布，如表 4.1 所示。

表 4.1: 各群之真實目標類別分布

	群 0	群 1
Pass	619	811
Fail	57	38

可見兩群皆包含 Pass 與 Fail 的樣本，各群皆滿足建立二元預測模型的基本門檻，後續將分別建立各群之預測模型，以觀察在不同群的預測模型，其預測能力表現是否存在差異。為提高實驗結果的可重現性，本研究提供相關環境與主要參數設定如表 4.2 所示。

表 4.2: 預測模型之環境與主要參數設定

項目	設定內容
程式版本	Python 3.12.7
預測模型	XGBClassifier
隨機種子	42
n_estimators	300
max_depth	3
learning_rate	0.1
subsample	0.8
colsample_bytree	0.8
min_child_weight	10
gamma	1.0
reg_lambda	2.0
reg_alpha	0.5
objective	binary:logistic
eval_metric	logloss

4.1.2 各群預測模型之評估結果比較

各群評估指標的平均整理如表 4.3 所示，從中可知，群 0 的 ACC 較低、FAR 較高，其 FAR = 4.68% 約為群 1 之 FAR = 0.99% 的 4.73 倍，而 ROC-AUC 則是群 0 較高。顯示不同群的預測準確度、錯誤回報率及整體排序能力存在差異，故整體資料存在異質性。

因此若未做分群而只使用整體資料，可能會把不同群的模型在預測時所判斷的依據被稀釋掉，使後續局部範圍內的模型預測更複雜，進而影響局部刻劃的擬合效果與解釋一致性。

表 4.3: 五折交叉驗證各群預測模型評估指標之平均

群名	樣本數	ACC	FAR	ROC-AUC
全體	1525	92.72%	1.89%	66.36%
群 0	676	88.47%	4.68%	69.74%
群 1	849	94.82%	0.99%	62.66%

4.1.3 各群中接近決策邊界之樣本

表 4.4 列出群 0 和群 1 中的預測模型輸出機率最接近 0.5 的前 30 個樣本，從中可知，兩群中皆存在輸出機率接近決策邊界的樣本，其中又以群 0 符合門檻的樣本數多於群 1。

依門檻 $|\hat{p}-0.5| \leq 0.05$ 篩選後，群 0 共有 12 個樣本符合門檻，其樣本編號為 82、225、44、144、345、298、484、105、111、247、653 與 109；群 1 共有 7 個樣本符合門檻，其樣本編號為 1158、990、1361、1189、1187、458 與 1054；後續皆作為各群局部刻劃中心點建立之依據。

表 4.4: 預測模型輸出機率最接近 0.5 的樣本摘要（由近到遠）

群 0			群 1		
樣本編號	$\hat{p}$	$ \hat{p}-0.5 $	樣本編號	$\hat{p}$	$ \hat{p}-0.5 $
82	0.498364	0.001636	1158	0.493004	0.006996
225	0.516134	0.016134	990	0.513882	0.013882
44	0.481022	0.018978	1361	0.521811	0.021811
144	0.527558	0.027558	1189	0.473835	0.026165
345	0.470658	0.029342	1187	0.528723	0.028723
298	0.468458	0.031542	458	0.464450	0.035550
484	0.533517	0.033517	1054	0.540420	0.040420
105	0.458454	0.041546	1254	0.421225	0.078775
111	0.457258	0.042742	1116	0.581546	0.081546
247	0.544061	0.044061	995	0.415044	0.084956
653	0.548375	0.048375	866	0.404468	0.095532
109	0.548989	0.048989	1108	0.395613	0.104387
359	0.436062	0.063938	1410	0.388741	0.111259
292	0.570125	0.070125	1009	0.357085	0.142915
20	0.570457	0.070457	1233	0.353403	0.146597

4.2 各群局部刻劃模型之建立與結果分析

本節呈現各群局部刻劃模型之結果。依研究方法與流程之特徵選擇程序，群 0 與群 1 分別有 97 個與 56 個特徵於 50 次實驗中於最終輪皆被保留，故後續以這些特徵作為局部刻劃模型之擬合的自變數；以重複抽區 200 萬個局部格子點及其對應之預測模型輸出機率作為應變數。

結果顯示如表 4.5，群 0 與群 1 之 R^2 點估計分別為 0.58 與 0.59，表示

局部刻劃模型對各群的預測模型輸出在局部範圍之變異皆可解釋約六成。

表 4.5: 局部刻劃模型決定係數 R^2

群	R^2
群 0	0.58
群 1	0.59

再者，表 4.6 與表 4.7 分別列出群 0 與群 1 之單次擬合局部刻劃模型中，依係數絕對值由大到小排序的前 30 個特徵及其係數。由表可之，兩群在局部範圍內具有不同的主要影響特徵，其中，群 0 以 x291、x7、x141、x87 與 x217 等特徵的影響性較大；群 1 則以 x386、x117、x420、x456 與 x28 等特徵較大。就係數分布而言，各群僅少數特徵具有較大的係數絕對值，其餘特徵的影響相對有限。

表 4.6: 群 0 之局部刻劃模型係數摘要（依係數絕對值由大到小）

特徵	係數	特徵	係數	特徵	係數
(intercept)	1.005144	x153	0.013929	x554	0.008468
x291	0.034033	x426	0.013283	x324	-0.008034
x7	-0.029912	x588	0.011796	x361	0.007764
x141	-0.028171	x585	0.010932	x247	-0.007745
x87	0.022993	x253	0.009463	x274	-0.007529
x217	0.022274	x144	-0.009319	x282	-0.007520
x461	0.019723	x470	0.009020	x525	0.007486
x20	0.017796	x103	-0.008795	x578	-0.006877
x58	-0.015820	x518	-0.008775	x240	0.006598
x1	-0.014731	x358	0.008565	x164	0.006592
x378	0.014099				

表 4.7: 群 1 之局部刻劃模型係數摘要 (依係數絕對值由大到小)

特徵	係數	特徵	係數	特徵	係數
(intercept)	0.996643	x8	0.004151	x196	0.002293
x386	0.016675	x92	0.003006	x337	0.002250
x117	-0.012556	x112	-0.002733	x81	0.002090
x420	-0.011799	x288	0.002681	x276	0.001966
x456	0.010252	x252	0.00264	x51	0.001769
x28	-0.009172	x17	0.002646	x355	-0.001724
x36	-0.008981	x347	0.002574	x145	-0.001689
x287	-0.007539	x82	0.002374	x431	0.001613
x103	-0.006848	x551	-0.002365	x571	-0.001550
x583	0.005797	x497	0.002339	x247	0.001472
x184	0.005055				

最後，本研究進一步評估局部刻劃模型在跨群時的表現，以觀察某群所建立的局部刻劃模型，在另一群的局部範圍是否仍具有良好的擬合度。重抽 1 萬點做評估後的結果如表 4.8 所示，並以決定係數 (R^2) 及相關係數 (ρ) 作為評估指標。其中， $f_c(\mathbf{x}_m^d)$ 表示第 c 群預測模型對第 d 群局部格子點 $\mathbf{x}_m^d$ 所輸出的預測機率； $g_c(\mathbf{x}_m^d)$ 表示第 c 群所建立之局部刻劃模型，對第 d 群局部格子點 $\mathbf{x}_m^d$ 所輸出的預測分數，其中 $c, d \in \{0, 1\}$ ， $\mathbf{m}$ 為局部格子點索引。

表 4.8: 各群的局部刻劃模型於群內與跨群套用下之評估結果

設置	R^2	ρ
$f_0(\mathbf{x}_m^0)$ vs. $g_0(\mathbf{x}_m^0)$	0.58	0.76
$f_1(\mathbf{x}_m^1)$ vs. $g_1(\mathbf{x}_m^1)$	0.64	0.80
$f_1(\mathbf{x}_m^1)$ vs. $g_0(\mathbf{x}_m^1)$	-4.15	0.22
$f_0(\mathbf{x}_m^0)$ vs. $g_1(\mathbf{x}_m^0)$	-2.02	0.05

結果顯示，當群 0 所建立的局部刻劃模型套用至群 1 的局部範圍時，其 $R^2 = -4.15$ 、 $\rho = 0.22$ ；反之，當群 1 所建立的局部刻劃模型亦套用至群 0 的局部範圍時；其 $R^2 = -2.02$ 、 $\rho = 0.05$ 。相較於各群模型在原來的局部範圍內可取得約六成左右的 R^2 與較高的相關係數，跨群套用後的 R^2 皆轉為負值，且相關係數亦明顯下降至兩成或接近 0，顯示模型跨群後，已無法有效刻劃另一群預測模型輸出的關係。

綜合而言，兩群的局部模型在跨群後皆明顯失去解釋性，顯示各群的預測模型在局部範圍內進行決策時所依賴的特徵結構並不一致，其局部範圍的決策具有群間差異。此結果說明局部刻劃模型具有明顯的區域性，因此不宜將某一群所建立之局部解釋直接套用至另一群。亦與前述分群的分析結果相互呼應，表示資料中的異質性不僅反映於整體模型的預測表現，亦反映於各群局部刻劃模型的重要特徵組成與影響方向。



Chapter 5

結論

5.1 總結

本研究建立一套從資料前處理、分群、預測模型建構，到局部刻劃模型擬合的分析流程。透過選取接近決策邊界的樣本來建立中心點，並於中心點附近作為局部範圍內生成的格子點，以降低外插風險，再利用局部刻劃模型來近似預測模型在該範圍內的輸出函數，以掌握模型的局部決策行為。研究結果顯示：

1. 整體資料中可能存在資料結構上具有差異的子群。以具高維度、高缺失性且類別不平衡的半導體製程資料 SECOM 資料為例，本研究比較整體建模與分群後建模之結果，發現資料在 PCA 降維投影空間中呈現群與群之間的差異，且各群在預測表現指標上亦存在差異。此結果顯示，先對資料進行分群，有助於將原本具有異質性的整體資料加以區分，使得後續在預測模型與局部刻劃模型的建立能在較一致的群內進行，進而提升局部刻劃結果的穩定性與可解釋性。
2. 在各群內分別建立預測模型及其對應的局部刻劃模型後，可觀察到各群的重要特徵及其影響大小和方向並不相同，顯示不同子群在局部的決策行為上存在明顯差異。此結果說明，若僅以整體模型進行解釋，容易忽略群與群之間在決策行為上的差異，因而降低模型在局部的決策行為之掌握程度，
3. 本研究所建立的局部線性刻劃模型，可在預測模型之外提供局部範圍

內較明確的特徵影響資訊，使原本難以直接說明的預測結果，可以轉化為由係數方向與大小所表示的決策描述。相較於僅關注模型預測的準確度之分析方式，本研究更進一步說明預測模型在特定局部範圍內是如何做出預測的判斷，有助於提升模型在半導體製程資料分析中的可解釋性與提升其應用價值。

5.2 未來工作



Bibliography

- Lundberg, S. and Lee, S. (2017). A Unified Approach to Interpreting Model Predictions. (arXiv:1705.07874). arXiv. <https://doi.org/10.48550/arXiv.1705.07874>.
- McCann, M. and Johnston, A. (2008). Secom. UCI Machine Learning Repository, <https://doi.org/10.24432/C54305>.
- Park, H., Koo, Y., Yang, H., Han, Y., and Nam, C. (2024). Study on Data Pre-processing for Machine Learning Based on Semiconductor Manufacturing Processes. *Sensors*, 24(17), 5461. <https://doi.org/10.3390/s24175461>.
- Presciuttini, A., Cantini, A., and Portioli-Staudacher, A. (2024). Advancing manufacturing with interpretable machine learning: LIME-driven insights from the SECOM dataset. *Advances in Production Management Systems. Production Management Systems for Volatile, Uncertain, Complex, and Ambiguous Environments*, 286–300. <https://doi.org/10.1007/978-3-031-71629-4>.
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). 「Why Should I Trust You?」: Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144. <https://doi.org/10.1145/2939672.2939778>.
- Salem, M., Taheri, S., and Yuan, J.-S. (2018). An Experimental Evaluation of Fault Diagnosis from Imbalanced and Incomplete Data for Smart Semiconductor Manufacturing. *Big Data and Cognitive Computing*, 2(4), 30. <https://doi.org/10.3390/bdcc2040030>.

Troyanskaya, O., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., and Altman, R. B. (2001). Missing value estimation methods for DNA microarrays. *Bioinformatics*, 17(6), 520–525. <https://api.semanticscholar.org/CorpusID:1105917>.

賴立夫 (2022). 使用 KNN 和決策樹方法對填補缺失值的製造數據進行失效預測和原因追蹤分析. <https://hdl.handle.net/11296/ub6st3>.

